AI, ML и Generative AI

Инженерные ментальные модели, архитектура систем и продакшн-реалии

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Игорь Рубанович (Ihar Rubanovich)

Engineering Manager II & AI Ambassador в EPAM Systems. Эксперт по внедрению системного AI-Assisted Engineering.



ТЕКУЩИЕ РОЛИ И ОПЫТ

Engineering Manager II • AI Ambassador @ EPAM

• **10+ лет в IT-индустрии:** от разработки распределенных систем до руководства delivery-командами.

• **AI-Assisted Engineering:** внедрение автономных кодинг-агентов (CodeMie, Cursor, Antigravity) в производство ПО.

• **Практический AI R&D:** Архитектор и разработчик Creator Tools — набор AI-инструментов для авторов YouTube, помогающих экономить время на производстве контента, оптимизировать процессы и зарабатывать больше.

РАБОЧИЙ EMAIL (ДЛЯ ДОБАВЛЕНИЯ В GITHUB COLLABORATORS):
ihar_rubanovich@epam.com

Формат: Практическая передача опыта реального внедрения AI в энтерпрайз-проекты.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Что мы изучим на курсе GenAI Basics

Шесть прикладных инженерных модулей — от базовых вызовов API до мультимодальности, открытых моделей и автономных агентов:

МОДУЛЬ 1 • УРОКИ 01-03

Фундамент & Python API

- L01: ИИ, ML и генеративный ИИ: общая картина
- L02: Токены, промпты, контекст, эмбеддинги
- L03: Первый вызов модели из Python (Gemini API)

МОДУЛЬ 2 • УРОКИ 04-06

Мультимодальный GenAI

- L04: Генерация картинок: сервисы и приёмы
- L05: Генерация видео: модели и API
- L06: Голос и звук: озвучка, распознавание, музыка

МОДУЛЬ 3 • УРОКИ 07-09

Экосистемы и аналитика

- L07: Экосистема Microsoft Copilot
- L08: ИИ для анализа данных
- L09: Экосистема Claude и артефакты

МОДУЛЬ 4 • УРОК 10

Open-Source & Local

- L10: Открытые модели: LM Studio, локально и RunPod

МОДУЛЬ 5 • УРОКИ 11-13

Агенты, инструменты и MCP

- L11: Вызов функций и первый агент
- L12: MCP, инструменты и фреймворки агентов
- L13: Свой ИИ-ассистент

МОДУЛЬ 6 • УРОКИ 14-16

От идеи к продукту

- L14: Быстрый прототип на Streamlit
- L15: Ответственный ИИ, безопасность и законы
- L16: Агентная разработка: агенты для кода

Цель курса: Системное понимание (Vision), практический кругозор и базовые навыки для уверенного погружения в GenAI.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Организация домашних заданий: GitHub-репозиторий

Все практические задания сдаются строго в виде структурированного репозитория на GitHub.

genai-homeworks — main

```
genai-homeworks/
├── README.md                    # Общее оглавление и ссылки на ДЗ
│
├── L01/                         # Урок 01
│   └── README.md                # ДЗ 1: AI Use-Case Memo (.md)
│
├── L02/                         # Урок 02
│   └── README.md                # ДЗ 2: Анализ токенов и промптинг
│
├── L03/                         # Урок 03
│   ├── solution.py              # Код Python (Pydantic / Streaming
│   ├── requirements.txt         # Зависимости
│   └── README.md                # Описание запуска
│
└── ...                          # Последующие модули (L04 - L16)
```

Порядок сдачи и ревью

1. Создание репозитория:
Создайте репозиторий `genai-homeworks` (Public или Private на ваш выбор).

2. Добавление преподавателя в Collaborators:
`Settings` → `Collaborators` → `Add people` :
ihar_rubanovich@epam.com

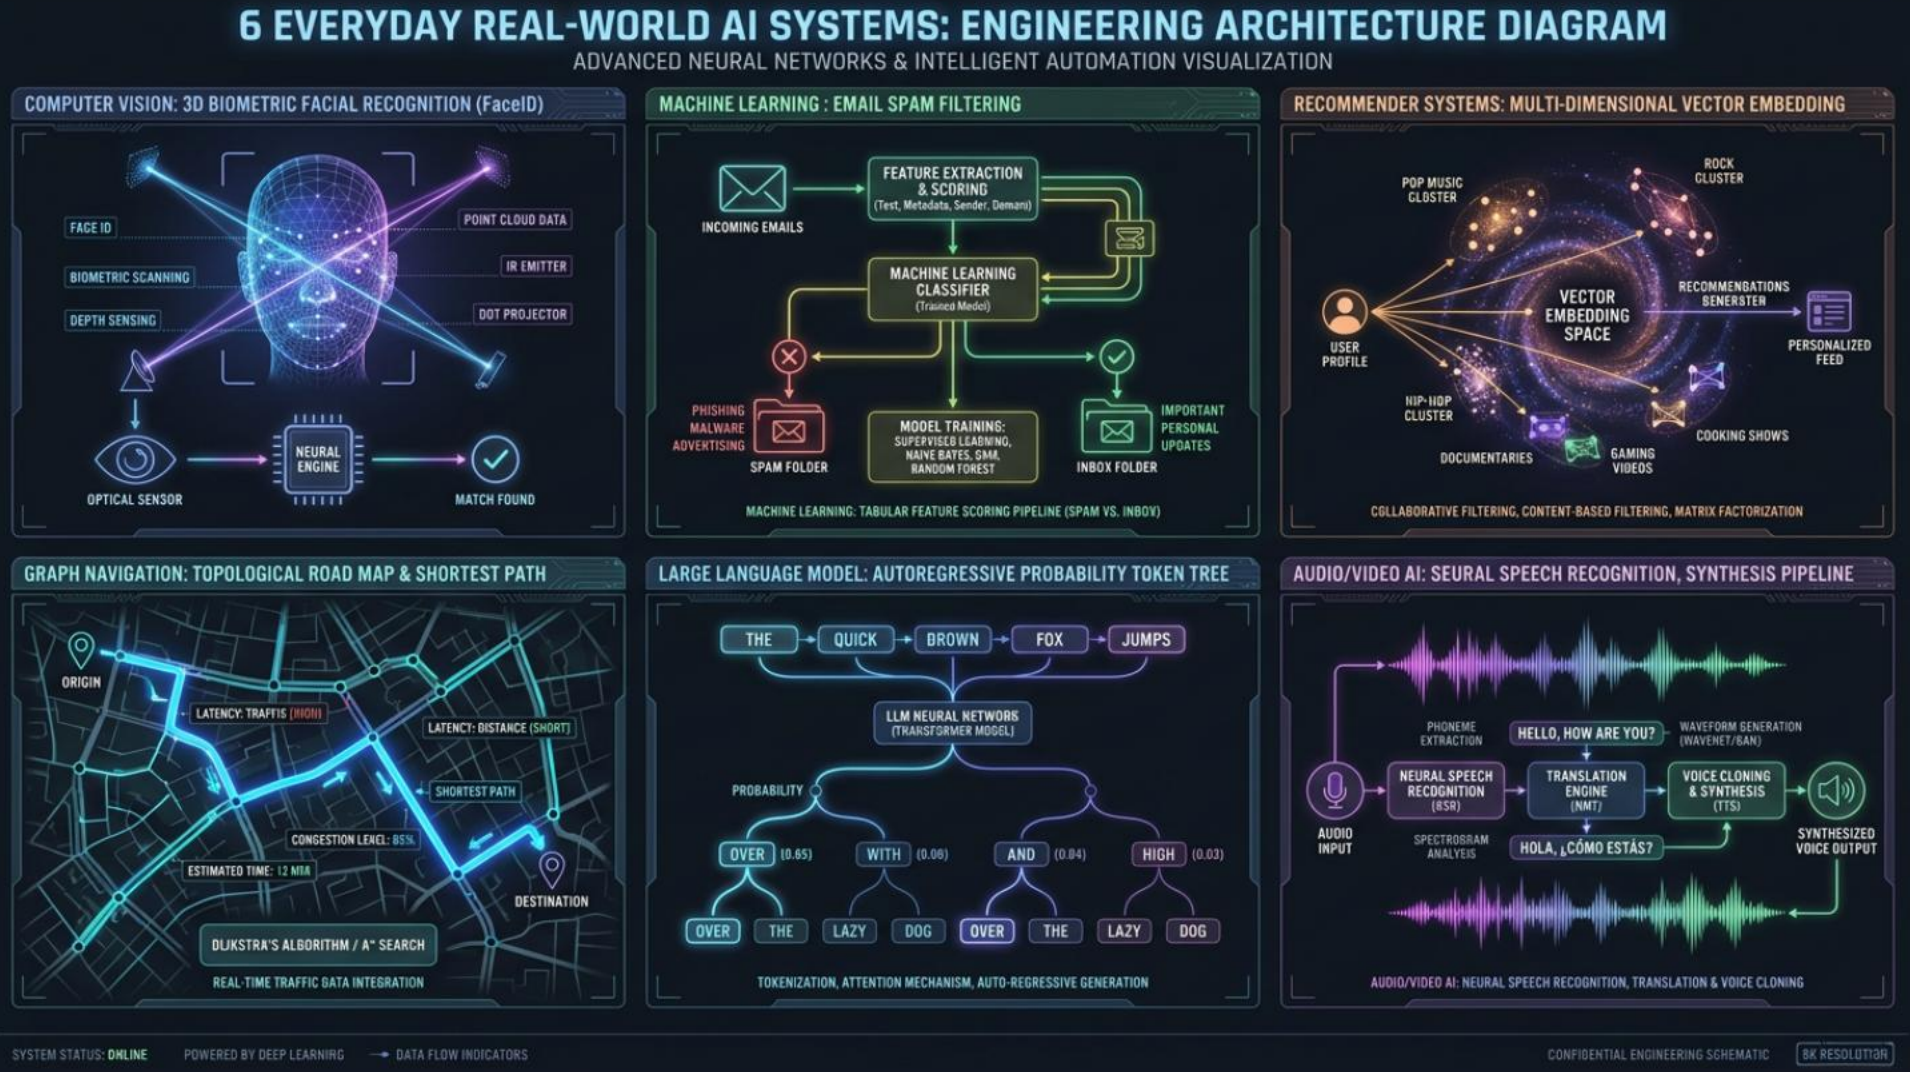
3. Формат проверки:
Ссылка на репозиторий или PR отправляется в учебный трекер курса. Каждое задание получает архитектурный фидбек.

Важно: Заведите репозиторий и добавьте коллаборатора сегодня после лекции.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Введение в AI: где технологии окружают нас каждый день

Шесть реальных систем — от FaceID и спам-фильтра до рекомендаций и языковых моделей:

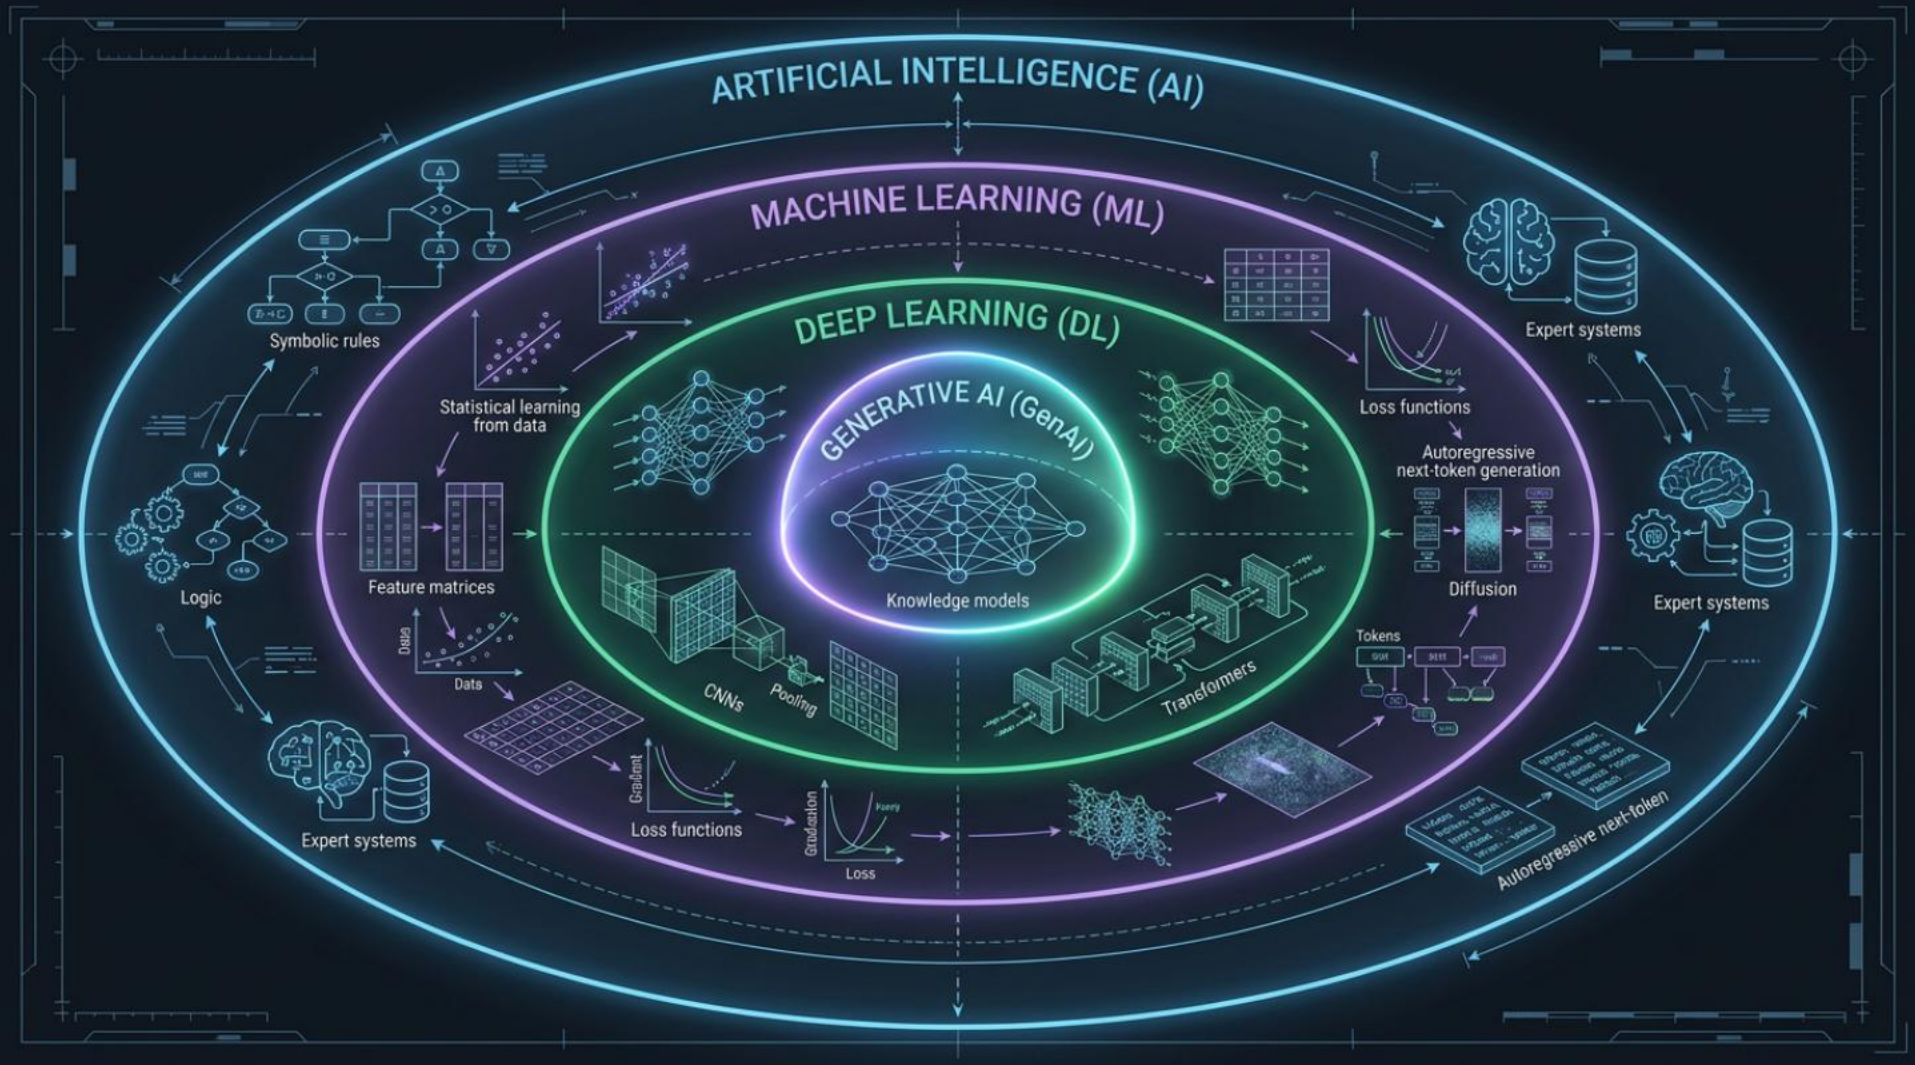


Вывод: Все эти сервисы называют словом «AI», но под капотом работают совершенно разные математические аппараты.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Таксономия: как соотносятся AI, ML, DL и GenAI

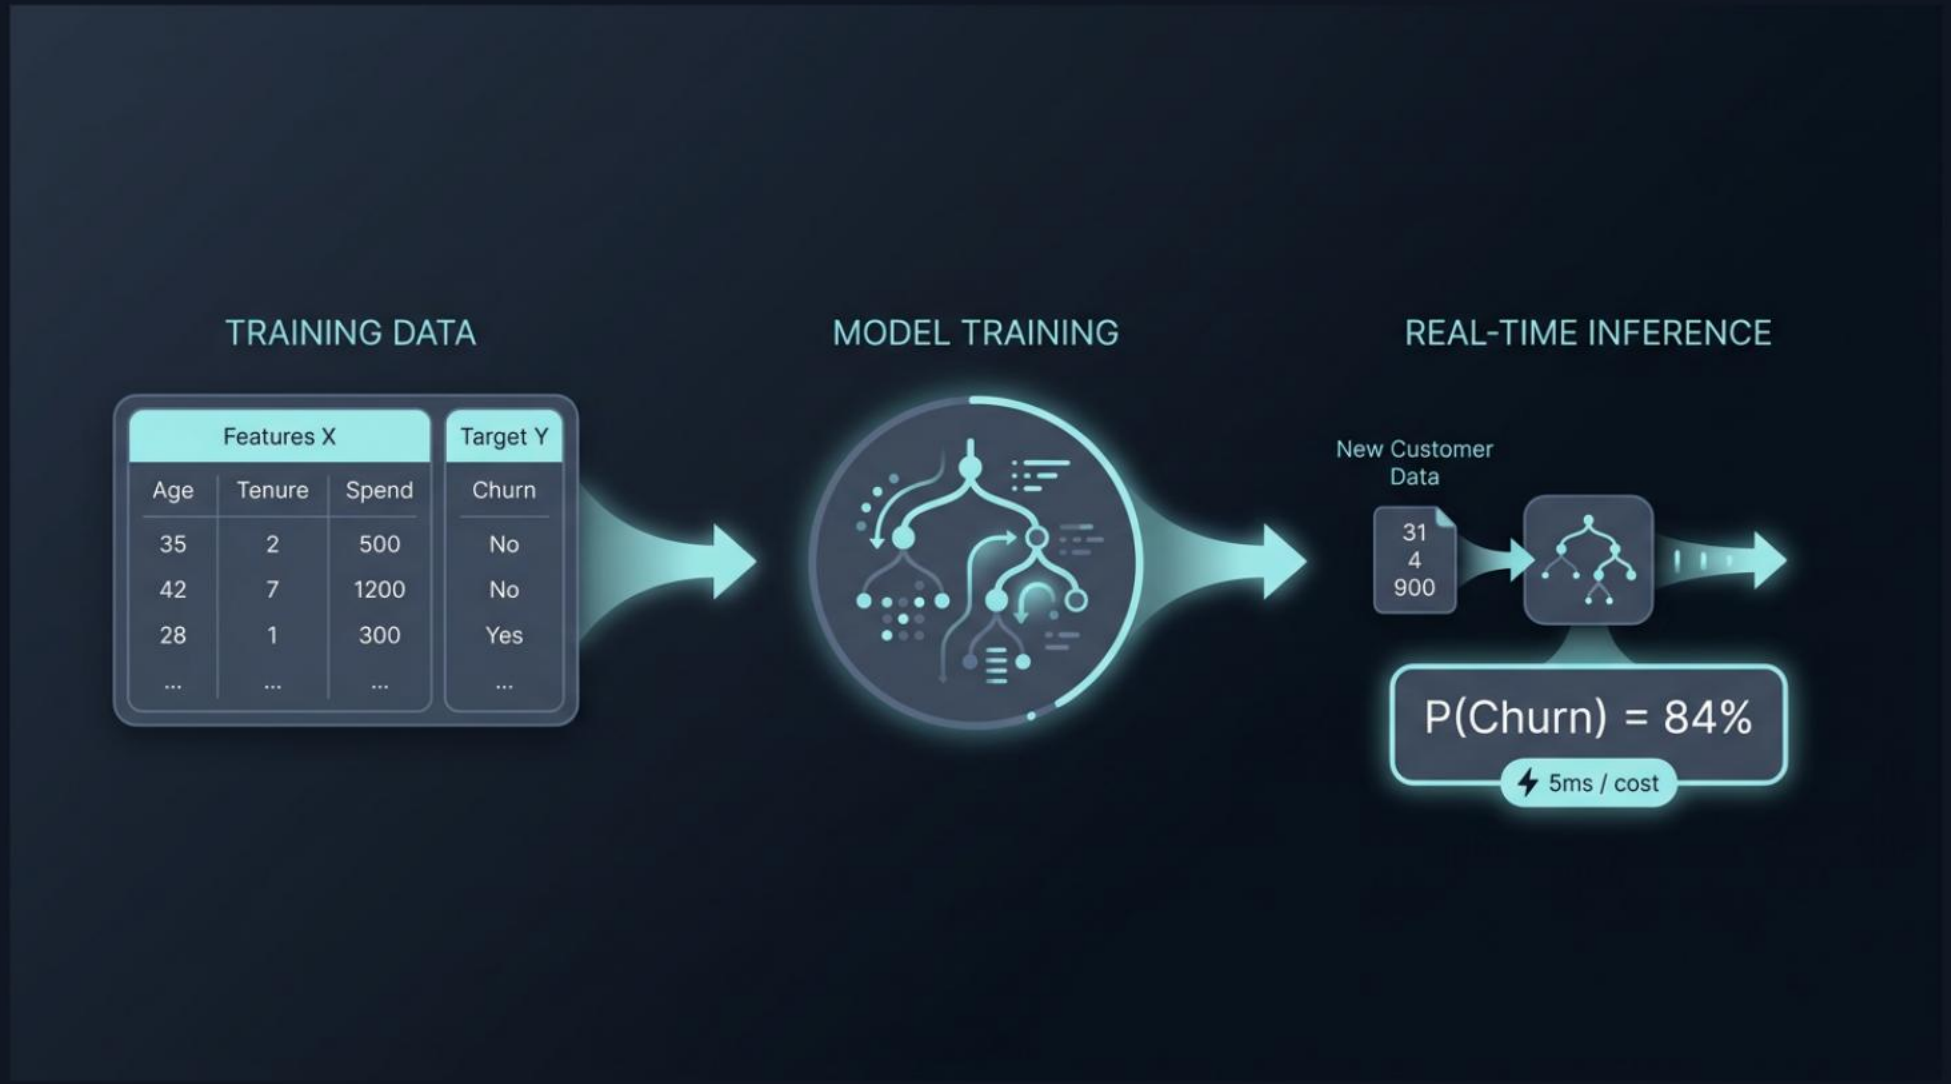
Строгая архитектурная матрешка: от общего понятия интеллекта к современным генеративным моделям:



Формула: Каждый GenAI — это Deep Learning. Но не каждый ML является Generative AI.

Классический Machine Learning: Архитектура и свойства

Обучение на размеченных исторических таблицах и мгновенный инференс вероятностей:

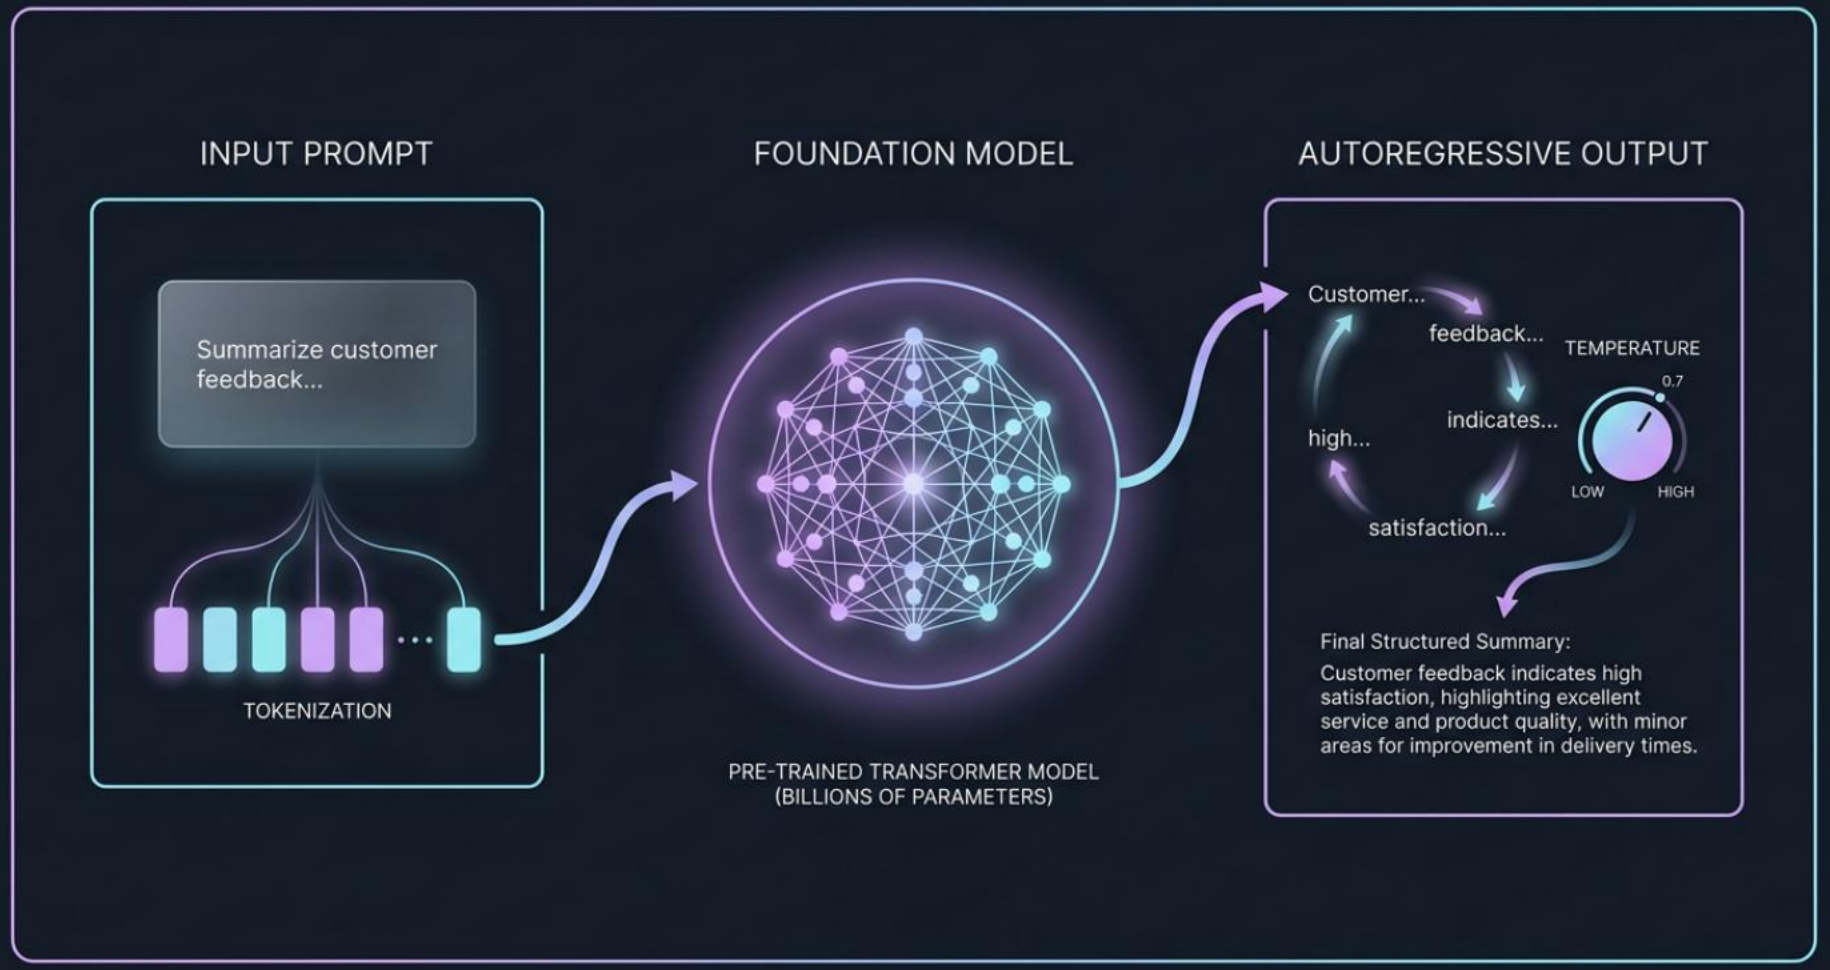


Преимущество ML: Скорость 5ms, стоимость $0 за запрос, строгая калибровка вероятностей на числах.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Generative AI: Архитектура больших языковых моделей

Предобученное ядро трансформера и авторегрессионный синтез нового контента токен за токеном:

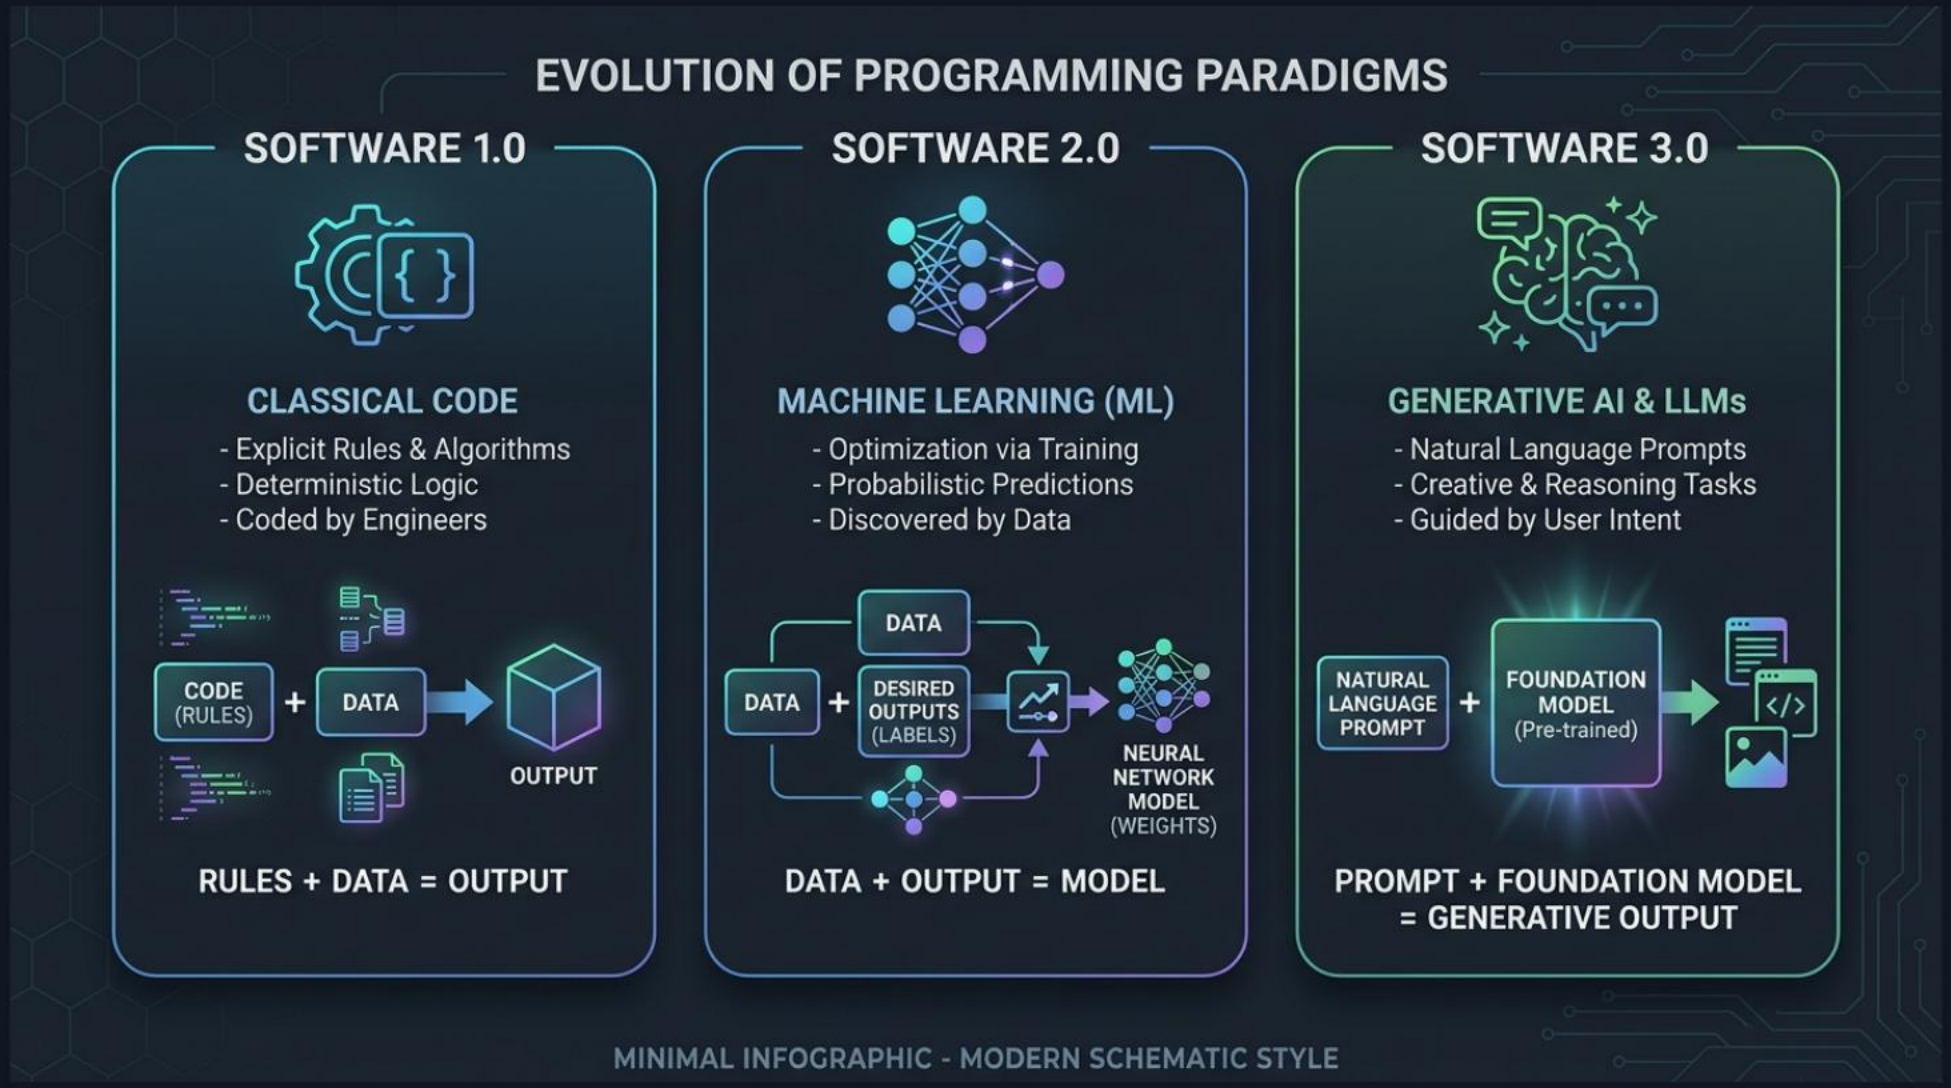


Суть: GenAI работает со смыслом и языком, синтезируя ответ через вероятностное семплирование.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Эволюция кода: Software 1.0 ➔ 2.0 ➔ 3.0

Как изменился способ заставлять компьютеры решать задачи за последние 20 лет:



Суть AI-инженера: Не обучать модели с нуля, а связывать строгий код 1.0 с гибкостью моделей 3.0.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Ловушка хайпа: почему «AI First» убивает бюджет

Попытка натянуть ChatGPT на любую задачу в компании гарантирует медленный и дорогой провал:

АНТИПАТТЕРН

«Давайте прикрутим LLM в бухгалтерию!»

- **Задержка:** 3 секунды ожидания вместо 2 миллисекунд в SQL.
- **Цена:** $0.03 за клик вместо $0.000001 в обычном коде.
- **Точность:** 95% вместо 100% (5% ошибок в счетах обанкротят компанию).

ИНЖЕНЕРНЫЙ ПОДХОД

«Problem First: Сначала тип задачи»

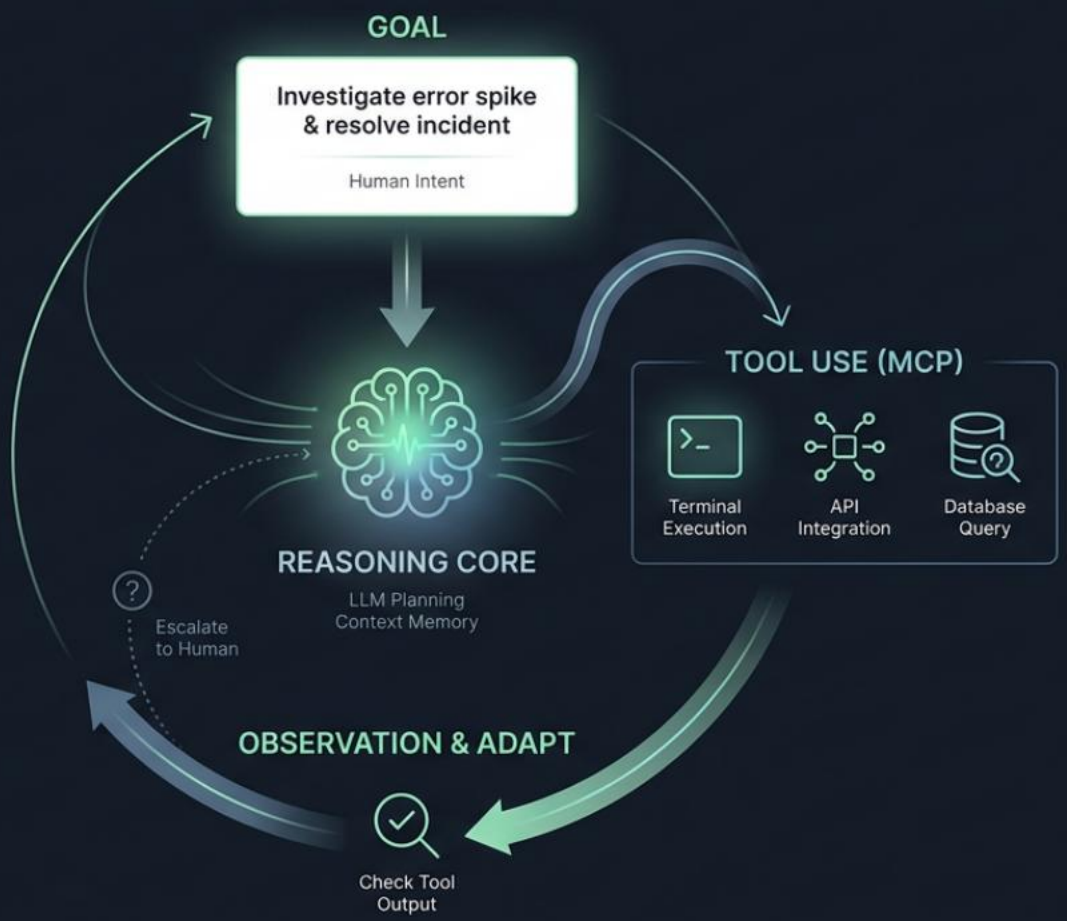
- **Точные формулы и правила?** ➔ Только детерминированный код (100% гарантия).
- **Исторические цифры и тренды?** ➔ Классический ML (скорость и статистика).
- **Неструктурированный язык и смысл?** ➔ Generative AI (под контролем человека).

Золотое правило: Если задачу можно решить 5 строчками кода — вызов LLM там запрещен.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Четыре парадигмы: когда нужен автономный AI-агент

От кода и классического ML к замкнутому циклу восприятия, мышления и вызова инструментов (MCP):

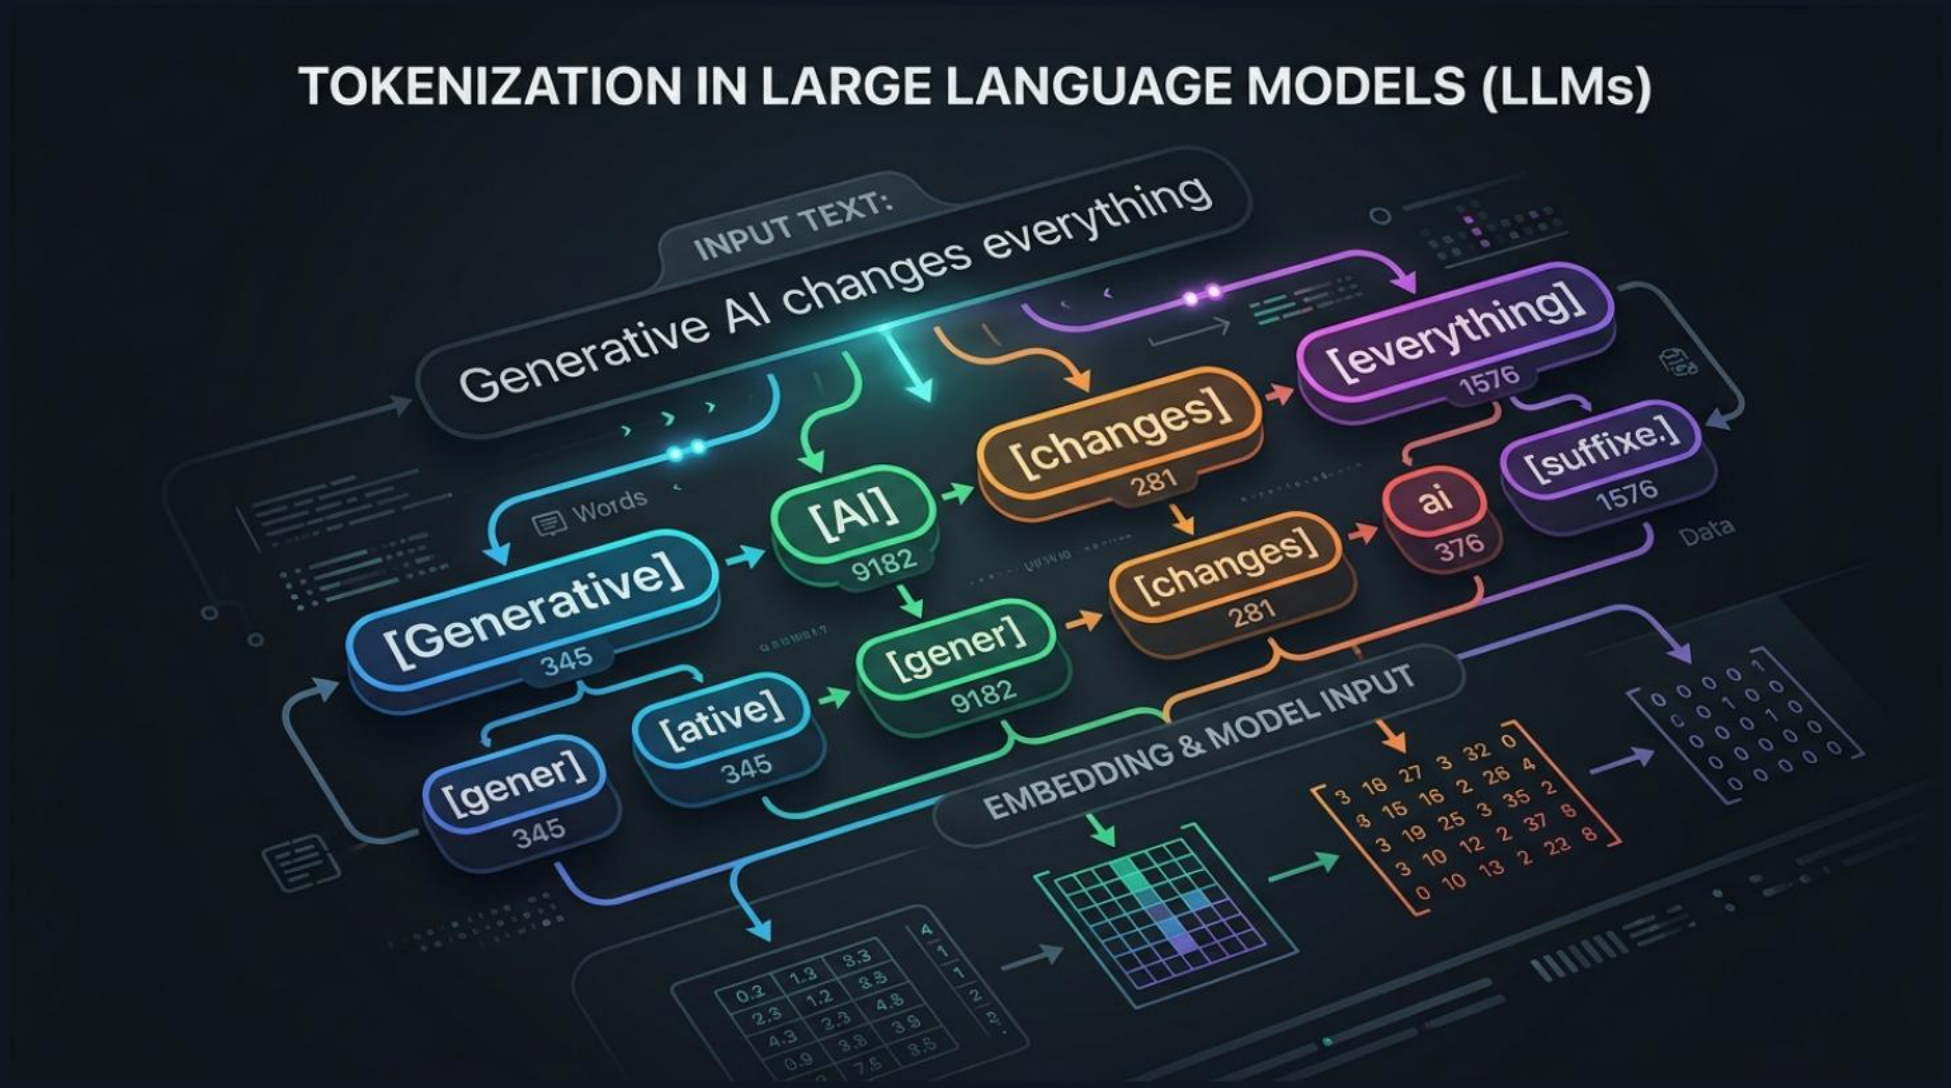


Формула: Код считает. ML прогнозирует. LLM пишет текст. Агент решает задачу в цикле (Goal → Think → Act → Observe).

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Что видит модель: Токенизация текста

Модель не видит буквы или слова. Она оперирует субсловами (токенами) и их числовыми векторами:



Экономика: Вы платите провайдерам не за секунды или мегабайты, а за количество входных и выходных токенов.

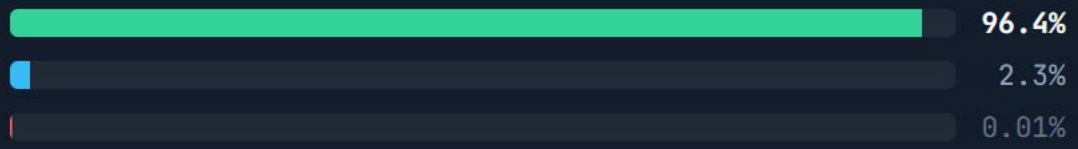
Под капотом: «T9 на стероидах» и вероятности

LLM — это авторегрессионный калькулятор вероятности следующего токена:

ВХОДНОЙ КОНТЕКСТ (PROMPT):

«Столица Франции — это [?]»

РАСПРЕДЕЛЕНИЕ ВЕРОЯТНОСТЕЙ СЛЕДУЮЩЕГО ТОКЕНА:



Параметр Temperature

Temperature = 0.0 (Строгий):
Выбирает строго самый вероятный токен. Идеально для JSON-схем, извлечения фактов и кода.

Temperature = 0.8 (Креативный):
Сэмплирует с вариативностью. Идеально для слоганов, мозгового штурма и сторителлинга.

Правило инженера: Выход модели — это статистика совпадений в данных, а не логическое рассуждение.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Галлюцинации vs Grounding: Как привязать модель к фактам

Модель не знает, где правда, а где ложь. Она просто собирает правдоподобный текст:

AI HALLUCINATION:
Probabilistic Next-Token Guess



SOURCE:
Johnson et al. (2025).
The quantum entanglement
of dream sequences.

VS

GROUNDING (RAG):
Grounded with Verified Document

ANSWER: 100% ACCURATE.
Solar flares result from sudden energy releases in the Sun's atmosphere due to magnetic reconnection.



Принцип RAG: Не заставляйте модель вспоминать факт из весов. Положите факт в контекст запроса.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Кофе-пауза: Перезагрузка внимания

5 минут перерыва. Время перевести дух, налить кофе или чай перед второй практической частью лекции.

ТАЙМЕР ОБРАТНОГО ОТСЧЕТА

05:00

СТАРТ СБРОС

Впереди во второй части:

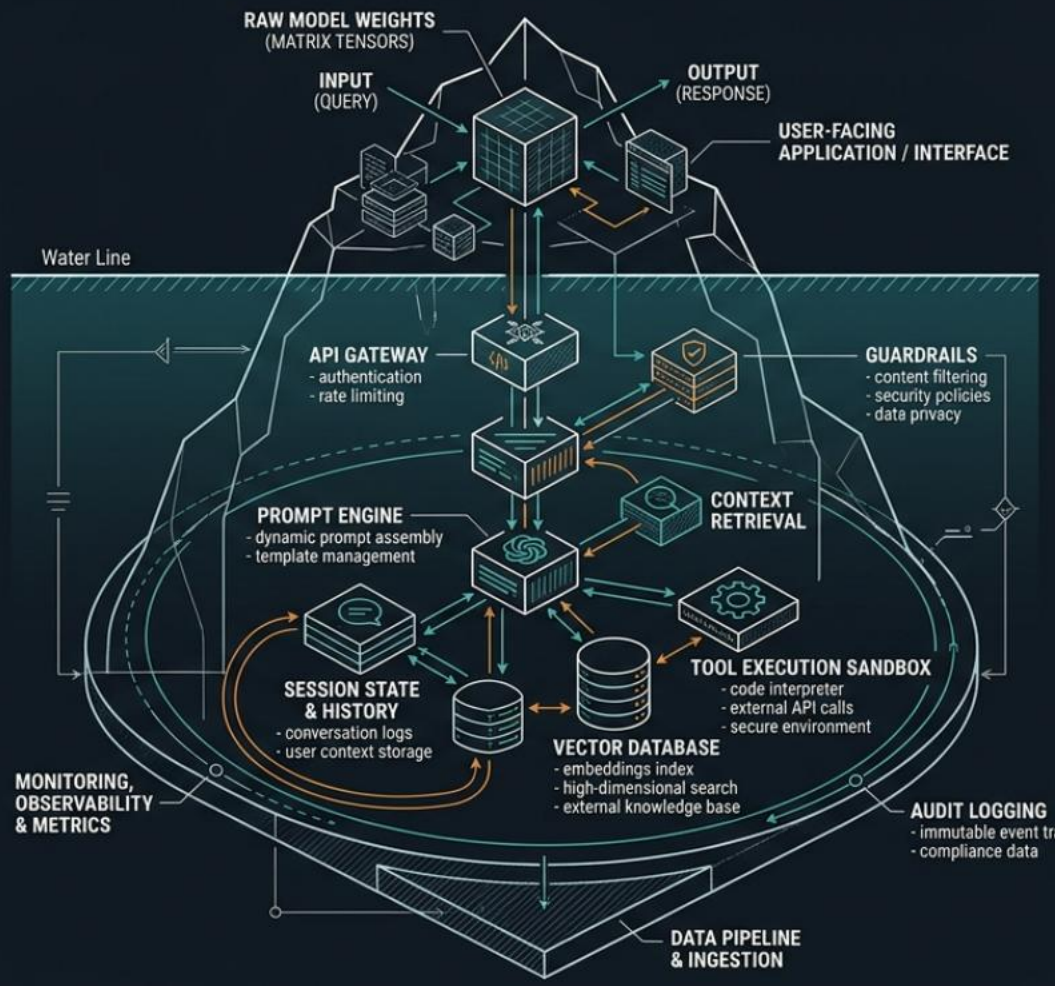
- **Архитектурный айсберг:** почему вызов API — это лишь 10% системы.
- **Зоны риска (Blast Radius):** где допустима автономия, а где нужен Human-in-the-Loop.
- **Уроки продакшна:** 4 фиаско индустрии vs опыт EPAM CodeMie @ Dawn Foods.
- **Дерево решений & Домашка №1:** архитектурный аудит и практический эталон.

Экватор занятия: Отдыхаем 5 минут и переходим к архитектуре и практике.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Архитектурный айсберг: Модель ≠ Продукт

Вызов API модели занимает 10 строк кода. Создание надежной системы требует еще 90% инфраструктуры:



Инженерная истина: Демо собирается за вечер. Продакшн строится месяцами вокруг надежности и безопасности.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Зона поражения (Blast Radius) и Human-in-the-Loop

Степень автономии модели обязана быть обратно пропорциональна цене ее ошибки:

НИЗКИЙ РИСК • ЗЕЛЕНАЯ ЗОНА

Черновики и креатив

- Саммари длинных статей
- Генерация идей и черновиков писем
- Внутренний поиск по документам

Автономия: Полная. Ошибка никого не убьет и не обанкротит.

СРЕДНИЙ РИСК • ЖЕЛТАЯ ЗОНА

Кодинг & Подготовка данных

- Автодополнение кода в IDE (Copilot)
- Первичное ревью Pull Request
- Классификация клиентских тикетов

Автономия: Co-pilot. Человек всегда проверяет перед мерджем.

ВЫСОКИЙ РИСК • КРАСНАЯ ЗОНА

Финансы, Прод и Юриспруденция

- Проведение платежей и счетов
- Юридические договоры и оферты
- Автономный деплой в продакшн

Автономия: Запрещена. Модель лишь готовит черновик решения.

Правило безопасности: Чем выше цена ошибки, тем жестче Human-in-the-Loop барьер.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Индустриальные кейсы: 4 дорогих провала vs 4 победы

Реальные уроки бизнеса: где компании потеряли миллионы, а где получили системный ROI:

4 ДОРОГИХ ПРОВАЛА (НЕДООЦЕНКА РИСКОВ)

- **Air Canada ($):** Чат-бот пообещал пассажиру скидку вопреки регламенту. Суд обязал компанию выплатить деньги.
- **Chevrolet за $1:** Чат-бот автосалона согласился продать клиенту Tahoe за $1 из-за банального jailbreak-промпта.
- **DPD Delivery:** Бот службы доставки обматерил клиента и написал стих о собственной бесполезности.
- **NYC Business Bot:** Официальный AI-консультант Нью-Йорка советовал предпринимателям нарушать трудовое право.

4 НАДЕЖНЫХ ПОБЕДЫ (СИСТЕМНЫЙ ROI)

- **EPAM CodeMie @ Dawn Foods:** Внедрение AI-оркестратора SDLC: ускорение написания фич и автотестов на 35%, генерация документации с контекстом проекта.
- **GitHub Copilot:** 55% ускорение написания рутинного кода и тестов у сотен тысяч разработчиков по всему миру.
- **Stripe Fraud Detection:** Гибрид классического ML-скоринга и LLM для расследования многослойных схем мошенничества.
- **Morgan Stanley:** Внутренний RAG-GPT для мгновенного поиска по 100,000 закрытых инвестиционных отчетов банка.

Вывод: Побеждают те, кто заземляет модели на базу знаний и встраивает строгие валидаторы.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Инженерное дерево решений: Нужен ли здесь GenAI?

Алгоритмический фильтр перед началом любого проекта. Прогоните задачу через 4 вопроса:

01	Можно ли решить задачу детерминированным алгоритмом, регулярным выражением или SQL?	ДА ➔ Пишите обычный код
02	Задача требует числового прогноза на основе исторических таблиц (отток, спрос, цены)?	ДА ➔ Обучайте классический ML
03	Требуется ли работа с неструктурированным языком, смыслом, кодом или генерацией идей?	ДА ➔ Применяйте Generative AI
04	Критична ли 100% точность для бизнеса, и есть ли процедура Human-in-the-Loop?	План валидации обязателен

Принцип зрелости: Не решайте проблемы молотком, если перед вами шуруп.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Домашнее задание: AI Use-Case Memo

Практический переход от теории к архитектурному аудиту: требования и реальный образец выполнения:

Требования к Memo (300-500 слов):

1. Процесс: Выберите 1 реальную задачу из вашей работы.

2. Дерево решений: Обоснуйте, почему нужен GenAI, а не SQL или классический ML.

3. Blast Radius: Оцените зону риска (Зеленая / Желтая / Красная) и степень автономии.

4. Архитектурное табу: Что вы категорически запретите делать модели в этой системе?

ПОРЯДОК СДАЧИ В GITHUB:

Файл: `genai-homeworks/L01/README.md`

Коллаборатор: `ihar_rubanovich@epam.com`

Образец выполнения: Курьер Glovo / Доставка еды

ПРИМЕР ДЗ

1. Процесс: В ресторане закончилось заказанное блюдо (или не указан код подъезда). Курьеру нужно срочно связаться с клиентом и согласовать замену/уточнить данные без срыва времени доставки.

2. Дерево решений:

- *Маршрут & ETA:* Граф дорог + ML-прогноз трафика (100% математика, 5ms).
- *Связь с клиентом:* **GenAI** (вежливое адаптивное сообщение на родном языке клиента).

3. Blast Radius (Желтая зона • Co-pilot): Модель генерирует готовый черновик сообщения («Здравствуйте! Чизкейк закончился, предлагают тирамису. Согласны?»), но **курьер подтверждает отправку тапом**.

4. Архитектурное табу: Модели **строго запрещено:** отменять заказ, начислять скидки/компенсации за счет сервиса, списывать деньги с карты клиента или штрафовать ресторан.

Дедлайн: Сдать до следующего занятия. Каждое Memo получает персональное архитектурное ревью.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран

Вопросы и ответы & Анонс Урока 02

Обсуждаем ваши рабочие кейсы и готовимся к глубокому погружению в физику моделей:

Открытый микрофон

Задавайте вопросы в чат или подключайтесь голосом.

Любые сомнения по выбору между кодом, классическим ML и LLM в ваших проектах приветствуются!

СЛЕДУЮЩЕЕ ЗАНЯТИЕ • УРОК 02

LLM Fundamentals: Токены, контекст и RAG

- Глубокий разбор BPE-токенизации на Python.
- Анатомия контекстного окна: почему 128k не спасают от потерь.
- Векторные эмбеддинги и первый заземленный RAG-пайплайн.

Контакты: ihar_rubanovich@epam.com • Материалы урока в репозитории.

← / → : Слайды | Пробел : Вперед | N : Заметки спикера | G : Обзорная сетка | F : Полный экран