

Генерация и редактирование изображений через API

От случайных пикселей к контролируемым инженерным пайплайнам

АКСИОМА 10/90 В COMPUTER VISION

«Аксиома 10/90: Вызов модели через API — это лишь 10% решения. 90% продакшена — это маски, фиксация геометрии, объектные хранилища S3/GCS, декодирование Base64, аудит метаданных и шлюзы модерации.»

01 • [PRIMITIVES](#)

Визуальные примитивы

Text-to-Image, Inpainting, Outpainting, маски и разделение сигналов референсов.

02 • [CONTROL](#)

Контрактный контроль

Анатомия промпта как техзадания: неприкосновенные свойства и критерии приемки.

03 • [PIPELINE](#)

Продакшен-пайплайн

Аудит метаданных, Base64 декодирование, Blast Radius и Human-in-the-Loop.

Игорь Рубанович

Engineering Manager II & AI Ambassador @ EPAM Systems



Igor Rubanovich

ihar_rubanovich@epam.com

ENTERPRISE DELIVERY

Архитектура и системное лидерство

15+ лет в IT-инженерии, управление распределенными командами и внедрение AI-ассистентов в корпоративный SDLC.

ПРАКТИЧЕСКИЙ AI R&D

Архитектор Creator Tools (Пет-проект)

Создатель и архитектор Creator Tools — набора AI-инструментов для авторов YouTube, помогающих экономить время на производстве контента, оптимизировать процессы и зарабатывать больше.

РЕАЛЬНЫЙ КЕЙС

EPAM CodeMie @ Dawn Foods

Ускорение SDLC на 35% при разработке фич, модульном тестировании и архитектурной документации.

ОБРАТНАЯ СВЯЗЬ

Сдача домашних заданий

Коллаборация в GitHub и ревью кода: ihar_rubanovich@epam.com

Дорожная карта курса: Где мы находимся

16 занятий в 6 модулях: от текстовых BPE-токенов к мультимодальности и агентам

Модуль 1 • L01-L03

Фундамент и Core API

BPE-токены, промптинг, контекстное окно, вызовы API на Python, стриминг и структурированный JSON.

✓ ЗАВЕРШЕН

Вы здесь • Модуль 2

Мультимодальность

- L04: Изображения и редактирование (API)
- L05: Видеогенерация (Runway, Kling, Sora)
- L06: Речь и аудио (ElevenLabs, Whisper)

▶ ТЕКУЩИЙ ЭТАП

Модуль 3 • L07-L09

Инструменты инженера

GitHub Copilot, экосистема Claude Artifacts, продвинутый анализ данных и генерация кода.

⌚ СЛЕДУЮЩИЙ

Модуль 4 • L10

Локальный AI и открытые модели

LM Studio, Ollama, квантование весов, локальный инференс и облачный деплой на RunPod.

⌚ СЛЕДУЮЩИЙ

Модуль 5 • L11-L13

Агенты и протокол MCP

Function Calling, создание первых автономных агентов, архитектура Model Context Protocol.

⌚ СЛЕДУЮЩИЙ

Модуль 6 • L14-L16

Продакшен и Agentic IDE

Быстрое прототипирование на Streamlit, безопасность и этика, Cursor, Windsurf, Claude Code.

⌚ СЛЕДУЮЩИЙ

GitHub Workflow и структура артефактов

Стандартизированная сдача домашних: ветка lesson-04 и воспроизводимый пакет

ДЕРЕВО РЕПОЗИТОРИЯ • L04

```
genai-homeworks/
├─ L01/
├─ L02/
├─ L03/
└─ L04/
    ├─ brief.md # Visual Generation Canvas
    ├─ references/ # Исходные фото и маски
    ├─ prompt_v1.txt # Начальный промпт
    ├─ prompt_v2.txt # Промпт со спецификацией табу
    ├─ candidates/ # Сгенерированные варианты
    ├─ qa.md # Чек-лист аудита дефектов
    └─ selected/ # Принятый результат + метаданные
```

ПРОТОКОЛ СДАЧИ

Ветка lesson-04 и Pull Request

Все изменения вносятся в отдельную ветку. Открывается PR в main, в рецензенты добавляется ihar_rubanovich@epam.com. Никаких прямых пушей в main.

ПОЛИТИКА БЕЗОПАСНОСТИ

Запрет приватных данных и закрытых брендов

Никаких реальных лиц сотрудников без письменного согласия, закрытых чертежей или невыпущенных продуктов. Используем открытые тестовые ассеты.

Ловушка: «Красиво ≠ Пригодно» (Pretty ≠ Usable)

Почему эстетически безупречная картинка может стать скрытой катастрофой для бизнеса

РАЗВЛЕЧЕНИЕ VS ПРОДАКШЕН

Иллюзия совершенства

В текстовых моделях плохой ответ виден сразу: код не компилируется или факт неверен.

В генерации графики **непригодная картинка выглядит кинематографично и дорого**. Человеческий мозг очаровывается сочным светом и не замечает, что объект перестал соответствовать реальности.

5 ТИХИХ КАТАСТРОФ В ПРОДАКШЕНЕ

- 01 Искажение формы изделия: Ручка сместилась на 15%, геометрия керамики поплыла — покупатель получит товар с другой эргономикой.
- 02 Галлюцинация логотипа: Официальный товарный знак превращается в бессмысленный псевдо-шрифт.
- 03 Ложные утверждения: Появление несуществующих характеристик (розетка EU-стандарта на рынке США).
- 04 Юридические риски: Случайное появление элементов защищенных стилей или лиц без согласия.
- 05 Нулевая воспроизводимость: Случайный результат невозможно повторить для следующей партии товаров.

Смена модальности: Физика диффузии и латентного пространства

Почему изображение — это не BPE-токены, и как работает пошаговое удаление шума (Denoising)

Текстовые LLM:

Дискретные BPE-токены \$w_1 \to w_2 \to w_3\$, авторегрессия. |

Диффузия & DiT:

Непрерывные тензоры, латентный VAE и пошаговый Denoising.

1. VAE LATENT SPACE

Сжатие пространства

Миллионы RGB-пикселей сжимаются вариационным автоэнкодером (VAE) в 8–16 раз в компактное скрытое пространство z . Инференс происходит над тензорами.

2. FORWARD & REVERSE DENOISING

Очистка шума (Denoising)

Картинку учат пошагово удалять белый гауссовский шум за 20–50 шагов. Нейросеть (UNet или DiT) на каждом шаге вычисляет дельту шума.

3. CONDITIONING & SEED


Кросс-внимание и Seed

Текстовый энкодер (CLIP / T5) передает эмбединги через Cross-Attention. Seed (зерно шума) определяет стартовую матрицу: фиксация seed дает воспроизводимость.

Ментальная модель: Генерация как пайплайн

Модель — лишь один узел; управляемость рождается в архитектурной обвязке до и после вызова

C4 Architectural Infographic Diagram: Enterprise Image Generation and Editing API Pipeline



6 визуальных примитивов компьютерного зрения

Фундаментальные операции, комбинация которых закрывает любые прикладные сценарии

01 • TEXT-TO-IMAGE

Генерация с нуля

Создание пикселей исключительно по тексту. Для концепт-арта и раскадровок без жесткой фиксации объекта.

02 • IMAGE-TO-IMAGE

Трансформация референса

Подача входного фото и текста. Модель сохраняет композицию, превращая скетч в финальный фото-рендер.

03 • INPAINTING

Редактирование по маске

Замена пикселей внутри альфа-маски. Замена фона вокруг товара с сохранением 100% геометрии изделия.

04 • OUTPAINTING

Расширение холста

Дорисовывание окружения за пределами границ кадра. Превращение фото 1:1 в широкоформатный баннер 16:9.

05 • REFERENCE SIGNALS

Опорные сигналы

Фиксация идентичности товара (IP-Adapter), колористики (Style Reference) или каркаса позы (ControlNet).

06 • NEGATIVE CONSTRAINTS

Аппаратные запреты

Жесткий фильтр в конфигурации: исключение текста, водяных знаков, анатомических дефектов и лишних чашек.

Анатомия промпта: Инженерное ТЗ, а не поэма

Разделение промпта на изолированные технические параметры вместо эмоциональных прилагательных

SUBJECT • ОБЪЕКТ

Центральная сущность

Объект в фокусе: один предмет, точный материал, глазурь, цвет. Без размытых абстракций.

COMPOSITION • КАДР

Ракурс и верстка

Угол съемки (eye-level, macro), малая глубина резкости, свободное пространство для верстки.

ENVIRONMENT • СВЕТ

Сцена и атмосфера

Материал поверхности (травертин, дерево), мягкий направленный свет слева, реалистичные тени.

STYLE • ЭСТЕТИКА

Тип съемки

Commercial editorial product photography. Запрет на 3D-рендеры, рисунки и фильтры.

SACRED ATTRIBUTES • ТАБУ

Что нельзя менять

Главная строчка: форма ручки, пропорции изделия и логотип обязаны остаться нетронутыми.

ACCEPTANCE • ПРИЕМКА

Критерии отбора

Чек-лист: совпадение контура товара, отсутствие текста, естественность света, модерация.

Сравнение: Слабый промпт vs Инженерный бриф

Как одна и та же задача решается на уровне случайной лотереи и на уровне предсказуемого контракта

СЛАБЫЙ ПРОМПТ (РУЛЕТКА)

"Сделай красивую рекламу этой кружки в уютной студии."

Типичный результат:

- Модель берет 99% творческой свободы.
- Ручка изменила форму, глазурь поплыла.
- В кадре появились случайные круассаны и лишняя чашка.
- *Непригодно для каталога и автоматизации.*

ИНЖЕНЕРНЫЙ БРИФ (ПАЙПЛАЙН)


"Using input_product.png as protected reference, preserve mug shape, speckled glaze, handle ergonomics, and proportions 100%. Replace only background and surface with pale travertine studio in soft natural morning light. Eye-level, 16:9 crop, 2K. No text, no hands, no extra mugs. Return 3 variants. Acceptance: zero geometry drift against catalog master."

Инженерный результат:

- Изолированные параметры, готовые к параметризации через JSON в коде.
- 100% сохранение физической идентичности товара.
- Четкие критерии для ручного или автоматического QA-отбора.


Сигналы референсов и мультимодальный контроль

Разделение векторов: идентичность продукта (IP-Adapter), эстетика (Style) и геометрия (ControlNet)



Механика Inpainting и маскирования

Как бинарная альфа-маска и размытие краев (Edge Feathering) защищают пиксели изделия



Жизненный цикл API и сетевые пакеты

Передача бинарных данных по проводу: синхронный Base64 vs асинхронные очереди (Job Queue)

ПАТТЕРН 1 • СИНХРОННЫЙ BASE64

Прямой возврат байтов (2–5 сек)

Где используется: Google Gemini API, OpenAI Images API.

- Клиент отправляет JSON с Base64-строкой изображения.
- Сокет удерживается 3–6 секунд.
- Сервер возвращает Base64-байты прямо в теле ответа.
- **Плюс:** Мгновенная интеграция в интерактивные боты.
- **Минус:** Риск таймаута на тяжелых 4K-пакетах.

ПАТТЕРН 2 • АСИНХРОННАЯ ОЧЕРЕДЬ

Опрос статуса и вебхуки (30–60 сек)

Где используется: Adobe Firefly Services, Midjourney, Local ComfyUI.

- Запрос немедленно возвращает HTTP 202 Accepted с job_id: 'img_98765' .
- Клиент опрашивает статус (Polling) или ждет Webhook.
- Готовый файл скачивается по временной подписанной ссылке из S3.
- **Плюс:** Надежность и масштабируемость очереди.

Ландшафт провайдеров без маркетингового хайпа

Сравнение ключевых платформ 2026 года по архитектурным возможностям и корпоративной защите

OPENAI IMAGES & RESPONSES

GPT-Image-2 / DALL-E

Глубокое понимание сложных смысловых инструкций, генерация и редактирование. Интеграция генерации как инструмента (Tool Calling) внутри агентов.

GOOGLE CLOUD / GEMINI

Gemini 3.1 Flash Image & Imagen 3/4

Нативный мультимодальный контекст диалога: возможность редактировать картинку через естественные уточнения в общем чате. Быстрый Base64 возврат.

ADOBE FIREFLY SERVICES

Firefly Image5 & Photoshop API v2

Золотой стандарт энтерпрайза: обучение строго на лицензионном стоке, юридическая страховка от исков (indemnity), послойное редактирование PSD.

OPEN SOURCE & LOCAL HOSTING

FLUX.1 / SDXL on RunPod

Полный контроль весов, локальный запуск в закрытом контуре компании, безлимитная генерация и поддержка расширений ControlNet и LoRA.

Экватор: Перерыв 5 минут

Время перезагрузить внимание перед продакшен-айсбергом, Blast Radius и живым кодом

ИНТЕРАКТИВНЫЙ ТАЙМЕР ПЕРЕРЫВА

05:00


СТАРТ 5 МИН

СБРОС

Отдохните 5 минут и переведите дыхание. Никаких рабочих тем в чате — полный отдых мозга. Во второй части: продакшен-айсберг 10/90, Blast Radius, запуск кода и домашка.

Айсберг 10/90 в Computer Vision

10% видимый вызов API модели vs 90% невидимой инженерной инфраструктуры



Зоны риска Blast Radius в генерации изображений

Светофор допустимой автономии: где ИИ безопасен, а где действует абсолютное табу

● ЗЕЛЕНАЯ ЗОНА • АВТОНОМИЯ

Нулевой риск ошибки

Сценарии:

- Внутренние мудборды для дизайнеров.
- Синтетические аватарки и мок-данные для QA-тестирования.
- Эскизы для мозгового штурма.

Модель может работать полностью автономно. Ошибка не стоит ничего.

● ЖЕЛТАЯ ЗОНА • HUMAN-IN-THE-LOOP

Умеренный риск

Сценарии:

- Карточки товаров для e-commerce маркетплейса.
- Иллюстрации в корпоративный блог.
- Превью-обложки для роликов на YouTube.

Модель генерирует 3–4 кандидата, но публикацию утверждает человек.

● КРАСНАЯ ЗОНА • ТАБУ

Катастрофический риск

Сценарии:

- Юридические и судебные доказательства.
- Медицинская диагностика и снимки.
- Печать упаковки с составом лекарств и ГОСТ.
- Изменение официальных товарных знаков.

Прямой запрет на использование генеративного ИИ.

Лайв-демо: Путь от хаоса к контролю

Запуск скриптов demo_геро: генерация героя, сравнение эдитов и сборка промпта из JSON

РАУНД 1 • 01_GENERATE.PY

Первый вызов и Base64

- Запрос к `gemini-3.1-flash-image` .
- Параметры: `aspect_ratio: '16:9'` .
- Декодирование байтов `base64.b64decode()` .
- Запись файла на диск в `out/` .

РАУНД 2 • 02_EDIT.PY

Vague vs Controlled

- `--mode vague` : абстрактный промпт ломает форму ручки и текстуру.
- `--mode controlled` : жесткие табу сохраняют 100% геометрии кружки и меняют только фон на травертин.

РАУНД 3 • 03_BUILD_PROMPT.PY

Сборка из JSON-схемы

- Чтение `visual_spec.json` .
- Программная конкатенация параметров: Subject, Environment, Constraints, Ratio.
- Исключение человеческих ошибок в строке промпта.

Дерево решений: GenAI vs Классический CV vs Детерминированный софт

Принцип «Сначала проблема, а не ИИ»: когда диффузионные модели не нужны и опасны

SOFTWARE 1.0 • DETERMINISTIC

Figma / CSS / SVG / Pillow

Когда выбирать:

- Векторные логотипы и товарные знаки.
- Точная типографика, даты, ценники.
- Верстка рекламных баннеров по сетке.

\$0 затрат, 0ms задержки, 100% точность букв.

SOFTWARE 2.0 • CLASSICAL CV

OpenCV / YOLO / Canny

Когда выбирать:

- Детекция брака деталей на конвейере.
- Распознавание штрихкодов и номеров.
- Кадрирование лиц и выравнивание горизонта.

2–5ms локальный инференс на обычном CPU, \$0 за токены.

SOFTWARE 3.0 • GENERATIVE AI

Diffusion & Multimodal APIs

Когда выбирать:

- Замена фона вокруг товара в e-commerce.
- Создание фотореалистичных текстур и сцен.
- Вариативность концепт-арта и баннеров.

Сложное семантическое рассуждение о пикселях и свете.

Домашнее задание: Reproducible Image Workflow Pack

Создание воспроизводимого пакета генерации с формализацией ТЗ и аудитом качества

СЦЕНАРИЙ НА ВЫБОР

3 прикладных трека

1. **E-commerce:** Замена фона товарной карточки с сохранением формы изделия (керамика, часы, электроника).

2. **YouTube / Медиа:** Превью-обложка для ролика с пустой зоной под типографику (паттерн Creator Tools).

3. **Tech Event:** Баннер технологического митапа с негативным пространством под даты и спикеров.

ЧЕК-ЛИСТ АРТЕФАКТОВ • GENAI-HOMEWORKS/L04/

- ✓ `brief.md` — заполненный Visual Generation Canvas (цель, табу, критерии).
- ✓ `references/` — исходные фото-референсы (без приватных данных).
- ✓ `prompt_v1.txt` и `prompt_v2.txt` — итерационный лог промптов.
- ✓ `candidates/` — минимум 2 сгенерированных варианта.
- ✓ `qa.md` — оценка кандидатов по рубрикатору (геометрия, артефакты, свет).
- ✓ `selected/` — финальный принятый ассет + метаданные генерации.

→ Ветка `lesson-04` , PR в `main` , коллаборатор: `ihar_rubanovich@epam.com` .

Резюме, открытый микрофон и анонс Урока 05

3 главных вывода занятия и анонс перехода к генерации и трансформации видео

ГЛАВНЫЕ ВЫВОДЫ УРОКА

- 1. Картинка в продакшене — это ТЗ, а не лотерея. Фиксация геометрии и строгие запреты важнее декоративных прилагательных.
- 2. Маски и референсы дают аппаратный контроль. Разделяйте сигналы стиля, идентичности объекта и каркаса сцены.
- 3. Айсберг 90% решает всё. Успех системы определяется объектным хранилищем, декодированием Base64 и Human-in-the-Loop.

NEXT SESSION • УРОК 05

Генерация и трансформация видео

Продолжение Модуля 2: Мультимодальность.

Переход от статичных пикселей к временному измерению: **Runway Gen-3, Kling, OpenAI Sora, Pika**. Управление движением камеры (Camera Motion Control), интерполяция кадров и сквозные видео-пайплайны.

 Микрофоны открыты — задавайте вопросы голосом и в чате!