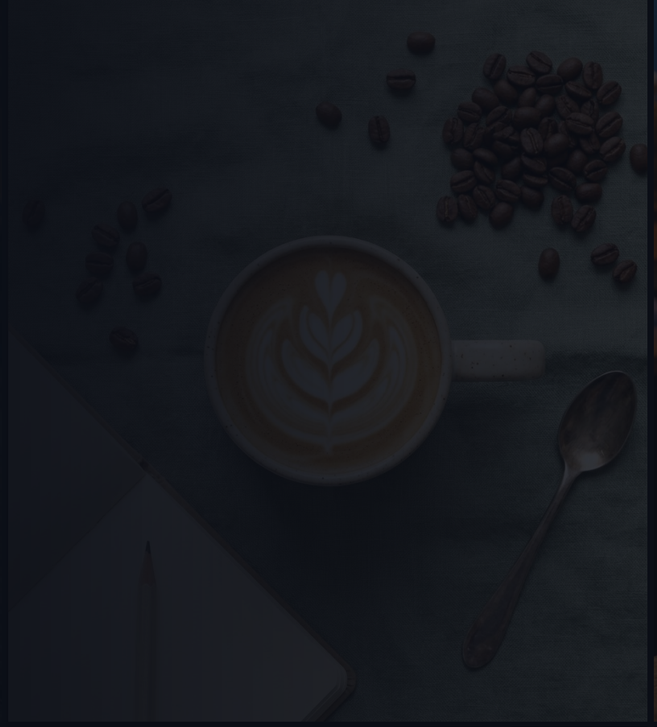
GENAI BASICS • УРОК 04 • МОДУЛЬ 2: МУЛЬТИМОДАЛЬНОСТЬ

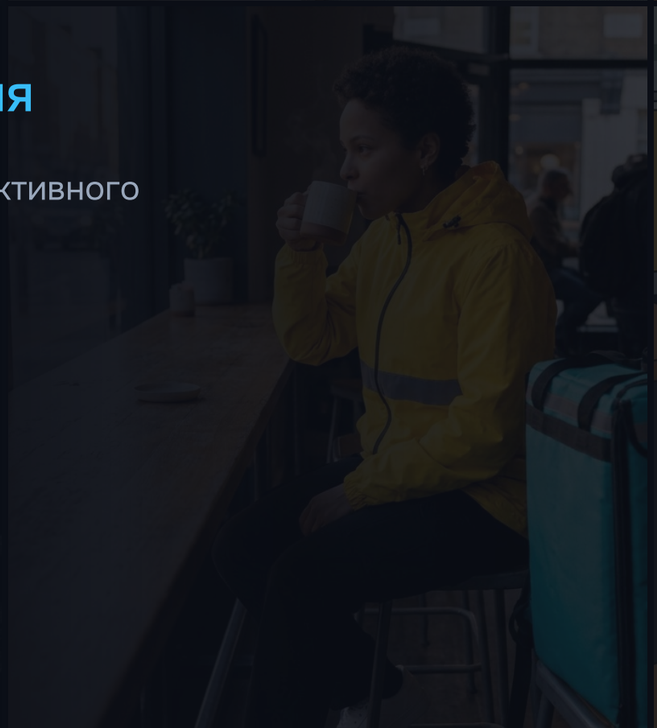
Генерация изображений

Сервисы, промпт-техники и паттерны контроля

ChatGPT, Nano Banana, Leonardo.ai, Midjourney, Kling и Sintx. От интерактивного хука и архитектуры провайдеров — к фотосессии товара, inpainting и персонажу, который узнаваем в каждом кадре.







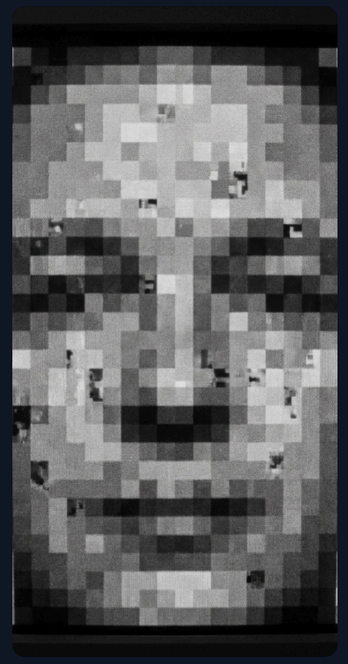


ИНТЕРАКТИВНЫЙ ХУК • РАЗМИНКА

Угадайте: кто реальный человек, а кто — ИИ?

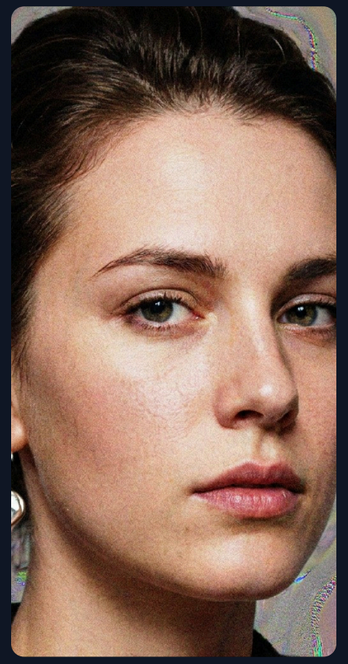
Шесть портретов. Напишите в чат буквы тех, кого вы считаете настоящей фотографией, и тех, кто сгенерирован нейросетью.

[A]



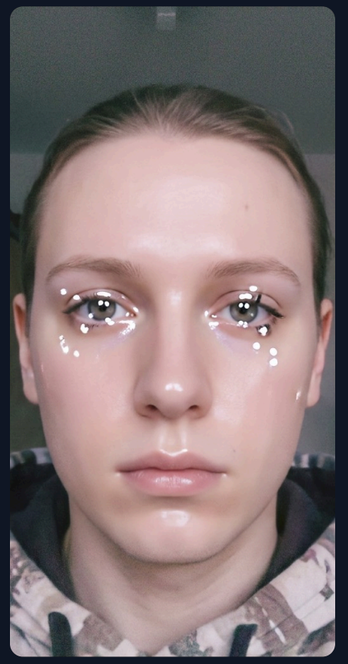
Портрет A

[B]



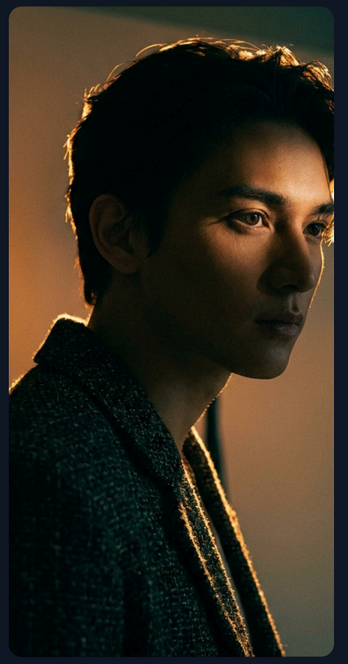
Портрет B

[C]



Портрет C

[D]



Портрет D

[E]



Портрет E

[F]



Портрет F

Вопрос в чат: напишите ваши догадки. Например: «A и B — нейросеть, E и F — настоящие люди» или «Только F реальный». На что вы обращаете внимание?

РАСКРЫТИЕ ИНТРИГИ • 2014-2026

Все 6 — это генерация ИИ. 10 лет эволюции

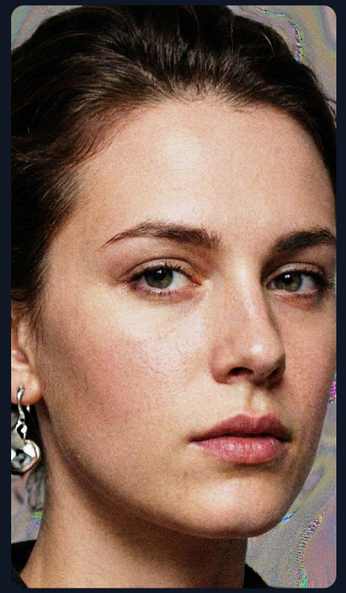
Ни одной реальной фотографии. Хроника того, как компьютерное зрение преодолело «зловещую долину» за одно десятилетие.

2014 GAN



Goodfellow GAN
64×64 px, серые пятна шума. Рождение технологии.

2018 StyleGAN



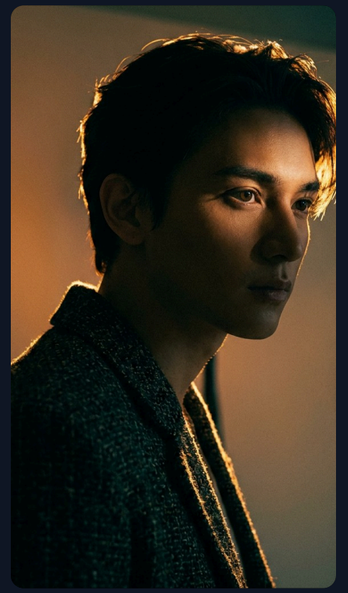
NVIDIA StyleGAN
Иллюзия реализма, но плавятся серьги, уши и фон.

2022 SD 1.5



Stable Diffusion
Диффузия в опенсорсе. Гламурный глянец, неживые глаза.

2023 MJ v5



Midjourney v5
Победа эстетики. Киношный контраст, теплый контурный свет.

2024 FLUX.1



FLUX.1 Dev/Pro
Микротекстура кожи, поры, морщины, естественные зубы.

2026 Pro VLM



Nano Banana Pro
Естественная оптика смартфона, боке, шум сенсора. Неотличимо.

> **Вывод для инженера:** Модели научились рисовать фотореализм из коробки. Проблема 2026 года — не в «красоте», а в **управляемости**: как заставить модель нарисовать ровно то, что требует ТЗ, и повторить героя в 10 сценах.

МАРШРУТ КУРСА

Модуль 1 пройден. Сегодня — пиксели

01 **Основы и API**
L01–L03

02 **Мультимодальность**
L04 картинки
L05 видео • L06 звук

03 **Среда инженера**
L07–L09

04 **Локальный AI**
L10

05 **Агенты и MCP**
L11–L13

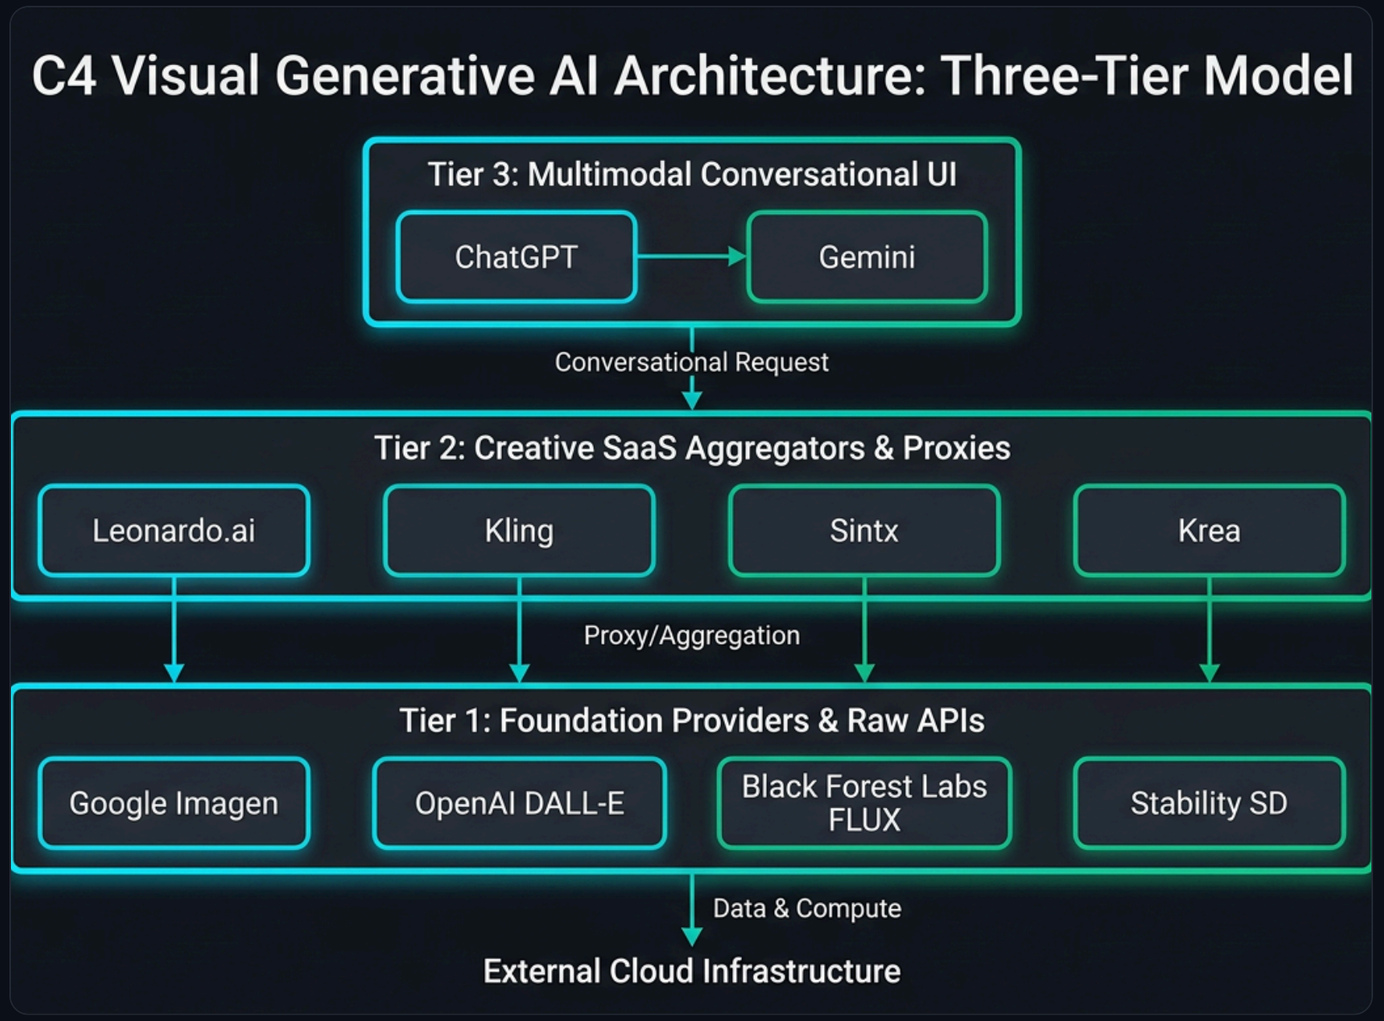
06 **Продакшен**
L14–L16

> **Что переносится из Модуля 1:** законы промптинга из L02 работают и для диффузии. Конкретика вместо абстракций, разделение на слоты и контекст. Но вместо примеров текста мы теперь подаем **референс-изображения**.

АРХИТЕКТУРА • ИНЖЕНЕРНЫЙ ОБЗОР

Три слоя экосистемы Visual AI

Как устроен рынок генерации картинок: от кремния и базовых весов — к креативным студиям и диалоговым чатам.



Tier 3: Мультимодальный чат

ChatGPT, Gemini, Grok Imagine. Единая модель рассуждает текстом, генерирует пиксели и помнит контекст диалога. Идеально для правок и надписей.

Tier 2: Креативные SaaS-агрегаторы

Leonardo.ai, Kling, Sintx, Krea. Прокси-сервисы с холстом, слоями, inpainting-кистью, апскейлерами и мульти-модельным роутингом.

Tier 1: Базовые модели и API

Google Imagen, OpenAI DALL-E, FLUX, Stability SD. Обучают веса, держат GPU-кластеры и отдают сырой REST/Python API для автоматизации.

LAYER 1 • БАЗОВЫЕ ПОСТАВЩИКИ

Кто обучает базовые модели и дает API

С ними вы уже работали в L03 через SDK. Те же компании предоставляют эндпоинты генерации изображений.

GOOGLE CLOUD

Imagen 3 / Nano Banana Pro

Модели: `gemini-3-pro-image`, `gemini-3.1-flash-image`.
Сила: мультимодальный контекст, привязка к референсам, SDK для Python.

OPENAI

DALL-E 3 / GPT Image 2.5

Модели: `dall-e-3`, `gpt-4o-image`.
Сила: сложный текст на картинке, строгое следование ТЗ, интеграция с Assistants API.

BLACK FOREST LABS

FLUX.1 (Pro / Dev / Schnell)

Открытый и закрытый API (Replicate, fal.ai, Together).
Сила: эталон анатомии, микротекстуры кожи, открытые веса для хостинга.

STABILITY AI

Stable Diffusion 3.5 / SDXL

Основа опенсорс-экосистемы. Доступ через API и локальный запуск (L10).
Сила: тысячи пользовательских LoRA-моделей под любой стиль.

MIDJOURNEY

Midjourney V6.1 / V8.2

Закрытая экосистема (Web и Discord). Официального публичного API нет.
Сила: непревзойденная коммерческая и кинематографичная эстетика.

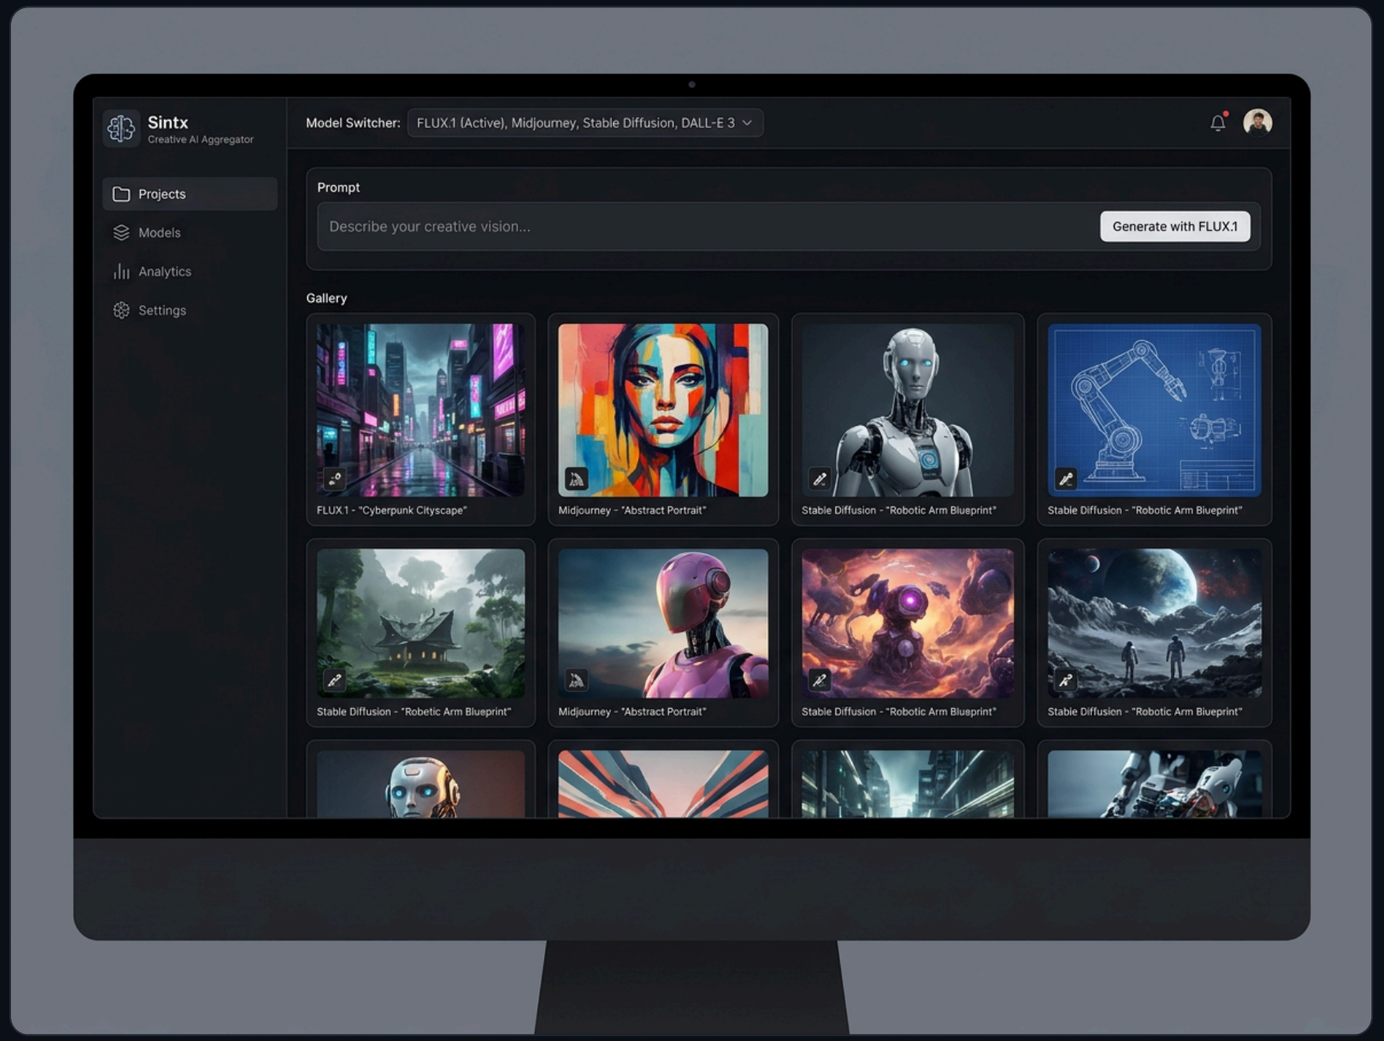
КАК ВЫЗЫВАТЬ В КОДЕ

Прямой вызов API

`POST /v1/images/generations` или `client.models.generate_content`.
Цена: $0.02 — $0.08 за кадр. Скорость: 3–15 секунд.

Зачем нужен SaaS-прокси вместо «голого» API?

Leonardo.ai, Sintx, Kling, Krea: почему креаторы и продакт-команды выбирают интерфейсы-агрегаторы.

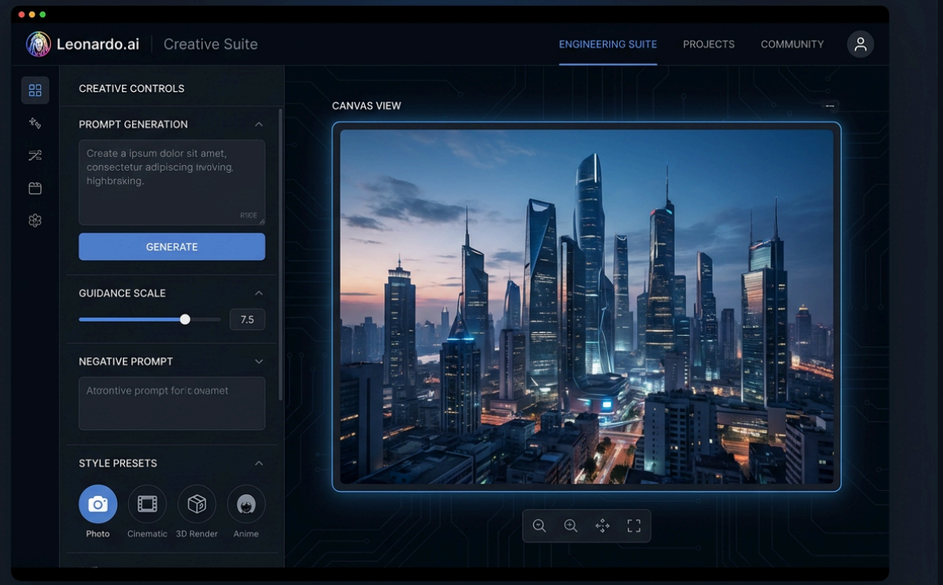


- **Единая подписка (Proxy/Router):** переключение между FLUX, Midjourney и SDXL в одном поле ввода без 5 разных счетов и API-ключей.
- **Интерактивный холст (Canvas):** слои, перемещение вырезанных объектов, ручная кисть inpainting и outpainting (дорисовка границ кадра).
- **Пресеты стилей и LoRA:** возможность подключить корпоративный стиль или пресет фотосессии в один клик.
- **Инструменты управления:** ползунки Guidance Scale, фиксация зерна (Seed), ControlNet по позе или контурам (Canny).

> **Определение:** Креативный SaaS — это прокси-оболочка над сырыми API, которая превращает генерацию в визуальный рабочий процесс.

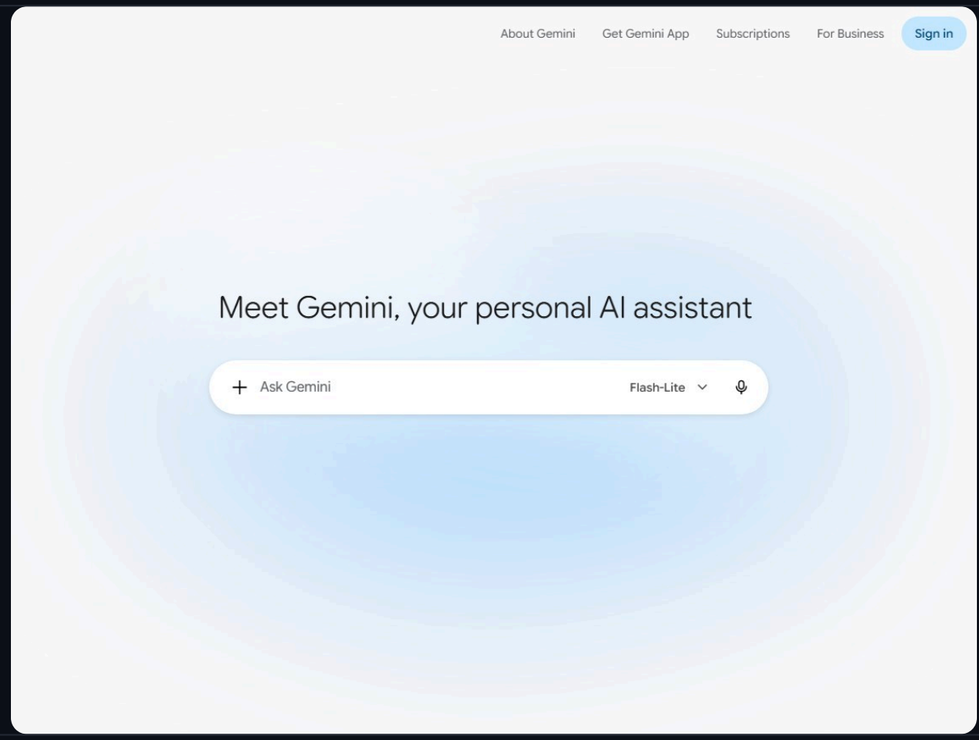
Холст и ползунки vs Диалоговая семантика

Две принципиально разные парадигмы генерации: студийный графический комбайн против мультимодальной LLM.



Leonardo.ai (Креативный SaaS)

Парадигма: графический редактор. Вы управляете параметрами диффузии: Guidance Scale (сила следования), Negative Prompt (список запретов), фиксация Seed, выбор LoRA. Чтобы убрать объект — берете кисть и маскируете пиксели.



ChatGPT & Nano Banana (Мультимодальный чат)

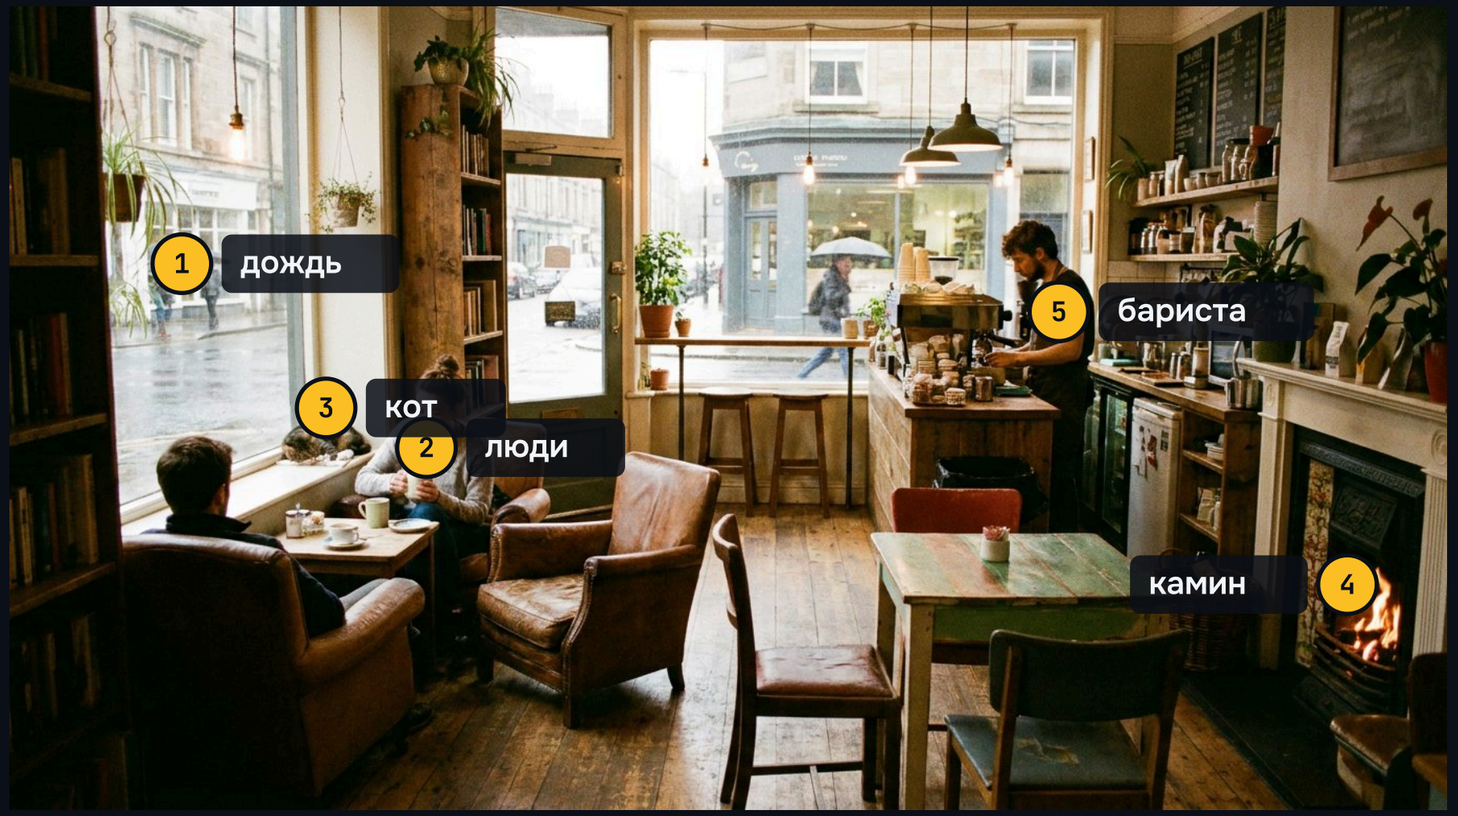
Парадигма: разговор с режиссером. Модель обладает зрением и пониманием физики мира. Правка формулируется текстом: *«Замени только кружку на айс-латте, сохрани свет и геометрию стола»*. Модель сама сегментирует объект.

Матрица выбора: SaaS vs Чат vs Raw API

КРИТЕРИЙ	КРЕАТИВНЫЙ SAAS (LEONARDO, SINTX)	МУЛЬТИМОДАЛЬНЫЙ ЧАТ (CHATGPT, GEMINI)	RAW API (PYTHON SDK / GOOGLE / REPLICATE)
Порог входа	Средний (интерфейс, ползунки, слои)	Минимальный (естественный язык)	Высокий (код, авторизация, пайплайны)
Точечные правки	Ручная кисть / маска / холст	Семантические (описание текстом)	Маска через Base64 / Inpainting API
Сложный текст и кириллица	Средне (зависит от выбранной модели)	Отлично (ChatGPT Images, Nano Banana)	Отлично (при вызове DALL-E / Imagen 3)
Консистентность персонажа	Character Reference, фиксация Seed	Мульти-референсы (до 14 картинок в Gemini)	Передача reference image в `contents`
Пакетная генерация (500+ шт.)	Неудобно (клики в UI, лимиты кредитов)	Невозможно (ручной чат)	Идеально (скрипт, $0.03/кадр, БД)

> **Инженерное правило:** Концепты и быстрые тексты ➔ **Чат**. Сложный коммерческий арт с ручной маской ➔ **SaaS**. Массовая генерация баннеров по каталогу товаров ➔ **API-скрипт**.

Шесть слов — и все решения принимает модель



ВЕСЬ СВОБОДНЫЙ ПРОМПТ

```
a cozy coffee shop in the morning
```

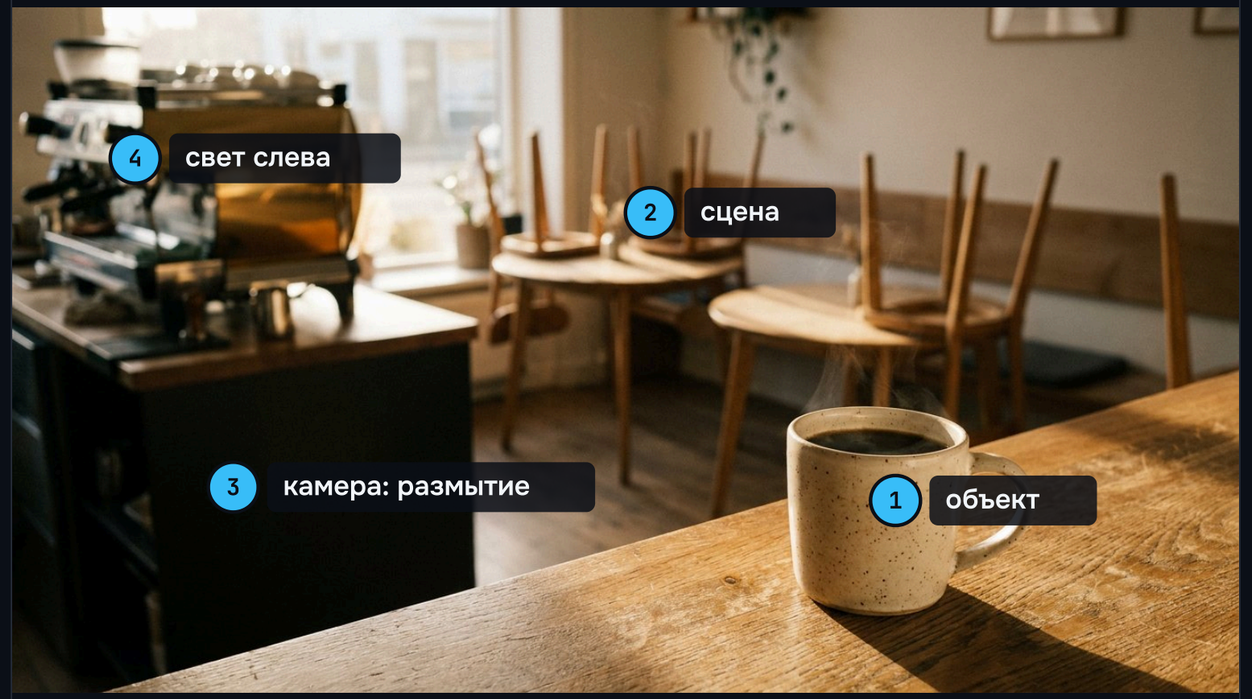
Утро? За окном дождь. Людей, кота и камин никто не просил — модель заполнила пустоты по среднему из обучающего датасета.

Шесть слотов — что за что отвечает и где улучшать

РАБОТАЮЩИЙ ПРОМПТ СО СЛОТАМИ (COPY & RUN) — 100% КОНТРОЛЬ СЦЕНЫ

```
Subject: a speckled cream ceramic mug of black coffee with steam, on
worn oak counter in right third.
Setting: empty Scandinavian coffee shop at 7 a.m., chairs up on
tables, brass espresso machine on left.
Camera: eye-level, 35mm lens, f/2.0, shallow depth of field.
Lighting: low warm morning sunlight from left window, long soft
shadows.
Style: realistic editorial photography. Constraints: no people, no
text, no logos.
```

ИНСПЕКТОР ГЕНЕРАЦИИ:



АНАТОМИЯ СЛОТОВ: ЧТО КОНТРОЛИРУЕТ КАЖДЫЙ ЭЛЕМЕНТ В МОДЕЛИ

1. Subject (Объект): Главный фокус, фактура и правило третей (right third).

2. Setting (Сцена): Время (7 утра) и контекст — блокирует случайных людей и бариста.

3. Camera (Оптика): 35mm (угол без дисторсии), f/2.0 (физическое боке вместо AI-мыла).

4. Lighting (Свет): Низкие лучи слева создают 3D-объем, тени и микрорельеф дерева.

5. Style (Стиль): Editorial photo исключает пластиковый глянец и 3D-рендер.

6. Constraints (Запреты): Строгие рамки отсекают галлюцинации букв, логотипов и толпы.

💡 **3 КЛЮЧЕВЫЕ ОБЛАСТИ УЛУЧШЕНИЯ СЛАБОГО ПРОМПТА** — BEST PRACTICE

1. Физические маркеры вместо абстракций: Не пишите «уютный/cozy» (модель рисует камин и кота). Задайте точные детали: *«7 a.m., chairs up on tables»*.

2. Оптика вместо мусорных тегов: Удалите шум «4k, masterpiece, trending» (игнорируется моделью). Задайте оптику: *«35mm lens, f/2.0, shallow depth of field»*.

3. Отрицательные Guardrails: Не надейтесь на удачу. Явный блок *«Constraints: no people, no text, no logos»* отсекает случайные лица и артефакты букв.

Важные детали и надписи — отдельным блоком




```
Must-have:
• меловая табличка с текстом ровно "FLAT WHITE 3.50" и "OPEN 7:00"
• один свежий круассан за кружкой
• лаванда в маленькой стеклянной вазе слева
```

- **Текст:** берем в кавычки и пишем слово `exactly`.
- **Количество:** указываем числом («one croissant», не «croissants»).
- **Позиция:** явно связываем («behind the mug», «to the left»).
- **Запрет лишнего:** фраза `no other text, no typos`.

Текст, круассан и лаванда — ровно как указано в ТЗ

Одна героиня — шесть слов камеры и света



`low angle` снизу — «героично»



`top-down` сверху — схема, флэтлей



`24mm wide` герой + окружение



`85mm f/1.8` портрет, размытый фон



`golden hour` теплый контровой свет



`softbox studio` ровный студийный свет

ЭКВАТОР ЗАНЯТИЯ

Перерыв 5 минут

05:00

Во второй части: хирургические правки (Inpainting), консистентный персонаж-курьер и фотосессия товара.

Правим по кругу, а не перегенерируем



ШАБЛОН ИНЖЕНЕРНОЙ ПРАВКИ

```
Отредактируй фото. Замени только объект X на Y.
Сохрани: ракурс, свет, фон, фактуру и тени.
Не меняй: геометрию окружения.
```

- **Одна правка за шаг** (как один атомарный коммит в git).
- **Явно называйте то, что сохранить** — модель защищает эти зоны.
- **После 6–8 правок** — дрейф неизбежен. Открываем новый чат с лучшим кадром.

Одна сцена — три направленные правки



Оригинал A2: утренняя кофейня, кружка



Объект (B1): кружка ➔ айс-латте



Свет (B2): дождливый вечер за окном



Стиль (E2): плоская векторная графика

ФОРМУЛА **Кадр A2 + атомарная дельта-инструкция**

«Замени только X на Y. Сохрани: ракурс, свет, фон, геометрию».

РАБОТАЮЩИЙ ПРОМПТ B1: ЗАМЕНА ОБЪЕКТА (INPAINTING)

```
Edit this photo. Replace only the ceramic mug with a tall glass of iced latte with visible coffee and milk layers and ice cubes. Keep everything else exactly the same: camera angle, counter, espresso machine, background, light direction and shadows.
```

РАБОТАЮЩИЙ ПРОМПТ B2: СМЕНА СВЕТА И ПОГОДЫ (RELIGHTING)

```
Edit this photo. Change only the time of day to a rainy evening: dark dusk outside window, raindrops on glass, warm interior pendant lamps switched on. Keep exact same composition, objects, mug and camera angle.
```

В ChatGPT / Gemini: диалоговая дельта к кадру.
В Leonardo / Kling: маска кистью (Mask) по кружке ➔ промпт замены.

Мастер-лист курьера: формула генерации ракурсов

Наивный запрос в каждой сцене рисует нового человека. Инженерный подход: сначала генерируем 4 ракурса на сером фоне и фиксируем физические якоря.



Character Reference Sheet: 4 ракурса в нейтральной позе со студийным светом

5 неизменных якорей: short curly hair • small silver hoop earring • bright yellow jacket with grey stripe • turquoise backpack • white sneakers

НАИВНО **«курьер едет на велосипеде под дождем»**

Модель генерирует случайного человека. В следующей сцене лицо, возраст и куртка меняются. Консистентность = 0%.

ИНЖЕНЕРНО **Генерация Character Sheet (4 ракурса на сером фоне)**

Студийный свет, нейтральный фон, фигура в полный рост (анфас, 3/4, профиль, со спины). Мастер-референс для всех сцен.

РАБОТАЮЩИЙ ПРОМПТ ДЛЯ ГЕНЕРАЦИИ МАСТЕР-ЛИСТА (C1)

```
Character reference sheet on a plain light grey background: the same young woman
food delivery courier shown four times in a row - front view, three-quarter view,
side profile, back view - full body, standing neutral pose.
Fixed appearance: about 28 years old, short curly dark-brown hair, light-brown
skin, small silver hoop earring in left ear, bright yellow waterproof jacket with
reflective grey stripe across chest, black cargo trousers, white sneakers, square
turquoise thermal backpack. Studio photography, clean even lighting. No brand
names, no logos, no text.
```

Куда вставлять: Google Gemini, Midjourney, Leonardo, Kling. Результат сохраняем как эталон `C1_sheet.png`.

Любой человек как референс: от 2–3 фото к мастер-листу

Как превратить себя или актера в управляемого героя: отправляем реальные фото в модель, накладываем строгий запрет на «улучшайзинг» и фиксируем 4 ракурса.

ВХОД 1 • РЕФЕРЕНСЫ — 2–3 реальных фото лица



Анфас (студия)



Эмоция / свет



Дневной свет

ВХОД 2 • ПРОМПТ В ЧАТ (GEMINI / CHATGPT / LEONARDO) — 100% IDENTITY LOCK

```
Create a photorealistic character reference sheet based on attached
real photographs of Ihar Rubanovich. The character is the exact same
adult man, not a generic model.
Preserve authentic facial identity: exact face shape, forehead, eyes,
eyebrows, nose, lips, jawline, hairline, skin tone, proportions. Do
not beautify, rejuvenate, stylize, or replace his face.
Four horizontal angles: front view, three-quarter view, strict side
profile, back view. Full body, standing neutral pose.
Outfit: bright yellow waterproof courier jacket with grey stripe,
black cargo trousers, white sneakers, turquoise thermal backpack.
Studio lighting, light grey background. No text, no logos.
```

Что отправляем: В чат Gemini / ChatGPT кидаем эти фото + промпт. В коде — передаем файлы в `contents`.



Результат на выходе: Идентичность лица сохранена на 100% во всех 4 ракурсах. Костюм курьера надет без искажений анатомии.

АНТИ-ПАТТЕРН

Без фразы `do not beautify/stylize` модель сгладит поры, изменит нос и нарисует слащавое лицо из стоковых картинок.

МОСТ К ПРОДАКШЕНУ

Полученный лист отправляется как **Character Reference** в любые сюжетные сцены (дождь, офис, кафе) и в Kling для видео.

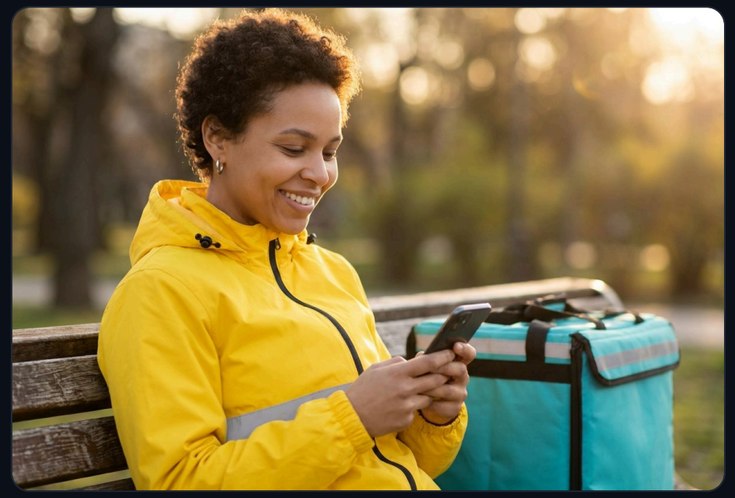
Курьер в сценах и первый кадр для видео (Kling / Veo)



Сцена 1 (16:9): на велосипеде под дождем → **база для видео**



Сцена 2: передача заказа у двери (35mm)



Сцена 3: перерыв на лавочке в парке (85mm)

РАБОТАЮЩИЙ ПРОМПТ ПЕРЕНОСА В СЦЕНУ (SCENE TRANSFER)

```
Use attached character sheet (C1) as identity reference:
The same courier (same face, curly hair, silver hoop earring, yellow jacket with
grey stripe, turquoise backpack) is riding a city bicycle through a rainy
evening street with wet cobblestones reflecting shop lights. Medium shot, 50mm
lens, motion blur in background. Realistic photography. No logos, no text.
```

Форматы: 16:9 для горизонтального видео/YouTube, 9:16 для Reels/Shorts (задаем селектором интерфейса).

МОСТ К ВИДЕО **Конвейер в Kling 3.0 / Google Veo 3.1**

1. **Экспорт кадра:** берем `C2_rain.png` (16:9) как нулевой кадр (t_0).
2. **Image-to-Video:** загружаем в Kling или Veo в слот **First Frame**.
3. **Промпт движения:** `"courier starts pedaling forward, wheels splash rain puddles, camera tracks along"`.
4. **Результат:** 100% стабильность лица и одежды! Персонаж не плывет в движении.

В тулах: Gemini (мультимодальный аттач) • Leonardo (Character Ref + Seed) • Kling/Veo (I2V First Frame).

Один пэкшот — четыре коммерческих кадра



Мастер-пэкшот: товар на белом фоне

1. ПРОМПТ МАСТЕР-ПЭКШОТА (D0)

```
Studio e-commerce packshot of a single handmade ceramic
mug: cylindrical body, speckled cream glaze with small
brown dots, unglazed terracotta-brown band at base, round
C-shaped handle on right. Centered, 3/4 view, pure white
background, soft even light. No text, no logo.
```



Лайфстайл (D1): кухня, утро



Флэтлей (D2): вид сверху



В руках (D3): масштаб товара



Баннер (D4): промо-постер

2. ПРОМПТ КАТАЛОЖНОЙ СЦЕНЫ (С РЕФЕРЕНСОМ D0)

```
Product photo session. Place exactly this mug (same shape, speckled cream glaze, terracotta base
band, handle on right) on light travertine kitchen counter next to morning window. Soft light,
50mm f/2.8. Do not change mug shape, clay glaze, or proportions.
```

Инженерный контроль: Референс `D0` + запрет дрейфа сохраняют форму и глазурь на 100% во всех сценах.

Назовите роль каждой картинки



Картинка 1 — персонаж (курьер)



Картинка 2 — товар (кружка)

→



Итог: курьер пьет из той самой кружки в утренней кофейне

ПРАВИЛО РОЛЕЙ **Не писать «объедини их» (будет каша). Назначить роли:**
Image 1 = identity reference (герой), Image 2 = product reference (товар).

РАБОТАЮЩИЙ ПРОМПТ КОМПОЗИЦИИ (GEMINI NANO BANANA / CHATGPT)

```
Image 1 is the courier character, Image 2 is the exact ceramic mug.
The courier from Image 1, in her yellow jacket with grey stripe, sits at a coffee shop window
counter on her break and drinks from exactly the mug from Image 2 (same speckled cream glaze and
terracotta base). Turquoise backpack on floor next to stool. Morning light, 35mm lens, realistic
photography. No logos, no text.
```

ЧАСТЬ 5 • ТО ЖЕ В КОДЕ

Серия картинок скриптом — тот же SDK, что в L03

```
from google import genai
from google.genai import types
from PIL import Image

client = genai.Client()
ref_img = Image.open("packshot.png")

resp = client.models.generate_content(
    model="gemini-3.1-flash-image",
    contents=[ref_img, PROMPT_SPEC],
    config=types.GenerateContentConfig(
        response_modalities=["IMAGE"],
        image_config=types.ImageConfig(aspect_ratio="16:9")
    )
)
resp.parts[0].as_image().save("output_scene.png")
```

50 карточек за 3 минуты

Вместо целого рабочего дня ручной возни в браузере. Вы берете CSV-файл с товарами и прогоняете цикл генерации.

> **10/90 в коде:** Вызов модели — 5 строк. Остальные 90% кода — чтение каталога, валидация промпта и автопроверка на артефакты.

Где генерация подводит и где ее нельзя применять

- **Анатомия и мелкий текст:** пальцы в толпе и длинные абзацы все еще дают сбои.
- **Дрейф деталей:** при 5+ правках подряд лицо и логотипы начинают незаметно плыть.
- **Юридический статус:** в США и ЕС чистый промпт без авторского участия не защищен копирайтом.
- **Водяные знаки:** SynthID (невидимый спектральный маркер Google) и C2PA (криптографический штамп происхождения).



ЗЕЛЕНАЯ • АВТОНОМНО

Мудборды, концепт-арт, иллюстрации к внутренним презентациям, раскадровки.

ЖЕЛТАЯ • HUMAN-IN-THE-LOOP

Карточки товаров, рекламные баннеры, обложки YouTube. Обязательна ручная приемка.

КРАСНАЯ • НЕ ГЕНЕРИРУЕМ

Юридические документы, медицинские инструкции, чужие логотипы, лица людей без согласия.

ПРАКТИКА • ДОМАШНЕЕ ЗАДАНИЕ №4

Фотосессия товара или персонаж-курьер

Трек А: фотосессия предмета

Свой предмет на белом фоне ➔ 4 коммерческих кадра (лайфстайл, флэтлей, в руках, баннер).

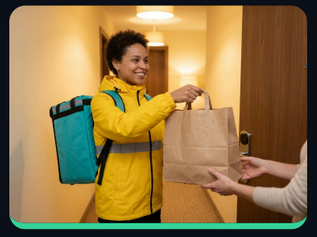





Трек Б: курьер доставки (Glovo)

Лист персонажа ➔ 3 сцены с якорными приметами ➔ 1 направленная правка (Inpainting).






СТРУКТУРА СДАЧИ В GITHUB

```
genai-homeworks/
└── L04/
    ├── images/ (01_free.png, 02_structured.png...)
    ├── prompts.md (промпты, сервис, дата)
    └── qa.md (что сохранилось, что уплыло)
```

Обязательно: сравнить один промпт в двух сервисах (например, Leonardo vs ChatGPT) и описать разницу в `qa.md`. Инвайт: `ihar_rubanovich@epam.com`.

Четыре правила инженера визуального AI

1. Инструмент — под задачу

Чат для идей и надписей, SaaS для холста и масок, API для конвейера в коде.

2. Структура вместо фразы

6 слотов (объект, сцена, камера, свет, стиль, запреты) + блок must-have.

3. Хирургическая правка вместо реролла

Атомарная команда «измени только X, сохрани Y» побеждает генерацию заново.

4. Консистентность через якоря

Мастер-референс + 4–6 ярких словесных примет удерживают героя в любой сцене.



Урок 05: Генерация видео

Кадры с курьером станут первыми кадрами для видеомоделей (Kling, Veo, Runway). Наш курьер поедет на велосипеде!