GENAI BASICS • УРОК 05 • МОДУЛЬ 2: МУЛЬТИМОДАЛЬНОСТЬ

Генерация видео

От ключевого кадра к ролику из нескольких шотов

Как видеомодель генерирует движение, почему один длинный промпт ломается и как собрать историю из коротких шотов. Veo, Gemini Omni, Kling, Seedance, Runway, Leonardo. Данные на октябрь 2026.



ПРИМЕР

Ролик 23 секунды из трёх шотов по 8 секунд



3 шота

каждый сделан из **готового ключевого кадра** (image-to-video)

8+8+8 → 23 с

склейка с двумя переходами по 0,5 с

≈ $10

3 × 8 с × $0.40, прайс **Veo 3.1**, 720p, без учёта дублей

> Дальше: где генерировать, как работает модель, почему один промпт на всю историю ломается, и пайплайн из 6 шагов.

ГДЕ ГЕНЕРИРОВАТЬ

Три уровня доступа к видеомоделям: чат, веб-студия, API

Чат-приложения

видео прямо в чате

Gemini app · Google Flow · Grok Imagine

УПРАВЛЕНИЕ	только текст промпта; в Flow ещё первый/последний кадр и продление
ОПЛАТА	подписка
ДЛЯ ЧЕГО	идеи, быстрые черновики
НАЧАТЬ С	**Gemini app**

Веб-студии

интерфейс для видео

Kling · Leonardo · Dreamina / CapCut (Seedance) · Runway · Luma · Hailuo

УПРАВЛЕНИЕ	настройки камеры, первый/последний кадр, референсы, multi-shot
ОПЛАТА	кредиты; бесплатный лимит небольшой
ДЛЯ ЧЕГО	отдельные ролики, ДЗ
НАЧАТЬ С	**Kling**

API

код и автоматизация

Gemini API / Vertex AI · Kling API · Runway API · xAI API

УПРАВЛЕНИЕ	всё как параметры запроса; пакетная генерация
ОПЛАТА	за секунду видео
ДЛЯ ЧЕГО	пайплайны, продукты
НАЧАТЬ С	**Gemini API**

> Одна модель часто доступна на всех трёх уровнях: Veo есть во Flow, в Leonardo, в Runway и в Gemini API (в Gemini app сейчас работает Gemini Omni). **ChatGPT видео не генерирует**: Sora закрыта.

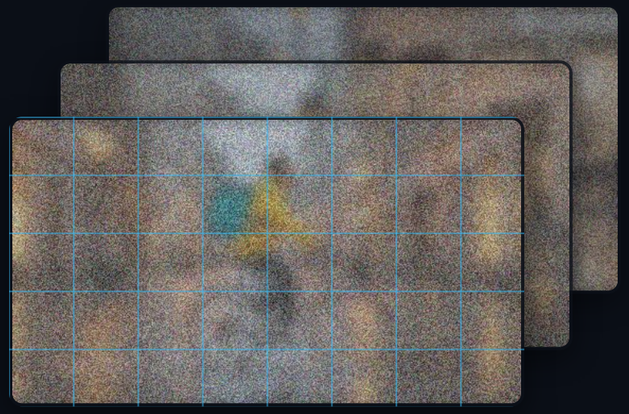
ПРИНЦИП РАБОТЫ

Как диффузионная модель генерирует кадры видео



1. Шум

Старт: случайный шум сразу **на все кадры** клипа



2. Очистка шагами

Видео режется на кусочки «место в кадре × момент времени». Десятки шагов убирают шум; текст и первый кадр подсказывают на каждом шаге



3. Кадры

24 кадра в секунду, согласованные между собой, поэтому движение плавное

Физического движка внутри нет. Модель видела миллионы видео и знает, как движение *обычно выглядит*. Поэтому ошибается там, где нужны точные правила: **руки и предметы в контакте, текст, длинные сцены**.

Схема: кадры из нашего шота 2, шум добавлен для иллюстрации.

АНТИПАТТЕРН

Text-to-video, вся история в одном промпте: 4 типа ошибок

TEXT-TO-VIDEO Veo 3.1 • 8 с • только текст



ПРОМПТ (СОКРАЩЁН)

```
Our friendly Glovo delivery courier enters a cozy
Scandinavian cafe, … picks up a brown paper food delivery
bag, puts it securely inside her turquoise backpack, then
cuts to her riding a city bicycle through the rainy avenue
at dusk … and then camera zooms in to a smartphone map …
```

> Причина: на 8 секунд модели дали **3 сцены и 5 действий**.



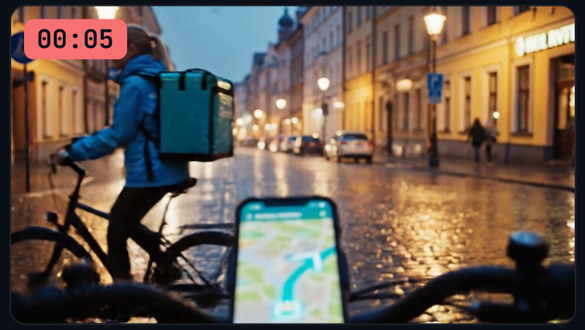
Действие пропущено

пакет остался на стойке, в рюкзак его так и не положили



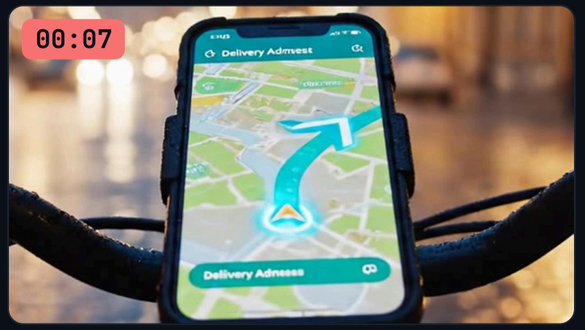
Детали поплыли после склейки

надпись на коробе меняется: «Glono» → «Glovo»



Пространство сломалось

руль с телефоном «въезжает» в кадр, а курьер всё ещё едет впереди



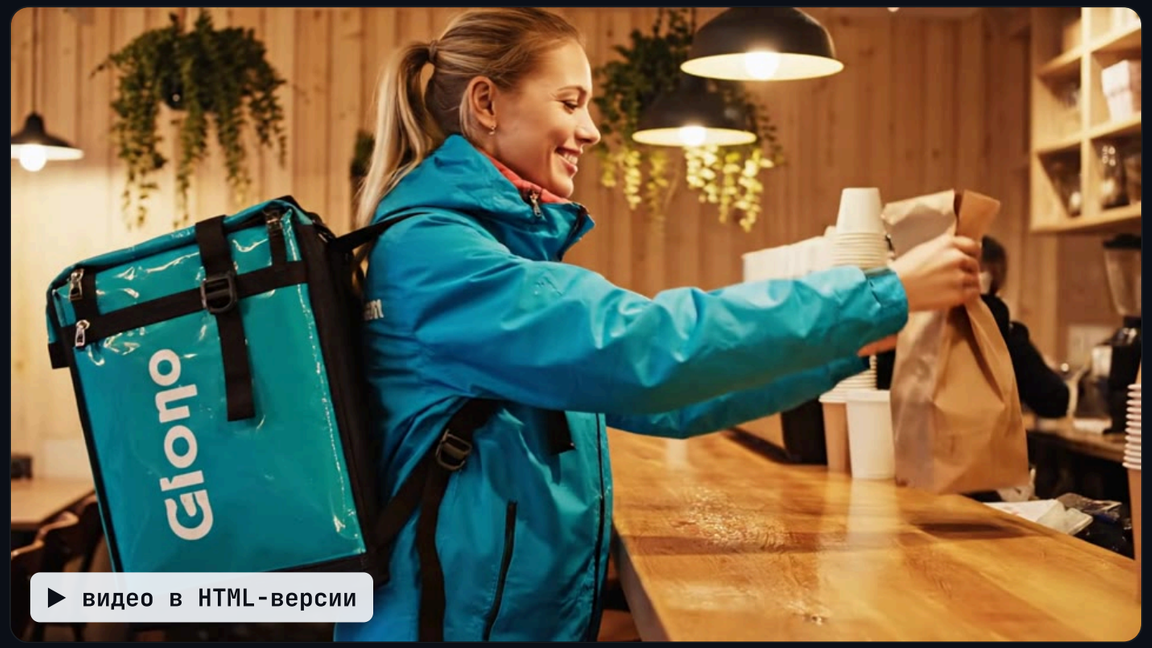
Псевдотекст

«Delivery Admest» вместо «Delivery Address»

ДВА РЕЖИМА ГЕНЕРАЦИИ

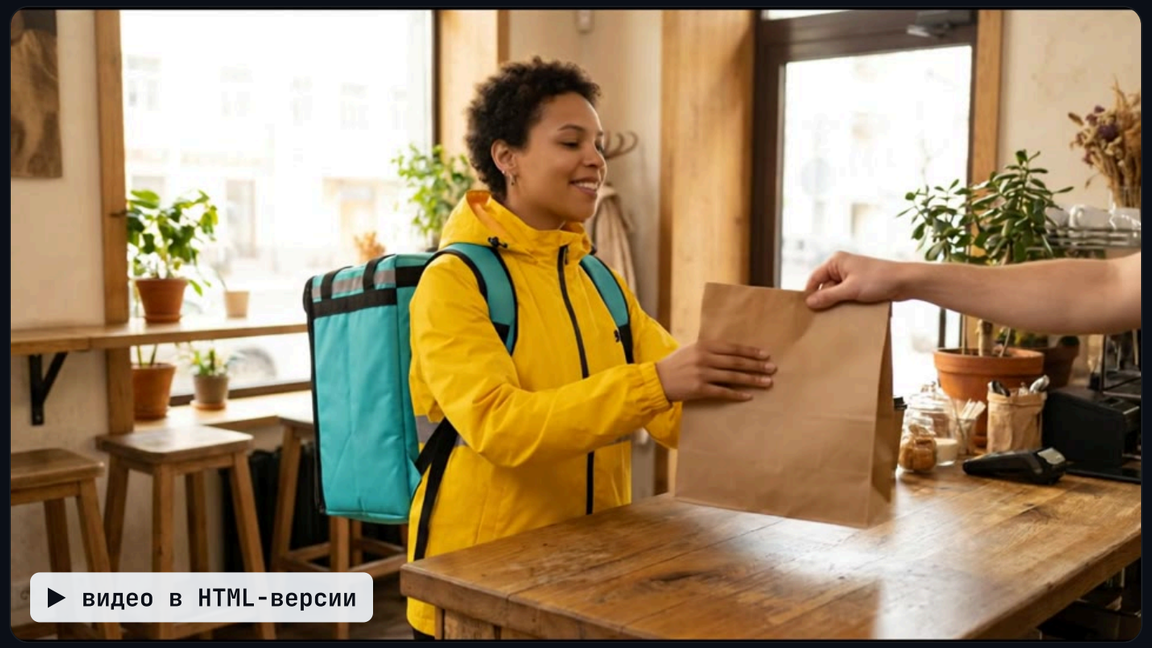
Text-to-video и image-to-video

TEXT-TO-VIDEO на входе только текст



Текст → Модель решает **что в кадре** и **как оно движется** → ✗ **две задачи сразу**

IMAGE-TO-VIDEO на входе кадр + текст



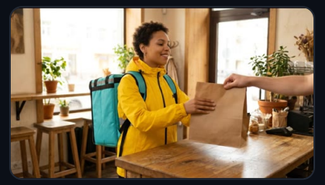
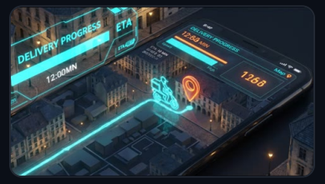
Кадр ✓ + текст о движении → Модель решает только **как оно движется** → ✓ **одна задача**

Правило: внешность, свет и композицию фиксируем в картинке (навык из L04). Видеомодель отвечает только за движение.

ШАГ 1 • СТОРИБОРД

Сториборд: вся история до первой генерации

История разбивается на шоты по 4–8 секунд. Каждая строка = один ключевой кадр + один промпт + одна генерация.

#	КАДР	ВРЕМЯ	ДЕЙСТВИЕ	КАМЕРА	ФАЙЛ КЛЮЧЕВОГО КАДРА
1		0–8 с	Курьер забирает пакет у бариста и поворачивается к выходу	средний план, медленный наезд	`shot1_cafe_pickup.png`
2		7.5–15.5 с	Едет на велосипеде по мокрой улице в сумерках	tracking рядом с курьером, низкий ракурс	`shot2_bike_rain.png`
3		15–23 с	Маршрут на карте прорисовывается до точки доставки	цифровой наезд и лёгкий наклон	`shot3_map_route.png`

ПОЛНЫЙ ШАБЛОН (CREATOR TOOLS) **Shot / timing** | **Visual** | **Voice-over** | **Image prompt** | **Video prompt** | **SFX (sound effects)** | **Music**

> **Почему короткие шоты:** длинный или продлённый клип накапливает дрейф, и любой дефект означает перегенерацию целиком. Короткий шот стабильнее, переделывается только он, и бюджет предсказуем.

Время с учётом переходов по 0,5 с. 1 минута ≈ 8 шотов по 8 с; 1 час ≈ 450 шотов. Сториборд ведут в таблице (Google Sheets, Excel): это план работ, бюджет и чек-лист приёмки.

Лист персонажа как референс для всех шотов



- Референс **сужает выбор** модели: меньше вариантов внешности.
- **Veo 3.1:** до 3 картинок-референсов. **Kling 3.0:** Elements, 2–4 картинки.
- Стабильнее, но **не гарантировано**: каждый шот проверяем глазами.

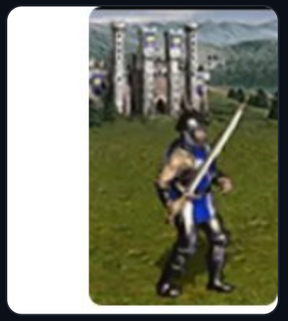




Результат: **тот же курьер** в шотах 1 и 2.

ШАГ 3 • КЛЮЧЕВОЙ КАДР (ПРИМЕР ИЗ L04)

Ключевой кадр правим в image-чате, до генерации видео



Спрайт: исходник из игры



«Сделай реалистичный кадр 16:9 по этому спрайту»

Черновик: не тот шлем и накидка



«Руки без защиты, накидка в бело-синие прямоугольники, шлем в форме плоского „котелка“»

Одобрено ✓: первый кадр для видео

правка картинки: секунды, центы

одна правка **картинки** в чате

перегенерация видео: минуты, $0.40/с

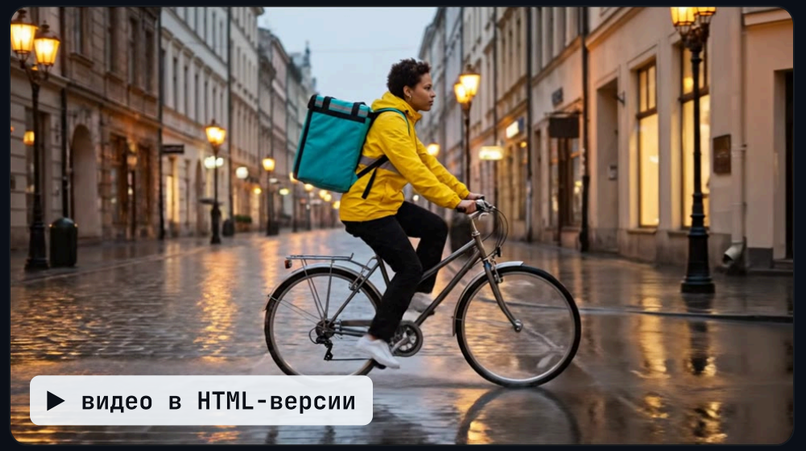
одна перегенерация **видео** (Veo 3.1, 720p)

Структура видеопромпта: 6 слотов

1 Камера · 2 Кто · 3 Действие · 4 Где и когда · 5 Детали движения · 6 Свет

ПРОМПТ ШОТА 2 (VEO 3.1, IMAGE-TO-VIDEO)

1 Dynamic tracking shot moving forward alongside the courier. 2 The same courier with short cropped curly hair 3 pedals her bicycle forward 4 through the rain-slicked city avenue at twilight. 5 Wheels spinning smoothly forward with water spray cutting through shallow puddles. 6 Wet cobblestones reflecting warm shop lights and streetlamps.



Результат: шот 2

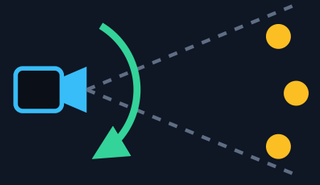
- **Глаголы движения** (pedals, spinning, tracks): модели нужно знать, что меняется.
- **Не пересказывайте кадр:** он уже на входе. Для внешности хватит одной приметы.
- **Пишите, что должно происходить.** Поле negative prompt есть не везде (есть в Kling, Wan).

Движения камеры и термины для промпта



Статичная камера `Static`

“static camera, locked-off shot”



Поворот на месте `Pan`

“slow pan left across the street”



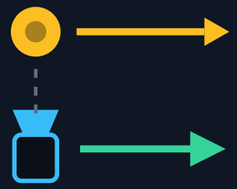
Наклон вверх / вниз `Tilt`

“tilt up to the rooftops”



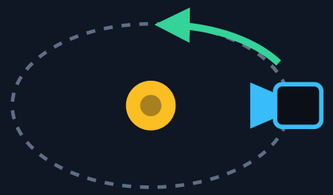
Наезд / отъезд `Dolly in / out`

“slow dolly in to her face”



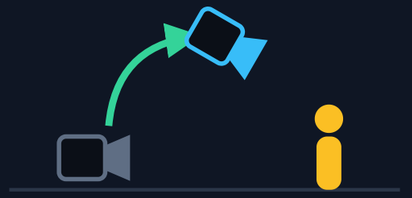
Едем рядом с героем `Tracking`

“tracking shot alongside the courier”



Облёт вокруг объекта `Orbit`

“slow orbit around the mug”



Подъём камеры вверх `Crane`

“crane up over the street”



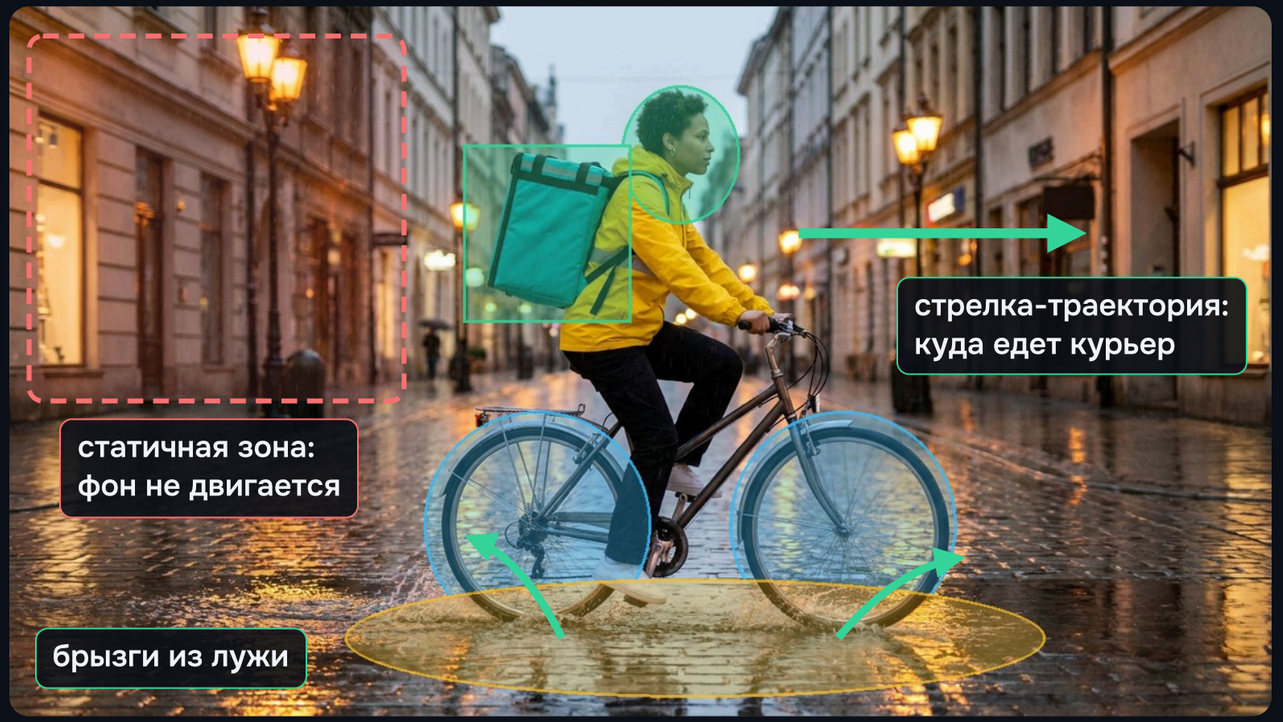
С рук, лёгкая тряска `Handheld`

“handheld, slight shake”

> Модели видели видео с подписями, поэтому понимают **операторские термины**. В чат-приложениях камеру задают только словами; в видеостудиях есть и отдельные настройки (Runway, Kling, Luma).

Схемы: вид сверху (Pan, Dolly, Tracking, Orbit) и сбоку (Static, Tilt, Crane). Камера голубая, объект жёлтый, движение показано зелёной стрелкой.

Управление кроме промпта: кадры, продление, референсы



Motion Brush (Kling): до 6 выделенных элементов, у каждого своя стрелка + статичная зона. Есть в моделях Kling 1.x–2.x; в списке функций Kling 3.0 его нет.



Первый + последний кадр

Модель достраивает движение между двумя картинками. **Veo 3.1, Gemini Omni, Kling 3.0**



Продление клипа

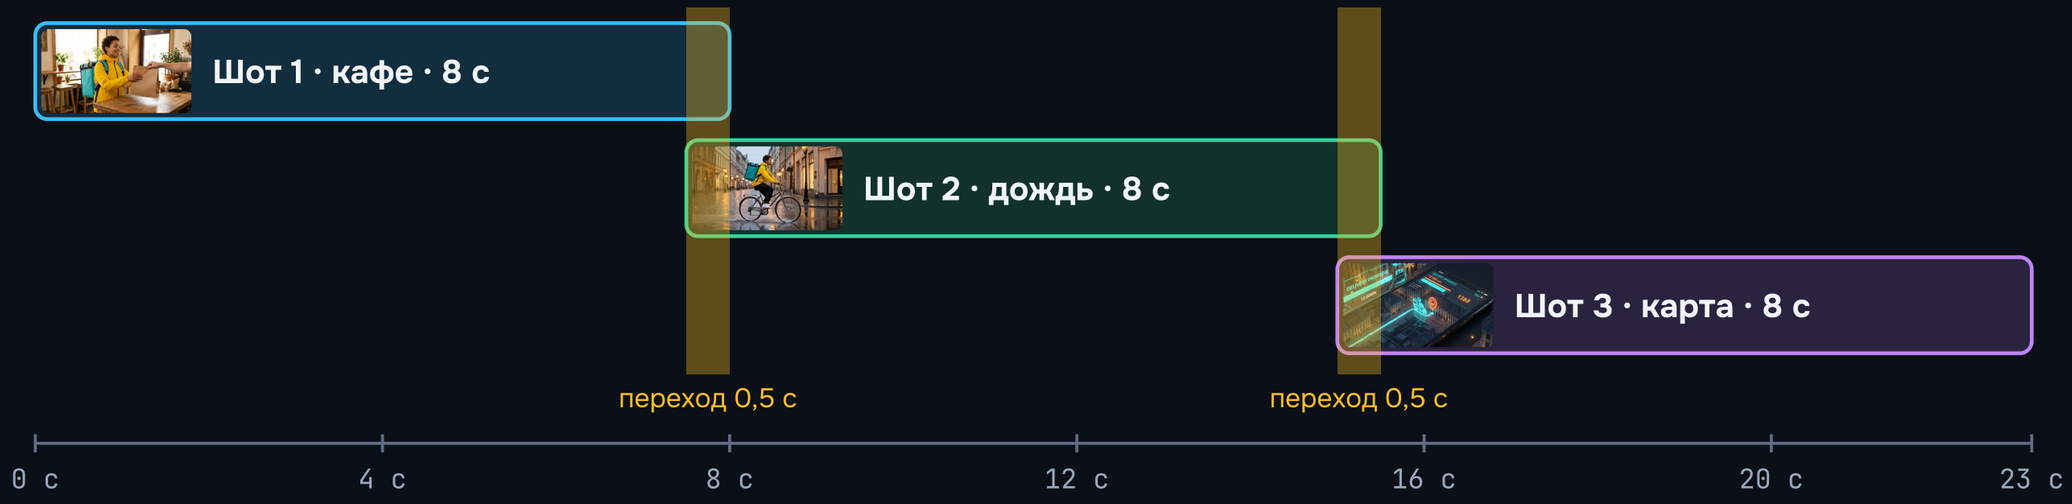
Veo 3.1: +7 с за шаг, до 148 с (720p, не Lite)
Gemini Omni: +10 с за шаг, до 40 с



Референсы героя

Veo 3.1 / Fast: до 3 картинок, клип 8 с
Kling 3.0 Elements: 2–4 картинки

Монтаж: три шота в один ролик на 23 секунды

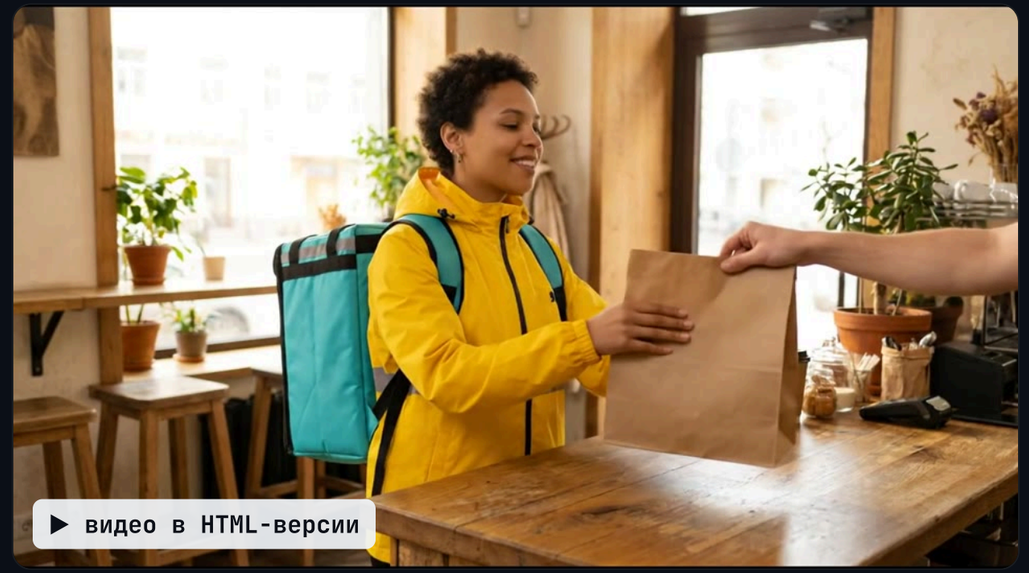


8 + 8 + 8 − 0,5 − 0,5 = 23 с

три клипа Veo 3.1 и два перехода: шторка и затемнение

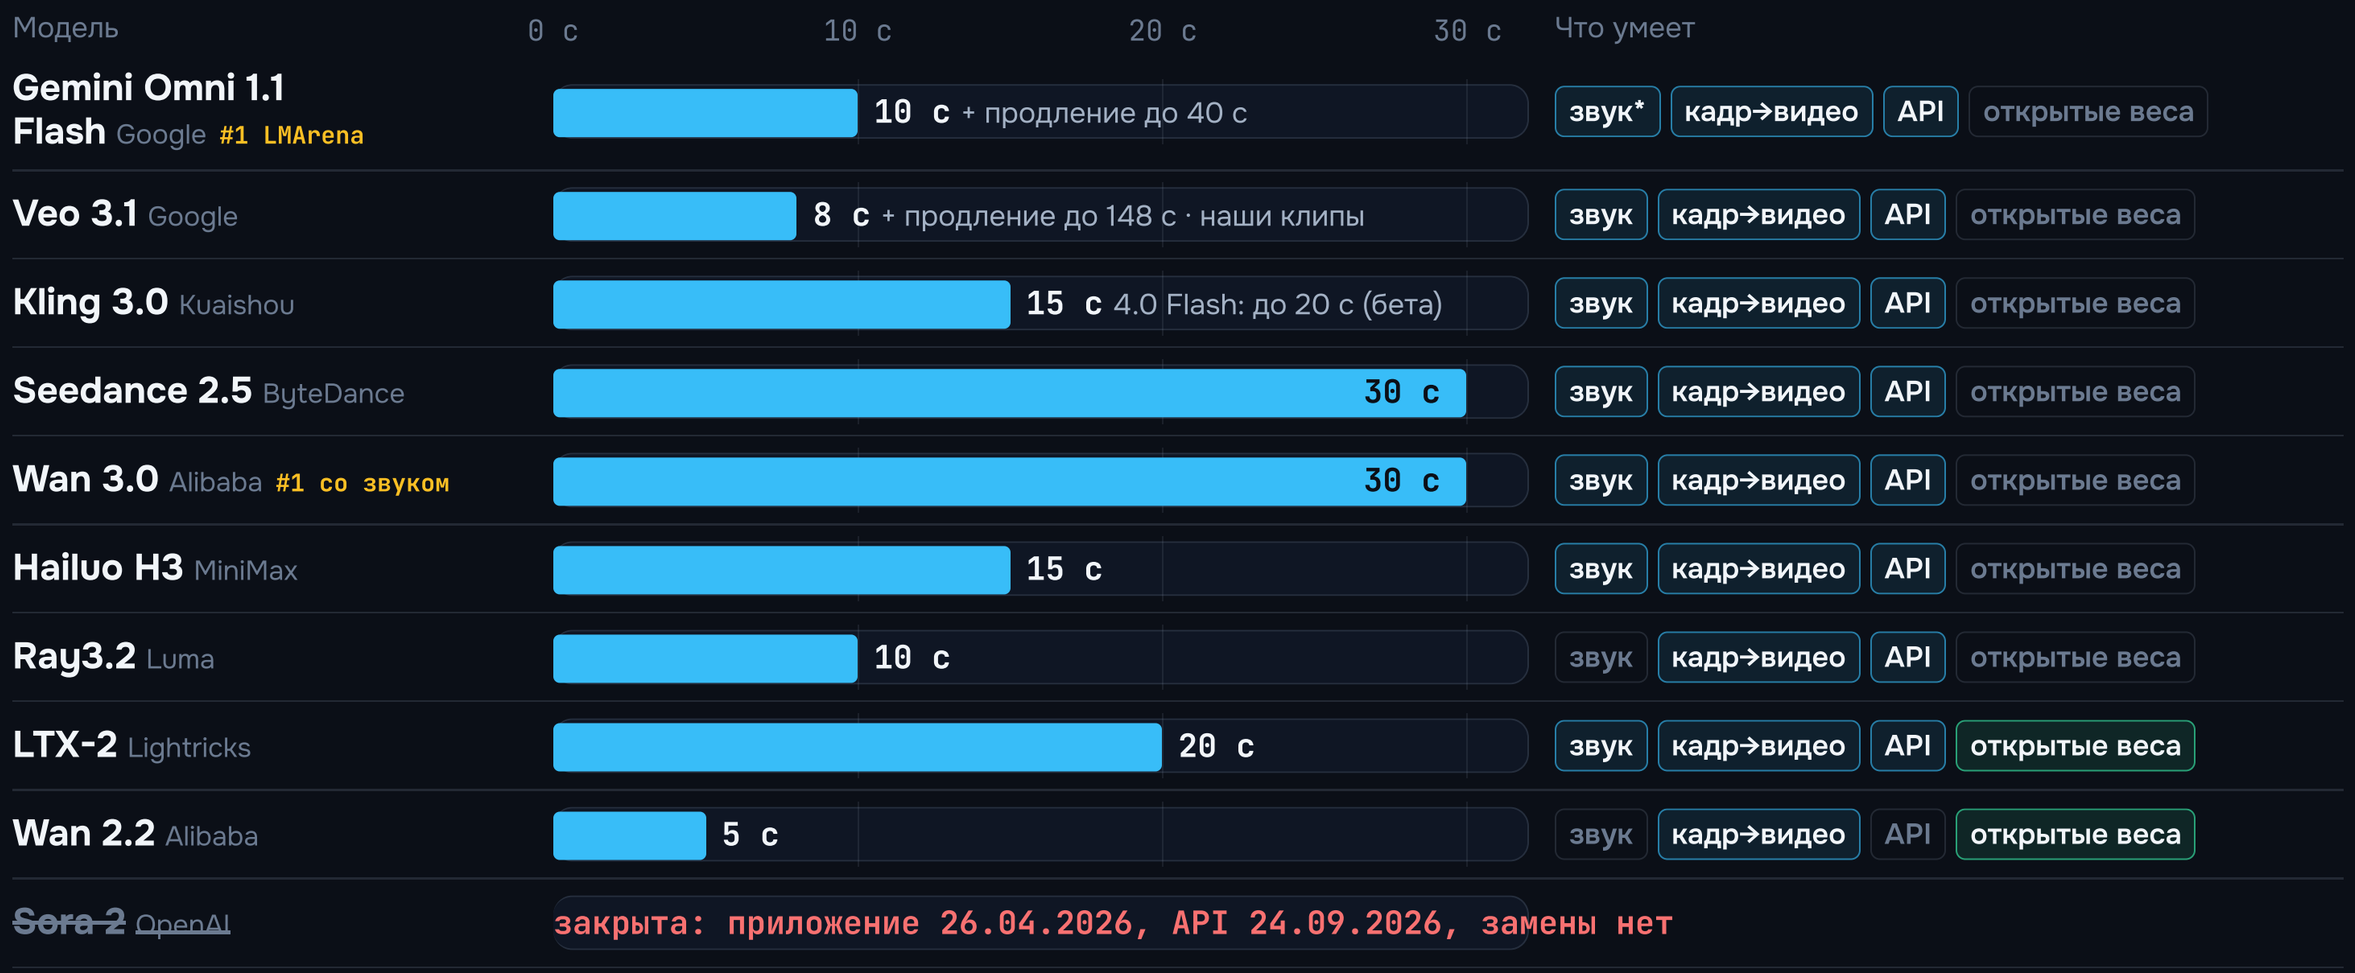
> Склейка в любом редакторе (CapCut, DaVinci Resolve) или одной командой:

```
ffmpeg -i shot1.mp4 -i shot2.mp4 -i shot3.mp4 -filter_complex  "[0]
[1]xfade=transition=wipeleft:duration=0.5:offset=7.5[a];
  [a][2]xfade=transition=fadeblack:duration=0.5:offset=15" final.mp4
```



РЫНОК • ОКТЯБРЬ 2026

Видеомодели: максимальная длина клипа и возможности



Полоса: максимум за одну генерацию. Подсвеченный значок: есть; серый: нет или не подтверждено. * Звук у Omni по сторонним обзорам. Рейтинги: LMArena (21.09.2026), Artificial Analysis со звуком (октябрь 2026).

ПЕРЕРЫВ

5 минут на кофе и отдых для глаз

05:00

Дальше: код, стоимость, приёмка, риски и домашнее задание.

ДЛЯ СПРАВКИ • GOOGLE-GENAI

Gemini API: видео из картинки на Python

```python
import time
from google import genai
from google.genai import types

client = genai.Client()  # ключ из GEMINI_API_KEY
op = client.models.generate_videos(
    model="veo-3.1-fast-generate-preview",
    prompt="Tracking shot alongside the courier",
    image=types.Image.from_file(location="shot2.png"),
)
while not op.done:  # ждём: от ~11 с до ~6 мин
    time.sleep(10)
    op = client.operations.get(op)
video = op.response.generated_videos[0].video
client.files.download(file=video)
video.save("shot2.mp4")
```

Асинхронная операция: **отправить → опрашивать статус → скачать**. Генерация занимает от секунд до минут.

ТОТ ЖЕ ШАБЛОН В ДРУГИХ API

- Kling API
- Runway API
- xAI API (Grok Imagine)

Gemini API, октябрь 2026. Бесплатного тарифа для Veo нет. Цены на следующем слайде.

СТОИМОСТЬ

Стоимость генерации: клип, минута, час видео

Цена считается за секунду сгенерированного видео, 720p. Час готового ролика = 3600 с = **450 шотов по 8 секунд**.

МОДЕЛЬ	$ ЗА СЕКУНДУ	КЛИП 8 С	1 МИНУТА	1 ЧАС	1 ЧАС, 3 ПОПЫТКИ НА ШОТ
Veo 3.1 Lite Gemini API	$0.05	$0.40	$3.00	**$180**	**$540**
Grok Imagine 1.5 xAI API	$0.08	$0.64	$4.80	**$288**	**$864**
Veo 3.1 Fast Gemini API	$0.10	$0.80	$6.00	**$360**	**$1,080**
Runway Gen-4.5 Runway API	$0.12	$0.96	$7.20	**$432**	**$1,296**
Seedance 2.5 Runway API, от	$0.20	$1.60	$12.00	**$720**	**$2,160**
Veo 3.1 Gemini API	$0.40	$3.20	$24.00	**$1,440**	**$4,320**

Наш ролик 23 с: 3 шота × 8 с × 3 попытки = 72 с генерации: $28.80 на Veo 3.1, $7.20 на Fast. При 3 попытках на шот генерируется втрое больше, чем остаётся в ролике.

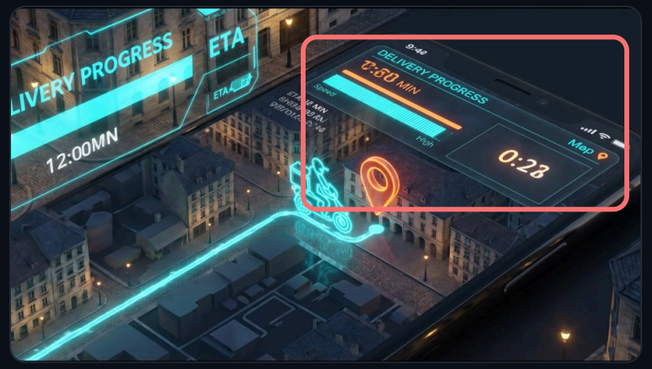
Kling (веб): 3.0, 1080p со звуком = 12 кредитов/с, то есть 43 200 кредитов за час; цена кредита зависит от тарифа. Чат-приложения: подписка, без цены за секунду.

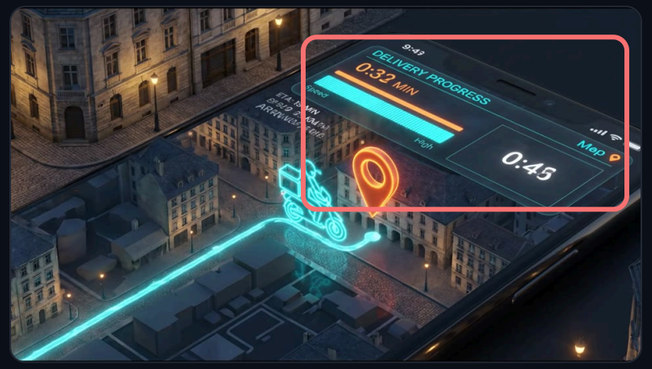
Цены: Gemini API, xAI API и Runway API, октябрь 2026; Gemini Omni 1.1 Flash ≈$0.10/с (720p, оплата токенами), Grok Imagine Lite $0.02/с; оплачиваются только успешные генерации. Не включены: картинки для ключевых кадров, монтаж, звук, работа людей. 3 попытки на шот: допущение для оценки.

ПРИЁМКА

Чек-лист приёмки сгенерированного клипа

Даже удачный image-to-video клип смотрим покадрово. Дефекты из **наших** шотов 2 и 3:





Шот 3, 1,5 секунды разницы: таймер прыгает 0:28 → 0:45, «Мер» вместо «Мар», на иконке мопед, а курьер на велосипеде.



Шот 2: вывеска «THABIK» из случайных букв.

ЧЕК-ЛИСТ ПРИЁМКИ

1. **Руки и предметы** в контакте: не слипаются, не исчезают
2. **Текст и цифры**: читаются и не меняются
3. **Лицо и одежда**: как на референсе
4. **Движение**: скорость и направление (колёса вперёд)
5. **Первый кадр**: совпадает с одобренным
6. **Стык шотов**: свет и цвет совпадают

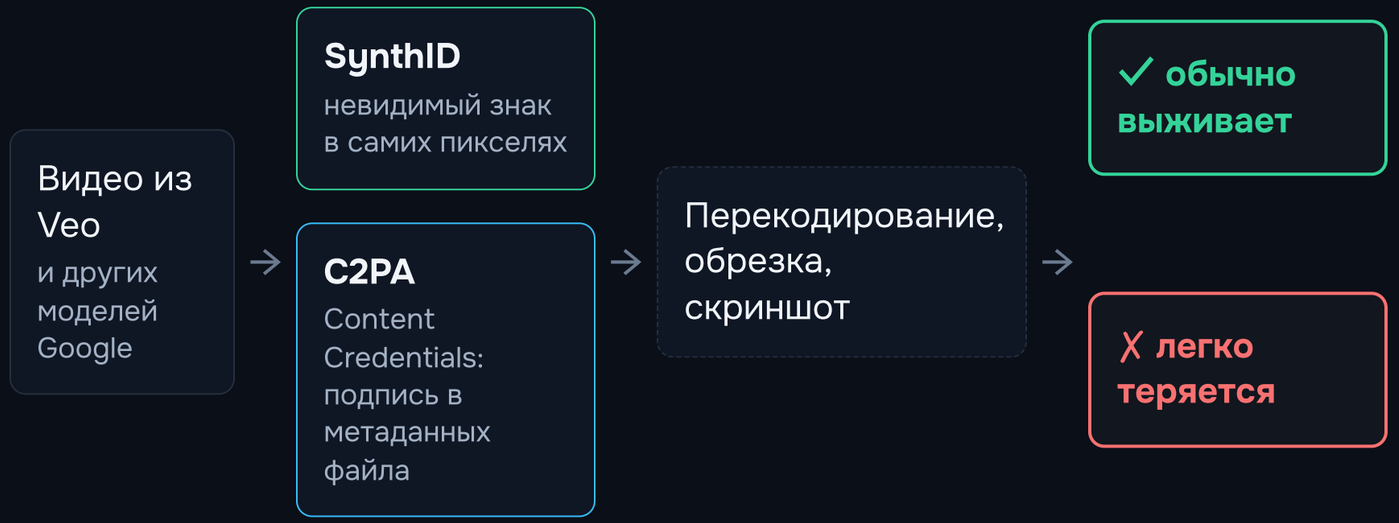
> Этот же чек-лист используется как **рубрика ДЗ**.

РИСКИ

Права, маркировка и происхождение видео

- **Свои кадры и персонажи**
  можно, с пометкой «создано ИИ»
- **Чужие бренды, логотипы, стили**
  только с разрешения и после юристов компании
- **Реальные люди без согласия**
  сотрудники, клиенты, публичные лица: только с письменного согласия

КАК МЕТКА ПЕРЕЖИВАЕТ ПЕРЕСОХРАНЕНИЕ



Проверка SynthID: загрузить видео в приложение Gemini (до 100 МБ, 90 с). Находит только SynthID, видео других сервисов может не распознать.

EU AI Act, ст. 50: с 2 августа 2026 дипфейк обязан пометить тот, кто его публикует; провайдер модели обязан ставить машиночитаемую метку. Штраф до €15 млн или 3% оборота.

ПРАКТИКА

Домашнее задание 5: мини-история из трёх шотов



Трек А · товар

3 шота промо по кадрам из L04: появление, деталь, финальный план. Форма и надписи не меняются.



Трек Б · курьер

3 шота истории курьера: забрал заказ, поездка, доставка. Лицо и форма как на референсе.

1. **Сториборд** на 3 строки → `storyboard.md`
2. **Text-to-video** одним промптом, для сравнения
3. 3 шота **image-to-video**; один из них ещё и во **втором сервисе**
4. Монтаж в `final.mp4`, 15–25 с
5. Промпты, настройки, стоимость → `video_spec.md`; приёмка по слайду 18 → `video_qa.md`

```
genai-homeworks/L05/
├── storyboard.md
├── videos/  # shots + final.mp4
├── video_spec.md
└── video_qa.md
```

Ревьюер: **ihar_rubanovich@epam.com**. Бесплатные лимиты сервисов небольшие и меняются: проверьте перед стартом (таблица в файле ДЗ).

ИТОГИ

Итоги урока

1. **Сначала сториборд**
   история разбита на шоты до первой генерации
2. **Сначала одобренный кадр, потом видео**
   image-to-video из одобренного кадра
3. **Одно действие на шот**
   4–8 секунд; историю собираем по сториборду и монтажом
4. **Структурированный промпт**
   камера + действие + детали движения
5. **Приёмка и бюджет**
   чек-лист на каждый клип; цена считается за секунду



Урок 06: звук и речь. Современные видеомодели генерируют звук сами. Как им управлять, разберём в L06.