GENAI BASICS • УРОК 06 • МОДУЛЬ 2: МУЛЬТИМОДАЛЬНОСТЬ (ФИНАЛ МОДУЛЯ)

Речь и аудио AI

Синтез речи, Whisper, саунд-дизайн Foley и генерация музыки

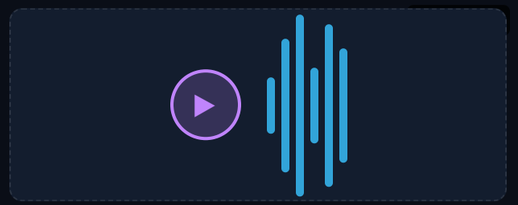
От одномерных звуковых волн и мел-спектрограмм к дискретным нейрокодекам (EnCodec/DAC), пословным таймкодам Whisper, студиям ElevenLabs и Suno, звуковой экосистеме Google и синхронизированному мультитреку со Sidechain Ducking.

АКСИОМА 10/90 В ГЕНЕРАТИВНОМ ЗВУКЕ: Генерация сырой формы волны нейросетью — это лишь **10% успеха**. Остальные **90%** — это Voice Activity Detection (VAD), нормализация громкости LUFS, пословная привязка субтитров, защита от дипфейков, задержка менее 150 мс и сведение стемов в Python.

ИНТЕРАКТИВНЫЙ ХУК • СЛЕПОЙ ТЕСТ

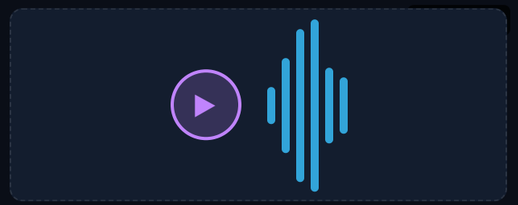
Слепой тест: отличите студийный микрофон от ИИ 2026 года

Четыре аудиофрагмента профессионального уровня. Напишите в чат: какие из них записаны микрофоном вживую, а какие сгенерированы нейросетью?



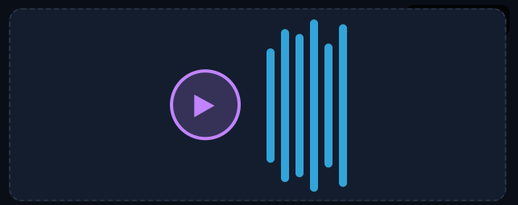
Дикторская начитка

Бархатный тембр документалиста, естественный вдох, звонкие согласные.



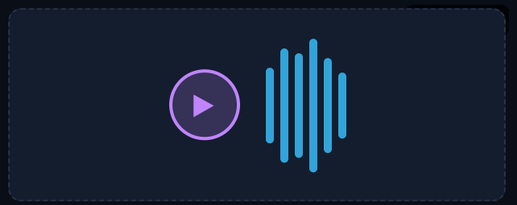
Фоли-шум велосипеда

Шины режут гравийную лужу, звон цепи, реалистичный мокрый асфальт.



Акустический джаз

Живое пианино, щеточки по малому барабану, пульсирующий контрабас.



Звонок в техподдержку

Диалог с задержкой 130 мс, перебивание собеседника, междометия «угу», «да-да».

Вопрос в чат: Напишите в чат, какие из 4 фрагментов — 100% нейросетевая генерация? Дать студентам 45 секунд на ответы.

ЭВОЛЮЦИЯ НЕЙРОЗВУКА • 2020–2026

Все 4 клипа — 100% генерация ИИ! Хроника преодоления робота

Все 4 фрагмента были синтезированы нейросетями. За 6 лет аудиотехнологии прошли путь от синтезаторов навигаторов до живых речевых агентов.

2020–2021 • РОБОТИЗИРОВАННЫЙ ЗВОН

WaveNet & FastSpeech

Срез: Металлический фазовый шум, роботизированная интонация без пауз и эмоций, полоса пропускания 16 кГц.

2022–2023 • ПРОРЫВ РАСПОЗНАВАНИЯ

OpenAI Whisper & ElevenLabs v1

Срез: OpenAI Whisper решает задачу транскрибации; ElevenLabs вводит эмоциональную выразительность и клонирование.

2024–2025 • НЕЙРОКОДЕКИ И МУЗЫКА

Suno v3, Udio & EnCodec

Срез: Полноценные 3-минутные песни с вокалом и куплетами; текстовая генерация фоли-шумов (SFX); дискретные токены звука.

2026 • ГОЛОСОВЫЕ АГЕНТЫ ON-DEVICE

Cartesia Sonic, Whisper v3 & Suno v4

Срез: Задержка речевого цикла менее 150 мс, студийное качество 48 кГц, мгновенный перевод речи с сохранением оригинального тембра.

> **Вызов 2026 года:** Вопрос естественности тембра закрыт. Главная битва идет за **минимальную задержку диалога (<150 мс)** и **мультитрековое сведение** без частотных конфликтов.

ДОРОЖНАЯ КАРТА КУРСА • ФИНАЛ МОДУЛЯ 2

Завершение мультимодальности: озвучивание немых роликов из L05

Модуль 2 переводит текстовые промпты в физический мир. В L04 мы зафиксировали кадры, в L05 оживили движение. Сегодня мы даем роликам голос, шумы и саундтрек.

M1 • ГОТОВО	L04 • ГОТОВО	L05 • ГОТОВО	L06 • ЗДЕСЬ	M3 • ДАЛЕЕ	M4–M6
База LLM	**Картинки**	**Видео**	**Речь и звук**	**Экосистема**	**Агенты и код**
L01–L03: Промпты и API	Промпты, C2_rain, пэкшот	I2V, камеры, монтаж	TTS, Whisper, Foley, саундтрек	L07: Copilot, M365 и Dev	L08–L16: MCP, архитектура

ЧТО МЫ ПОЛУЧИЛИ ИЗ УРОКА 05

Немые 5-секундные видеодубли

Курьер Glovo под дождем (`shot2_bike_rain.mp4`) и вращающаяся кружка кофе (`packshot_360.mp4`) безупречны визуально, но кинематографически мертвы без звука.

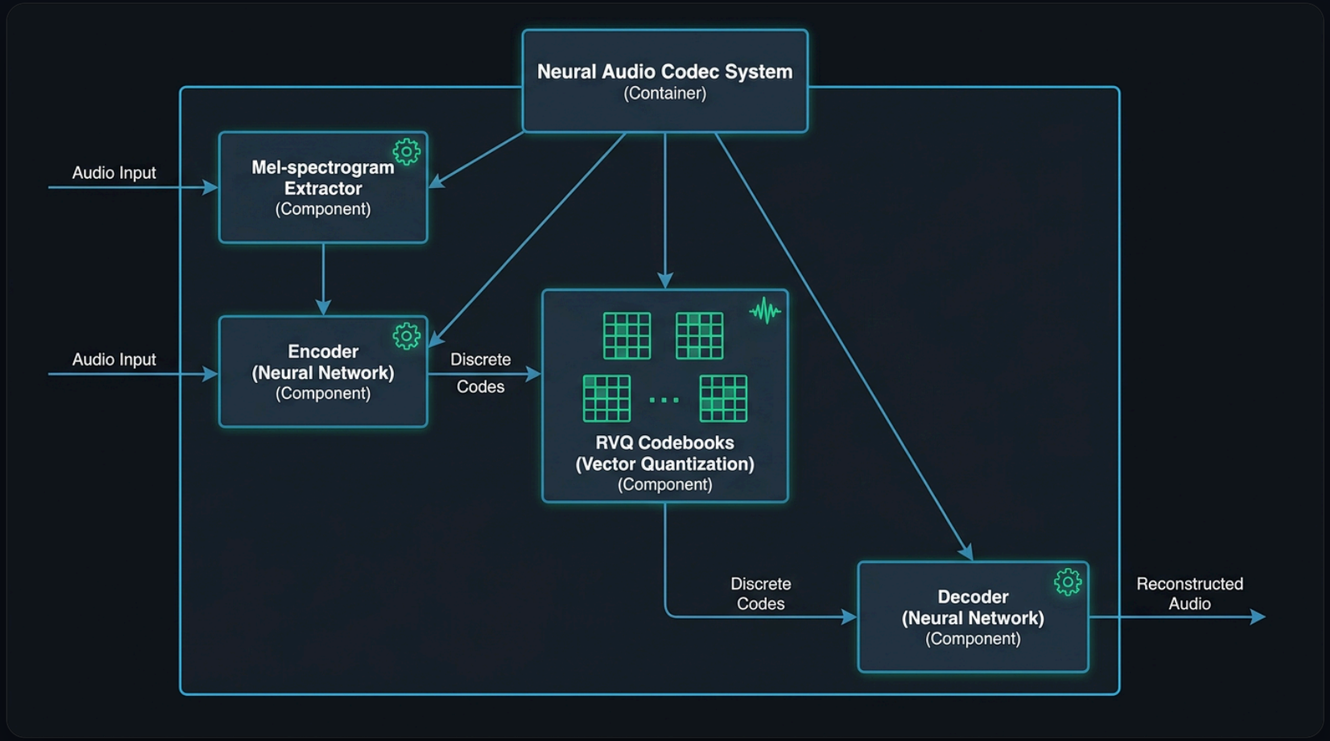
ЧТО L06 ДАЕТ ДЛЯ ПОЛНОГО ПРОДАКШЕНА

3-слойный акустический саундтрек

1. **Закадровый голос:** синтез речи диктора с точной артикуляцией.
2. **Фоли SFX:** брызги луж, шелест дождевика, трещотка втулки велосипеда.
3. **Музыка:** атмосферный фон с автоматическим приглушением (ducking).

Природа звука: форма волны, мел-спектрограммы и нейрокодеки

Как трансформеры генерируют непрерывный 48 кГц звук: архитектура остаточного векторного квантования (RVQ).



1. НЕПРЕРЫВНАЯ ВОЛНА PCM (1D)

44 100 чисел в секунду

Звук — одномерная волна давления воздуха. Прямая подача в авторегрессионный трансформер переполнила бы контекстное окно за секунды.

2. ПРЕОБРАЗОВАНИЕ ФУРЬЕ (STFT)

Мел-спектрограммы (2D)

Нарезка на окна по 25 мс с логарифмической шкалой частот Mel. Именно это принимает энкодер Whisper.

3. НЕЙРОКОДЕКИ (ENCODEC / DAC)

RVQ: всего ~50 токенов/сек

Остаточное векторное квантование: сжимает 48 кГц звук в дискретные целочисленные токены, понятные обычным языковым моделям!

OpenAI Whisper: Encoder-Decoder и пословные таймкоды субтитров

Стандарт распознавания речи в индустрии: от 30-секундных мел-спектрограмм к пословной синхронизации субтитров.

АУДИО-ЭНКОДЕР (СВЕРТКИ + ATTENTION)

30-секундные чанки

Принимает 80/128-канальную мел-спектрограмму. Две 1D-свертки со страйдом 2 сжимают временную ось в 4 раза, после чего стек Transformer-блоков извлекает акустические эмбеддинги.

ТЕКСТОВЫЙ ДЕКОДЕР (СПЕЦТОКЕНЫ)

Префиксные промпты задачи

Авторегрессионный декодер управляется токенами: `<|startoftranscript|>`, язык `<|ru|>`, задача `<|transcribe|>` или `<|translate|>` (прямой перевод на английский).

WORD-LEVEL TIMESTAMPS

Субтитры без ручной разметки

Параметр `word_timestamps=True` анализирует матрицы Cross-Attention и методом Dynamic Time Warping вычисляет точные миллисекунды начала и конца каждого слова для монтажа.

Инженерная ценность: Пословные таймкоды позволяют видеомонтажному скрипту на Python автоматически нарезать речь на субтитры `.srt` и синхронизировать анимацию титров на экране.

Кабинет Whisper Playground: борьба с зацикливанием и Silero VAD

Почему Whisper циклится в тишине и как связка с Silero VAD и CTranslate2 обеспечивает безотказный продакшен.



ПРОБЛЕМА: ПЕТЛИ ПОВТОРОВ В ТИШИНЕ

Галлюцинации Repetition Loops

Когда диктор молчит, авторегрессионный декодер Whisper цепляется за шум и входит в бесконечный цикл: *«Спасибо за просмотр! Ставьте лайк...»*.

РЕШЕНИЕ: SILERO VAD (1 МБ НЕЙРОСЕТЬ)

Предварительная вырезка пауз

Voice Activity Detection: за 2 мс сканирует файл, вырезает паузы и тишину. Whisper получает только гарантированную речь, что на 100% исключает зацикливание.

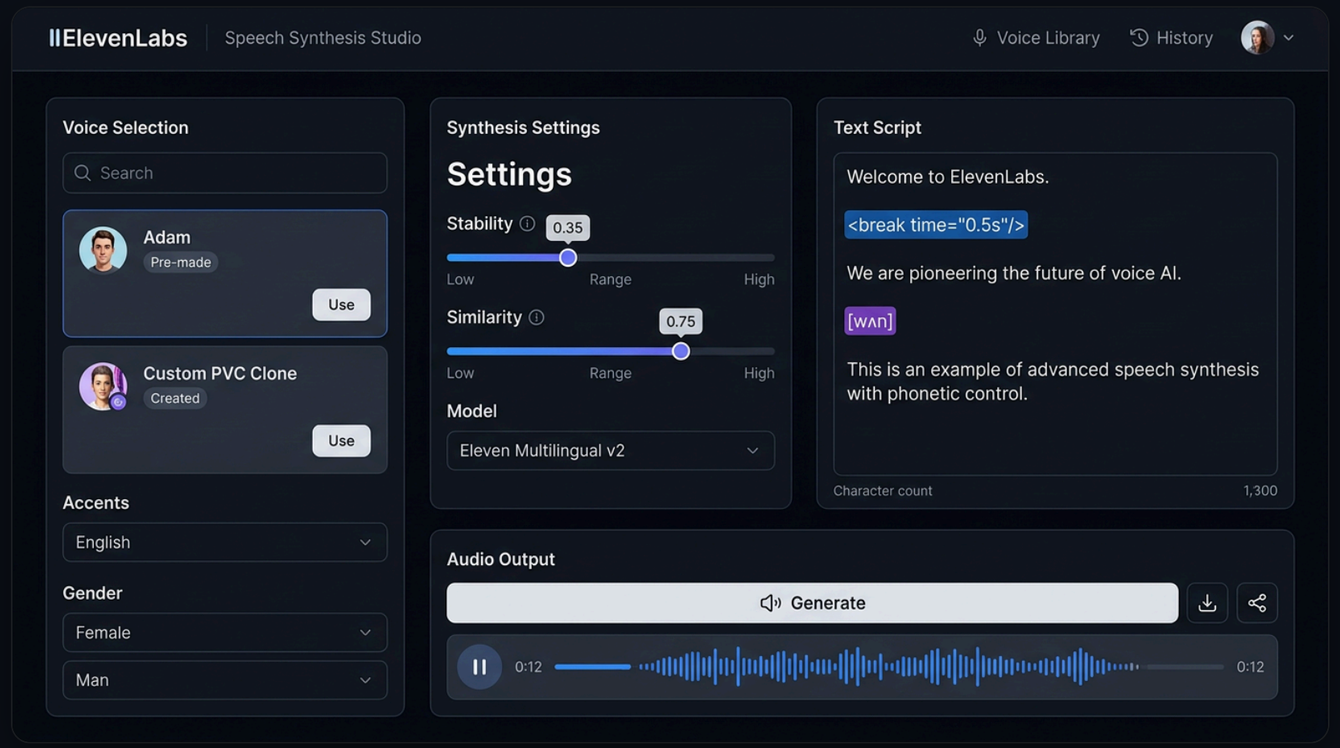
РАНТАЙМ: FASTER-WHISPER (CTRANSLATE2)

Ускорение в 4 раза на C++

Квантование INT8/FP16 сокращает расход видеопамяти на 50% и ускоряет транскрибацию в 4 раза по сравнению с ванильным PyTorch.

Ландшафт TTS 2026: студийный ElevenLabs против сверхбыстрых агентов

Рынок синтеза речи разделился на студийных лидеров, ультранизкую задержку для ботов и локальные $0 модели.



1. СТУДИЙНЫЙ ЭТАЛОН (ELEVENLABS V2)

48 кГц, 32+ языка, эмоции

Эталон для озвучки видео и дубляжа. В кабинете слева: выбор голоса и клонов; в центре: ползунки Stability и Similarity; справа: текст с SSML и фонетикой. Задержка ~350 мс.

2. ДИАЛОГОВЫЕ АГЕНТЫ (CARTESIA SONIC)

Задержка 135 мс до первого байта

Архитектура State-Space Model. Создана специально для телефонных ботов и мгновенных ответов без задержки.

3. ЛОКАЛЬНЫЙ OPEN-SOURCE (KOKORO-82M)

82 млн параметров, $0 API cost

Лицензия Apache 2.0. Работает локально на CPU и в браузере через WebAssembly без передачи данных в облако.

Управление диктором: пунктуация, SSML-теги и ползунки Stability

Как управлять дыханием, паузами и эмоциональным накалом искусственного голоса без искажений.

ПУНКТУАЦИЯ КАК НОТНАЯ ГРАМОТА

Вдохи, паузы и акценты

- **Многоточие (`...`):** принуждает модель сделать естественный вдох и замедлить темп.
- **Длинное тире (`—`):** создает смысловую паузу перед кульминацией фразы.
- **ЗАГЛАВНЫЕ БУКВЫ:** добавляют эмоциональное ударение и повышение тона.
- **SSML & IPA:** тег `<break time="0.5s"/>` и фонетическая транскрипция для брендов: `<phoneme alphabet="ipa" ph="gloʊvoʊ">Glovo</phoneme>`.

КАЛИБРОВКА ПОЛЗУНКОВ ELEVENLABS

Stability: актерская игра vs стабильность

- **Stability = 0.30–0.40:** Высокая вариативность, шепот, драматические паузы, эмоциональный накал (кинотрейлеры, сторителлинг).
- **Stability = 0.80–0.90:** Монотонная, академическая подача (юридические дисклеймеры, документация, банковские IVR).
- **Similarity Boost = 0.75:** Высокая точность оригинального тембра без появления фазовых артефактов микрофона.

> **Золотое правило:** Никогда не ставьте Stability на 1.0 (голос превратится в бездушного робота) и ниже 0.2 (появятся случайные фальцеты и срывы голоса). Оптимум для рекламы — **0.35–0.45**.

Клонирование голоса: Instant (d-векторы) vs Professional (LoRA PVC)

Два принципиально разных подхода к воспроизведению тембра человека: быстрый zero-shot против студийного обучения.

INSTANT VOICE CLONING (IVC / ZERO-SHOT)

60 секунд аудио • d-вектор спикера

• **Как работает:** Сверточная сеть извлекает 512-мерный вектор эмбеддинга спикера и подмешивает его в базовую модель при генерации.
• **Скорость и стоимость:** Готово за 5 секунд, $0 затрат на обучение.
• **Ловушка:** Сходство ~80%. Если исходный сэмпл записан на плохой микрофон в комнате с эхом — это эхо навсегда впечатается во все генерации!

PROFESSIONAL VOICE CLONING (PVC / FINE-TUNING)

45 минут студии • Дообучение весов LoRA

• **Как работает:** Полный цикл дообучения адаптеров весов (LoRA) на GPU в течение 2–4 часов на чистых студийных записях.
• **Результат:** 98% сходства, способность шептать, кричать и сохранять тончайшие обертоны и форманты живого человека.
• **Стандарт:** Требует верификации согласия владельца голоса через Voice Captcha.

Аудио-безопасность: векторы угроз, Voice Captcha и SynthID

Как защитить бизнес от CEO-fraud, а голос от несанкционированного клонирования.

ВЕКТОРЫ УГРОЗ 2026

Мошенничество и дипфейки

• **CEO Voice Fraud:** Звонки финансовым директорам с имитацией голоса руководителя.
• **Обход биометрии:** Атаки на банковские контакт-центры с подтверждением платежей голосом.
• **Фейковые доказательства:** Синтез записей с компроматом на публичных лиц.

DYNAMIC VOICE CAPTCHA

Защита от чужих аудиозаписей

Платформа генерирует случайную динамическую фразу с текущим таймстемпом. Владелец обязан зачитать ее вслух в камеру. Украденная запись не пройдет проверку!

IN-BAND ВОТЕРМАРКИНГ

Google SynthID & PerTh

Микроскопическая фазовая модуляция гармоник. Человек ее не слышит, но спектральный детектор гарантированно выявляет ИИ даже после сжатия в MP3 и наложения шума улицы!

Blast Radius в аудио: Зеленая, Желтая и Красная зоны

Четкие границы допустимого применения нейрозвука в enterprise-проектах.

ЗЕЛЕНАЯ ЗОНА (АВТОНОМНО)

Фоли, черновики и авторский дубляж

• Генерация предметных звуковых шумов (шаги, брызги, ветер).
• Черновые начитки внутренних презентаций.
• Авторский дубляж собственных видеороликов (кейс Creator Tools).
Риск ущерба: 0%. Полная автономность.

ЖЕЛТАЯ ЗОНА (HUMAN-IN-THE-LOOP)

Голосовые боты и реклама бренда

• Голосовые боты первой линии поддержки (обязателен аудиодисклеймер: *«С вами говорит AI»*).
• Коммерческие рекламные ролики (обязателен аудит звукорежиссера на артефакты).
Риск репутации: средний. Контроль человека.

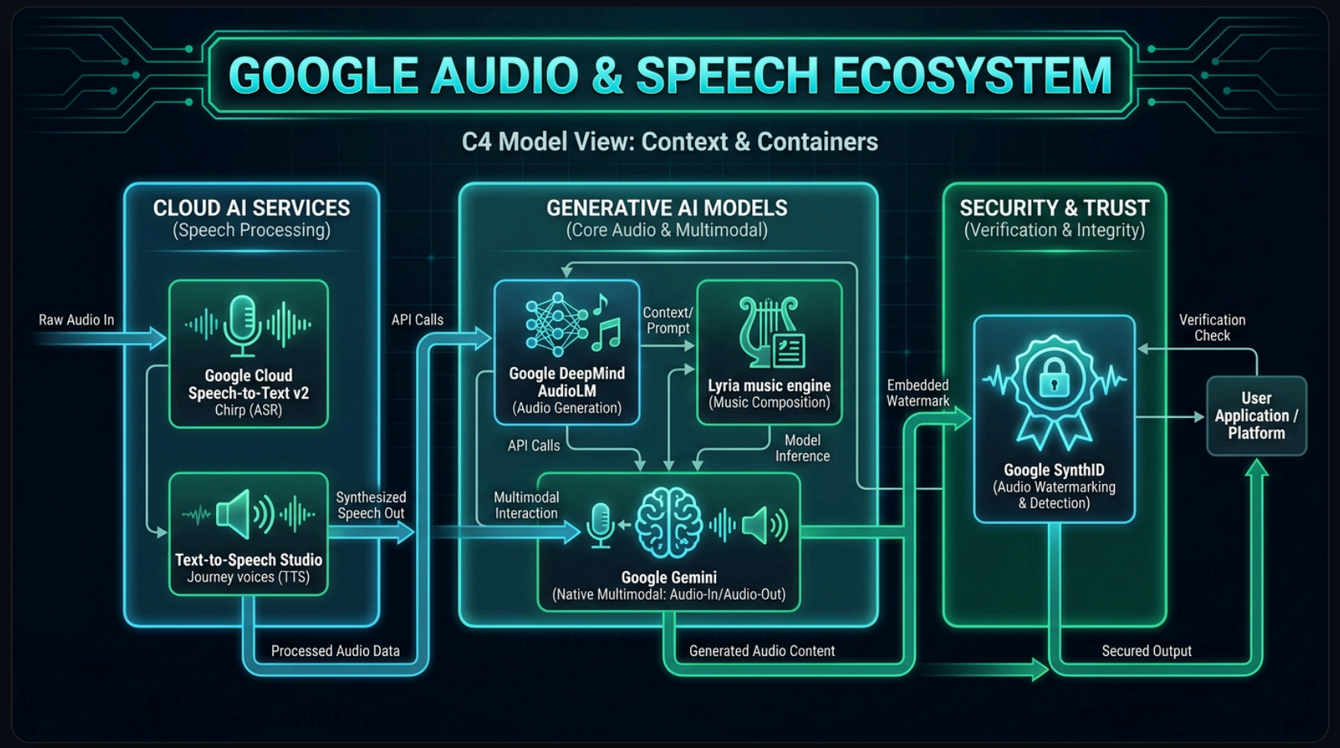
КРАСНАЯ ЗОНА (СТРОГИЙ ЗАПРЕТ)

Клонирование без согласия и суд

• Клонирование голоса живых людей без письменного юридического согласия.
• Генерация звонков от экстренных служб.
• Обход голосовой биометрии банков.
Категорически запрещено. Уголовная ответственность.

Что есть у Google со звуком: Cloud Studio, DeepMind и Gemini Native Audio

От классических облачных сервисов речи к фундаментальным моделям DeepMind и прямому нативному аудио в Gemini.



1. GOOGLE CLOUD SPEECH STUDIO

Journey Voices & Chirp (USM 2B)

TTS: Journey и Studio Voices — студийные 48 кГц голоса с тонкой SSML-настройкой.
ASR: Модель Chirp на базе 2-миллиардной Universal Speech Model распознает речь на 100+ языках в сложной акустике.

2. DEEPMIND AUDIO & LYRIA MUSIC

SoundStream, AudioLM & Lyria

DeepMind создал **SoundStream** (пионер RVQ нейрокодеков) и **Lyria** — флагманский движок генерации музыки (лежит в основе YouTube Dream Track и MusicFX).

3. GEMINI NATIVE MULTIMODAL AUDIO

Прямое Audio-In ➔ Audio-Out

Революция без каскада: Gemini воспринимает звук напрямую без текстового посредника — слышит сарказм, смех, шум улицы и отвечает нативным голосом! Плюс защита **SynthID**.

ПРАКТИЧЕСКИЙ R&D КЕЙС • CREATOR TOOLS

Speech-to-Speech и дубляж на 100+ языков с сохранением тембра

Как устроен конвейер локализации видео для YouTube-авторов: управление слоговым бюджетом и фазовый вокодер.

ЭТАП 1: ТАЙМИНГИ И РЕЧЬ

Whisper + VAD

Извлечение слов с точными временными границами и чистка пауз для исключения смещения монтажа.

ЭТАП 2: БЮДЖЕТ СЛОГОВ

LLM Syllable Budget

Промпт обязывает модель переводить с жестким ограничением числа слогов, предотвращая расползание хронометража.

ЭТАП 3: ТЕМБР СПИКЕРА

Voice Conversion

Синтез на целевом языке с сохранением оригинальных формант, высоты тона и дыхания автора.

ЭТАП 4: ПОДГОНКА В КАДР

Elastic Time-Stretch

Фазовый вокодер (Phase Vocoder) сжимает темп речи на ±15% без изменения высоты тона под склейки видеоряда.

Результат: Зритель в Бразилии или Германии слышит голос автора на своем языке с идеальным попаданием в монтажные склейки видеоряда!

ЭКВАТОР ЗАНЯТИЯ • 5 МИНУТ ОТДЫХА

Перезагрузка слухового аппарата

Слуховое восприятие требует колоссальных энергетических затрат мозга. Отключите звук, выпейте воды, дайте ушам отдохнуть.

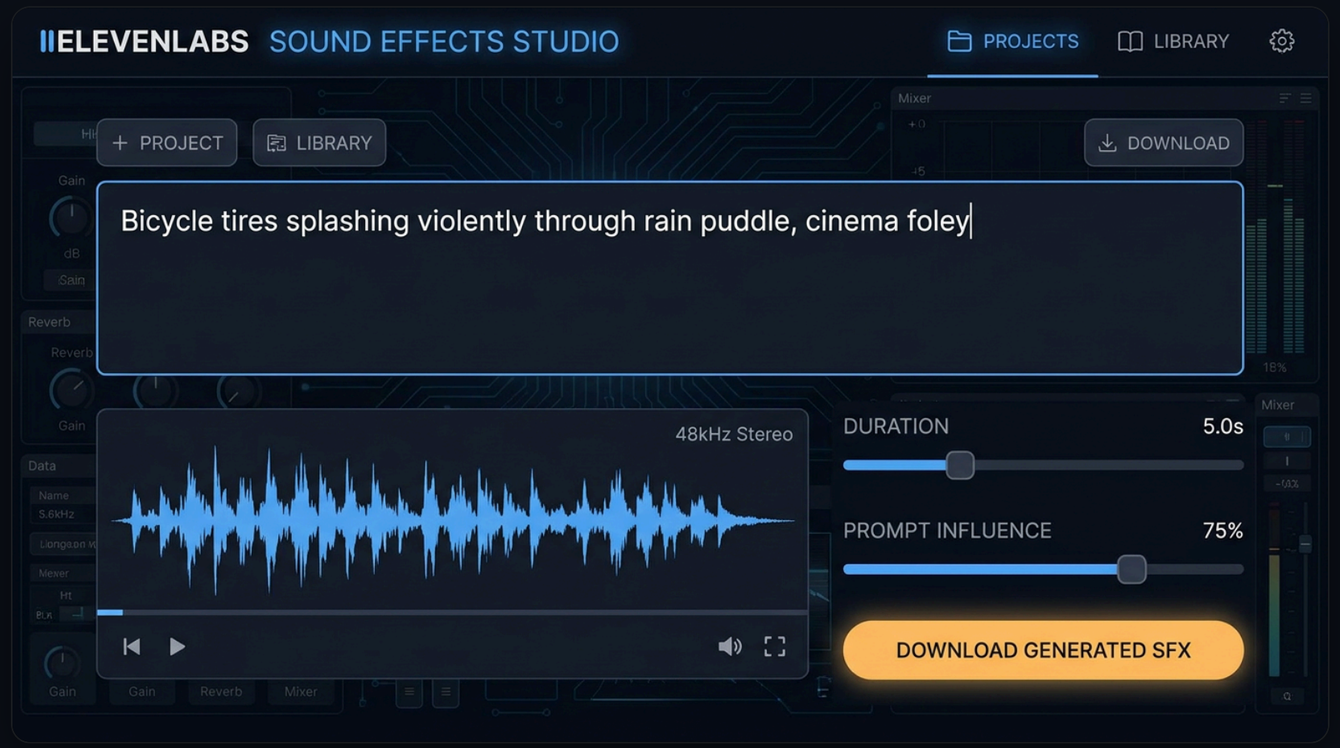
05:00

ВО ВТОРОЙ ПОЛОВИНЕ УРОКА:

Генерация шумов Foley (ElevenLabs SFX) • Звуковая матрица сториборда Giant Stories • Музыка в Suno v4 • Сведение 3 стемов со Sidechain Ducking на Python • Голосовые агенты реального времени (<300 мс).

Генерация фоли-шумов: предметный звук из текста по 3-слотовой формуле

Больше не нужно искать звуки в стоковых библиотеках. Модели генерируют физические шумы по детальному описанию материалов.



3-СЛОТОВАЯ ФОРМУЛА FOLEY-ПРОМПТА

[Источник] + [Действие] + [Пространство]

1. **Материал:** `rubber tires`, `ceramic mug`, `wet leather`.
2. **Кинетика движения:** `splashing violently`, `scraping stone`.
3. **Акустика пространства:** `outdoor alleyway reflections`, `hollow vault echo`.

ЭТАЛОННЫЙ ПРОМПТ ДЛЯ КУРЬЕРА GLOVO

Шоссейный велосипед под дождем

```
Bicycle rubber tires splashing violently through a deep rainwater puddle on wet cobblestone, fine water spray, quiet evening city background hum, cinema foley
```

САУНД-ДИЗАЙН СТОРИБОРДА • ПРОДАКШН-МАТРИЦА

Звуковая партитура сториборда: кейс Creator Tools Giant Stories

Как в реальном продакшне привязывать звуковые слои и музыкальные хуки к каждому 5-секундному видеошоту.

ШОТ #	КЛЮЧЕВОЙ ВИЗУАЛ СЦЕНЫ	ДИКТОР (VOICE-OVER)	FOLEY SFX LAYER	МУЗЫКАЛЬНЫЙ ХУК (MUSIC)
Шот 1	Опечатанный ящик 1929 года в подвале	«Никто не открывал его почти сто лет…»	Гул каменного подвала, редкие капли воды, шуршание крысы	Низкий контрабасовый дрон, 60 BPM, минор
Шот 2	Бурение на нефть в техасской жаре	«Они копали вслепую, теряя последние деньги…»	Стрекот цикад, скрежет лопаты о сухой камень, глухой стук	Пульсирующий суб-бас, редкий перкуссионный щелчок
Шот 3	Ротационный типографский пресс	«Но утренняя газета перевернула всё…»	Механический грохот шестерен, шипение краски, шелест бумаги	Нарастающее тремоло струнных, разгон темпа
Шот 4	Курьер Glovo мчит под дождем	«Горячий ужин вовремя, несмотря на шторм.»	Хлесткие брызги лужи из-под колес, шелест дождевика	Теплый lo-fi бит 74 BPM с приглушением под голос

> **Принцип киноинженерии:** Саунд-дизайн проектируется **до начала монтажа**. Каждый шот имеет точную акустическую партитуру из двух стемов: предметных шумов и музыкального хука.

Музыкальный продакшен: тумблер Instrumental, структурные теги и Demucs

Как генерировать управляемый фоновый саундтрек без конфликтов с голосом диктора.



ЖЕЛЕЗНОЕ ПРАВИЛО: INSTRUMENTAL ВКЛЮЧЕН

Никакого вокала под диктора!

Если в фоновой музыке звучит сгенерированный вокал, он немедленно вступит в частотный конфликт с речью диктора, сделав слова неразборчивыми.

ТЕГИ РАЗМЕТКИ В ОКНЕ ТЕКСТА (LYRICS)

Управление структурой аранжировки

Даже в инструментальном режиме пишем: `[Intro: Chillhop acoustic]` → `[Verse: 74 BPM]` → `[Build-up: Cello]` → `[Outro: Fade out]`.

РАЗДЕЛЕНИЕ НА СТЕМЫ (DEMUCS V4)

Изоляция дорожек в один клик

Разбивка трека на 4 изолированных файла: барабаны, бас, инструменты и вокал для независимой регулировки громкости.

Сведение 3 стемов и Sidechain Ducking: автоматическое приглушение музыки

Как собрать голос диктора, фоли-шумы и музыку в сбалансированный мастер без цифрового клиппинга.



СТЕМ 1 • ДИКТОРСКАЯ РЕЧЬ

-14 LUFS (Пики не выше -1.0 dBFS)

Центральный моно-канал, срез частот ниже 80 Гц для удаления низкочастотного гула микрофона.

СТЕМ 2 • ФОЛИ SFX

-18 LUFS (Стерео-панорама)

Синхронизация с видео: пик брызг колеса совпадает с кадром наезда на лужу.

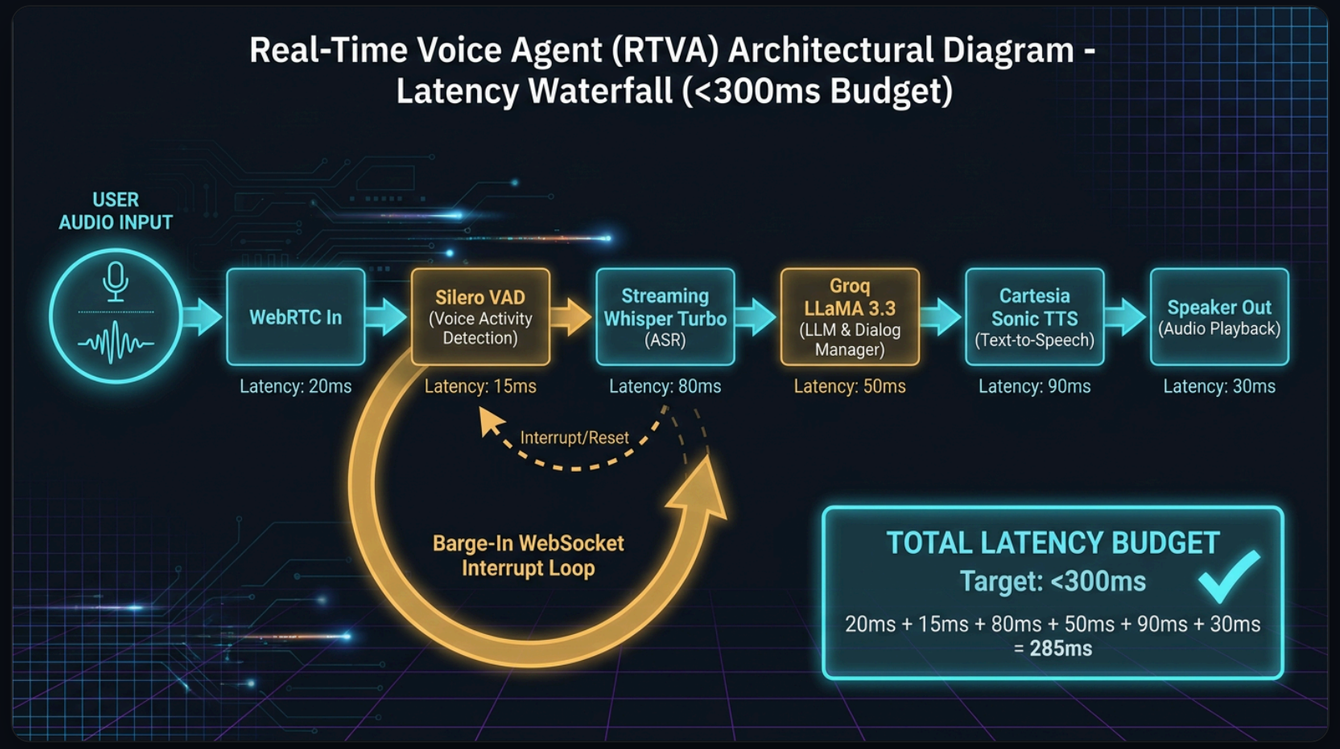
СТЕМ 3 • МУЗЫКА С SIDECHAIN DUCKING

Автоматическая просадка на -5 дБ

В паузах музыка звучит на -18 LUFS. Как только звучит голос, автоматика приглушает музыку до **-23 LUFS**. Реализуется в Python через библиотеку `pydub`.

Голосовые агенты реального времени: бюджет задержки <300 мс и Barge-In

Почему стандартные REST API неприменимы для диалога и как строится потоковый WebRTC-пайплайн.



РАСЧЕТ БЮДЖЕТА ЗАДЕРЖКИ: 285 МС

Укладываемся в порог восприятия

1. Вход аудио WebRTC: **20 мс**
2. Детекция конца речи Silero VAD: **15 мс**
3. Распознавание речи Whisper Turbo: **80 мс**
4. Время до 1-го токена Groq LLaMA 3.3: **50 мс**
5. Потоковый синтез Cartesia Sonic: **90 мс**
6. Буфер вывода в динамик: **30 мс**

ОБРАБОТКА ПЕРЕБИВАНИЯ (BARGE-IN)

Мгновенный обрыв генерации

Если пользователь заговорил поверх агента, локальный VAD посылает сигнал сброса по WebSocket, сервер мгновенно отменяет генерацию, и динамик замолкает за 20 мс.

ПРАКТИКА В КОДЕ • PYTHON API AUTOMATION

Автоматизация в Python: извлечение таймкодов Whisper и сведение стемов

Готовый пайплайн в Colab-ноутбуке: от транскрибации до автоматического наложения звука на видео.

БЛОК 1: ПОСЛОВНЫЕ ТАЙМКОДЫ WHISPER

```
import whisper

model = whisper.load_model("large-v3-turbo")
result = model.transcribe("voice.wav", word_timestamps=True)

for segment in result["segments"]:
    for word in segment["words"]:
        print(f"[{word['start']:.2f}s -> {word['end']:.2f}s] {word['word']}")
```

БЛОК 2: СВЕДЕНИЕ СО СТЕМАМИ В PYDUB

```
from pydub import AudioSegment

voice = AudioSegment.from_file("voice.wav") - 2  # -14 LUFS
sfx   = AudioSegment.from_file("sfx.wav") - 6    # -18 LUFS
music = AudioSegment.from_file("music.wav") - 12 # -22 LUFS

# Сведение слоев
mix = music.overlay(sfx).overlay(voice)
mix.export("final_soundtrack.wav", format="wav")
```

> **Ссылка на Colab:** Ноутбук `notebooks/L06_Speech_and_Audio_AI_Pipeline.ipynb` запускается за $0, содержит синтетические генераторы тестовых стемов и собирает итоговое видео с озвучкой.

КОНТРОЛЬ КАЧЕСТВА • AUDIO QA

Чеклист контроля качества звука: 4 критических дефекта

Инженерный чеклист аудита перед отправкой аудиоматериалов в продакшен.

1. ЦИФРОВОЙ КЛИППИНГ

Пики выше -1.0 dBFS

Симптом: Треск и хрип на громких согласных. **Лечение:** Лимитер на мастер-шине с потолком -1.0 dBFS.

2. ФАЗОВЫЙ ШУМ (3 КГЦ)

Гребенчатый телефонный фильтр

Симптом: Металлический звон нейросети. **Лечение:** Переключение вокодера на 48 кГц и срез резонансов эквалайзером.

3. ДРЕЙФ ИНТОНАЦИИ

Случайные скачки эмоций

Симптом: Диктор резко переходит с шепота на крик. **Лечение:** Повышение ползунка Stability до 0.45–0.50.

4. РАССИНХРОН ЛИПСИНКА

Задержка губ > 40 мс

Симптом: Губы смыкаются раньше звука согласных. **Лечение:** Сдвиг дорожки по таймкодам Whisper в видеоредакторе.

ПРАКТИЧЕСКОЕ ЗАДАНИЕ • ДОМАШКА №6

Домашнее задание №6: создание 3-слойного саундтрека для ролика из L05

Возьмите ваш 5-секундный видеоролик из Урока 05 и создайте для него полноценное звуковое сопровождение.

ЧТО НЕОБХОДИМО СДЕЛАТЬ

3 изолированных аудиостема

1. **Стем 1 (Голос диктора):** 1 фраза в ElevenLabs / Cartesia / Kokoro.
2. **Стем 2 (Foley SFX):** предметный шум по 3-слотовой формуле в ElevenLabs SFX.
3. **Стем 3 (Музыка):** инструментальный трек в Suno v4 / Udio с приглушением под голос.
4. Свести дорожки с видеороликом в единый файл `final_video_with_audio.mp4`.

СТРУКТУРА СДАЧИ В РЕПОЗИТОРИЙ GITHUB

```
genai-homeworks/L06/
├── 01_voiceover.mp3          # Диктор
├── 02_foley_sfx.mp3          # Шумы Foley
├── 03_music_bg.mp3           # Музыка
├── final_video_with_audio.mp4# Готовый ролик
├── audio_spec.md             # Спецификация
└── audio_qa.md               # Чеклист QA
```

Сдача: Добавить `ihar_rubanovich@epam.com` в коллабораторы вашего GitHub-репозитория. Ревью в течение 48 часов.

ФИНАЛ МОДУЛЯ 2 • ПЕРЕХОД К РАЗРАБОТКЕ ПО

Итоги Модуля 2: 4 инженерных закона звука и анонс Урока 07 (Copilot)

Модуль «Мультимодальность» завершен! Мы научились создавать картинки, видео и звук студийного качества.

4 ИНЖЕНЕРНЫХ ЗАКОНА ЗВУКА В GENAI

Главные выводы занятия

1. **VAD First:** Никогда не отправляйте сырое аудио в Whisper без Silero VAD.
2. **Пунктуация для дыхания:** Управляйте паузами и темпом диктора знаками препинания.
3. **Instrumental для видео:** Запрещайте вокал в фоновой музыке под речь диктора.
4. **Sidechain Ducking:** Музыка обязана проседать на -5 дБ, когда звучит голос.

АНОНС МОДУЛЯ 3 • УРОК 07: COPILOT ECOSYSTEM

ИИ в разработке программного обеспечения

- **Microsoft 365 Copilot & GitHub Copilot:** архитектура Semantic Index и Graph.
- **Agent Mode в VS Code:** автономное решение багов и терминальные агенты.
- **Реальный кейс:** EPAM CodeMie @ Dawn Foods (ускорение SDLC на 35%).