GENAI BASICS • УРОК 06 • МОДУЛЬ 2: МУЛЬТИМОДАЛЬНОСТЬ

Речь и аудио

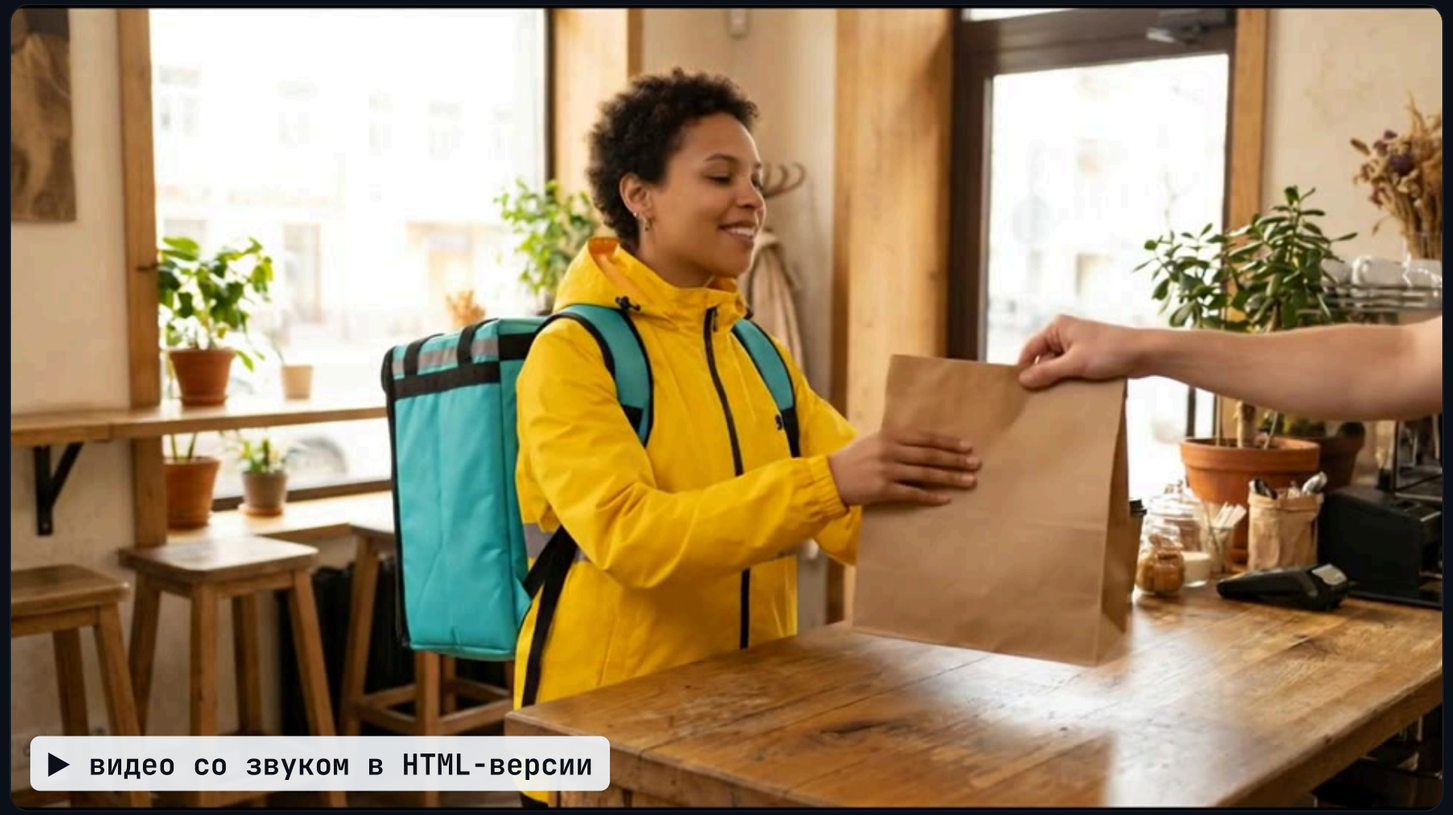
Озвучка, звук и музыка для ролика и проверка результата

Синтез речи, распознавание речи, голосовые агенты, музыка. ElevenLabs, OpenAI, Google, Suno, открытые модели. Данные на октябрь 2026.



ПРИМЕР

Ролик курьера из L05 с озвучкой, звуком и музыкой



3 реплики

8,7 с речи; голос из **открытой модели** синтеза речи (скачивается и работает локально) на обычном ноутбуке

3 дорожки

голос + звук, который Veo сгенерировал вместе с видео + музыка

-14,0 LUFS

громкость в единицах Loudness Units relative to Full Scale (LUFS), как её слышит ухо: 0 = максимум, -14 = норма стриминговых сервисов, -23 = ТВ

ПАЙПЛАЙН УРОКА 1 Сценарий 2 Текст для голоса 3 Голос 4 Шумы и музыка 5 Сведение 6 Проверка

ГДЕ ГЕНЕРИРОВАТЬ

Три уровня доступа к аудиомоделям: чат, веб-студия, программный интерфейс (API)

Чат-приложения

голос и музыка прямо в чате

ChatGPT | Gemini app

УПРАВЛЕНИЕ	голосовой режим и промпт; голос и длину почти не настроить
ОПЛАТА	подписка
ДЛЯ ЧЕГО	попробовать, черновик музыки
НАЧАТЬ С	**Gemini app (Lyria 3.5)**

Веб-студии

интерфейс для звука

ElevenLabs | Suno | Google AI Studio

УПРАВЛЕНИЕ	библиотека голосов, настройки, звуковые эффекты, музыка, дубляж
ОПЛАТА	кредиты; бесплатный лимит небольшой
ДЛЯ ЧЕГО	озвучка ролика, домашнее задание
НАЧАТЬ С	**ElevenLabs**

API

код и автоматизация

OpenAI Audio | Gemini API | Google Cloud / Azure Speech | ElevenLabs API | Deepgram / AssemblyAI

УПРАВЛЕНИЕ	всё как параметры запроса; пакетная обработка, живой звук
ОПЛАТА	за символ, токен или минуту
ДЛЯ ЧЕГО	пайплайны, продукты, агенты
НАЧАТЬ С	**Gemini API**

Четвёртый путь: открытые модели (файлы модели скачиваются и запускаются на своём компьютере). Whisper (распознавание), Kokoro и Piper (синтез речи), MusicGen (музыка). $0 за минуту, но железо, установка и лицензии на вас. Наш пример сделан так.

КАРТА ЗАДАЧ

Четыре задачи аудио-ИИ: что на входе и что на выходе

текст → голос

Синтез речи (text-to-speech, TTS)

озвучка роликов, уведомления, аудиокниги. **Сегодня: голос курьера.**

голос → текст

Распознавание речи (speech-to-text, STT)

субтитры, протоколы встреч, поиск по звонкам. Второе название: automatic speech recognition (ASR). **Сегодня: проверка озвучки.**

голос → голос

Речь в речь (speech-to-speech)

голосовые агенты, синхронный перевод, дубляж. Отвечает в реальном времени.

текст → музыка, шумы

Музыка и звуковые эффекты

подложка, джинглы, шумы. Плюс звук, который **видеомодель** делает сама (L05).

ПРИНЦИП РАБОТЫ

Как модель синтеза речи превращает текст в звук

Текст
«Шесть сорок две.»
→
Модель
предсказывает аудиотокены
→
Аудиотокены
12–50 в секунду
→
Декодер
токены → отсчёты
→
Звук
24 000–48 000 чисел в секунду

РЕПЛИКА 1 НАШЕГО СЦЕНАРИЯ, РЕАЛЬНАЯ ФОРМА ВОЛНЫ · 3,8 С



Сколько данных: секунда звука в студийном качестве = 48 000 чисел (Gemini отдаёт 24 000). Модель работает со сжатым видом: Gemini считает **25 аудиотокенов в секунду**, MusicGen **50 шагов**.

Чего нет внутри: словаря правил чтения. Модель выучила, как текст обычно звучит. Поэтому ошибается на **числах, именах, сокращениях**.

МОСТ ИЗ L05

Звук внутри видеомодели: что Veo 3.1 сгенерировал сам

Шот 1, кафе промпт без реплик



▶ звук в HTML-версии

РАСПОЗНАНО В ЗВУКЕ VEO

“Here's your order. Thank you. Have a good day.”

Неудачный клип из L05 в промпте тоже нет реплик



▶ звук в HTML-версии

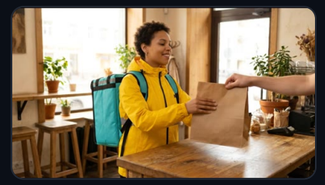
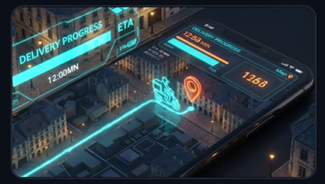
РАСПОЗНАНО В ЗВУКЕ VEO

“Continue straight for 200 meters, then your destination is on the left.”

Даёт: шум улицы, дождь, шаги, синхронно с картинкой. Но платим за него: Veo 3.1 в Vertex AI со звуком $0.40/с, без звука $0.20/с.

Не даёт: точный текст, один голос на все шоты, отдельные дорожки. Реплики модель **придумывает сама**.

Сценарий озвучки: текст, время и бюджет слов на каждый шот

ШОТ	ВРЕМЯ	ЗАКАДРОВЫЙ ТЕКСТ	СЛОВ / ДЛИНА	ШУМЫ
	0–8 с	«6:42. Заказ 417 забран, ещё горячий.»	9 / 3,8 с	кафе: шум зала, чашки
	7,5–15,5 с	«На проспекте дождь. Маршрут в обход моста.»	7 / 2,5 с	дождь, шины по лужам
	15–23 с	«До двери 12 минут. Анна уже в пути.»	8 / 2,3 с	тихий интерфейсный звук

Музыка: одна подложка на все шоты, лоу-фай, без вокала

≈ 2,8 слова/с

измерено на нашей озвучке; планируйте **2–2,5 слова в секунду**, чтобы осталась пауза

Шот 8 с ≈ 6 с речи (по секунде тишины у склеек) **× 2–2,5 слова/с = 12–15 слов.** На русском планируйте 1,8–2,2 слова/с. Не влезает: сокращаем текст, голос не ускоряем.

Текст для голоса: числа словами, стиль отдельной инструкцией

ЧТО ВИДИТ ЗРИТЕЛЬ → ЧТО ЧИТАЕТ МОДЕЛЬ

СЦЕНАРИЙ	ТЕКСТ ДЛЯ ГОЛОСА	ПОЧЕМУ
6:42	Шесть сорок две	время: «шесть сорок две» или «восемнадцать сорок две»?
417	четыреста семнадцать	решаем заранее: число или номер по цифрам «четыре один семь»
12 мин	двенадцать минут	сокращения модель может прочитать по буквам

СТИЛЬ ЗАДАЁТСЯ ОТДЕЛЬНОЙ ИНСТРУКЦИЕЙ

```
Инструкция: Спокойный, дружелюбный диспетчер. Средний
темп. Короткая пауза после каждой фразы.
Текст: Шесть сорок две. Заказ четыреста семнадцать
забран, ещё горячий.
```

- **OpenAI:** отдельное поле `instructions`; **Gemini 3.8:** отдельное поле `style`, короткие звуки тегами: `<sigh>`.
- **ElevenLabs v3:** теги в тексте, например `[whispers]`.
- **Словарь произношений** для имён и терминов (ElevenLabs, Google, Azure).

Три источника голоса: библиотека, описание, клон

Готовый голос

Вход: выбрать из библиотеки сервиса

✓ **лицензия сервиса**

Gemini: 30 голосов; OpenAI: 13; наш пример: Kokoro `af_heart`, Piper `dmitri`

Голос по описанию

Вход: текст «молодой голос, лёгкая хрипотца, быстрый темп»

! проверить похожесть на известных людей

ElevenLabs Voice Design, Gemini API voice design

Клон голоса

Вход: запись реального человека, от 3–10 с до 30+ мин

✗ **только с письменного согласия владельца**

сервисы требуют запись фразы согласия или проверку голосом

Перед выбором: прогоните через голос самые сложные слова сценария (имена, числа). Голос, который их искажает, отклоняем.

Шумы и музыка: промпт, длина и лицензия трека

Наша музыкальная подложка MusicGen-small · 23 с



▶ звук в HTML-версии

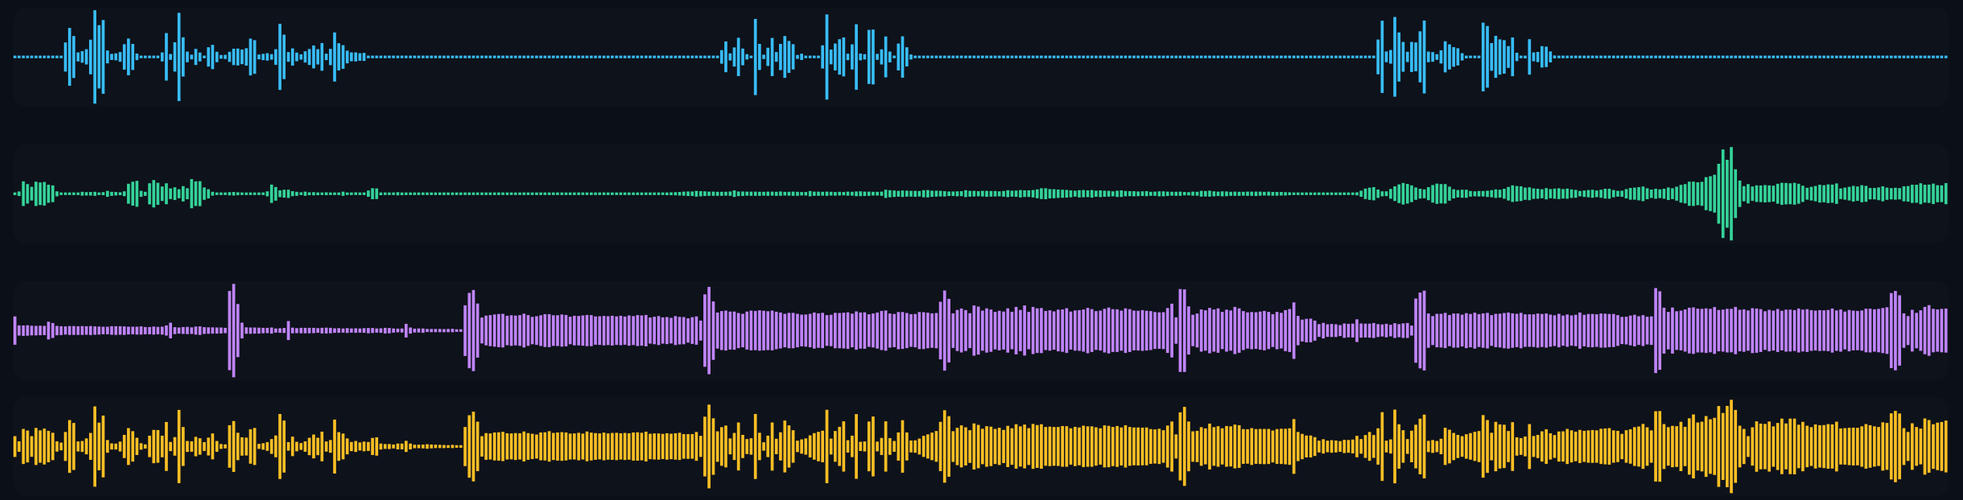
ПРОМПТ

```
calm lo-fi hip hop beat, soft electric piano, light rain mood, 85 bpm, no vocals
```

Веса MusicGen: лицензия **Creative Commons «с указанием авторства, некоммерческая» (CC BY-NC 4.0)**. Для урока можно, для клиента нет.

СЕРВИС	ДЛИНА	КОММЕРЧЕСКОЕ ИСПОЛЬЗОВАНИЕ
Suno v6 песни	песня	только платные тарифы
Lyria 3.5 Gemini app, Gemini API	пара минут	не указано; метка SynthID на каждом треке
ElevenLabs Music музыка	3 с – 5 мин	«почти любое», по тарифу
ElevenLabs Sound Effects шумы	≤ 30 с	по тарифу

Сведение: голос сверху, фон приглушён



- **Приглушение (ducking):** фон автоматически тише, пока звучит голос.
- **Громкость:** -14 Loudness Units relative to Full Scale (LUFS) для Spotify и других стриминговых сервисов, -23 LUFS для эфира (стандарт Европейского вещательного союза EBU R128).
- **Пик:** истинный пик (true peak), самая высокая точка волны, включая промежутки между отсчётами; не выше -1 дБ (dBTP), иначе сжатие в MP3 или AAC даст искажения.

Без кода, Audacity (бесплатно): 1) импорт звука ролика, музыки и реплик; 2) фон: *Effect › Auto Duck*; 3) *Mix and Render* → *Loudness Normalization* -14 LUFS → *Limiter* -1 dB; 4) WAV в CapCut или Clipchamp, звук клипа выключить.

С кодом: ffmpeg (sidechaincompress + loudnorm), полная команда в make_audio.py.

Проверка озвучки распознаванием речи

СЦЕНАРИЙ

6:42. Заказ 417 забран, ещё горячий. На проспекте дождь. Маршрут в обход моста. До двери 12 минут. Анна уже в пути.

ЧТО УСЛЫШАЛ WHISPER (SMALL, НА НОУТБУКЕ)

~~Часть 42.~~ Заказ **417** забран. Ещё горячий. На проспекте дождь. Маршрут в обход моста. До двери **12 минут.** ~~Оно~~ уже в пути.

- **«Часть 42» вместо «Шесть сорок две»**: причина в голосе: проглатывает «ш»
- **«Оно» вместо «Анна»**: причина в голосе: неверно читает имя

14,3%

частота ошибок в словах (word error rate, WER) = (замены + пропуски + вставки) / слов в сценарии

2 / 4 → 2 / 4

критичных слов верно: автоматически → после прослушивания (время, номер, минуты, имя)

Без кода: ElevenLabs Speech to Text, Google AI Studio (промпт «Transcribe verbatim. Do not correct mistakes.»), Buzz (Whisper для компьютера).

АРХИТЕКТУРА

Три архитектуры речевых систем: файл, поток, голосовой агент

Файл (batch)
субтитры, протоколы, наша проверка

запись → распознавание → текст с таймкодами

от секунд до минут
ждать можно

Поток (streaming)
живые субтитры, заметки на встрече

микрофон → короткие кусочки → черновой текст → итоговый

доли секунды
черновик может измениться

Речь в речь (realtime)
голосовой агент, перевод

голос → конец фразы? → модель + инструменты → голос

счёт на секунды
перебивание, тишина, задержка

Голосовой агент двумя способами: цепочка «распознавание → языковая модель → синтез» (проще отлаживать) или одна модель «речь в речь» (быстрее, естественнее). Строим агентов в модуле 4.

РЫНОК • ОКТЯБРЬ 2026

Аудиомодели по задачам: коммерческие и открытые

Синтез речи (TTS) текст → голос	ElevenLabs v4 / v3 · Gemini 3.8 Flash TTS · OpenAI gpt-4o-mini-tts (до 06.01.2027) · Kokoro-82M Apache-2.0 · Qwen3-TTS Apache-2.0
Распознавание речи (STT, ASR) голос → текст	OpenAI gpt-transcribe · ElevenLabs Scribe v2 · AssemblyAI Universal-3.5 Pro · Whisper large-v3-turbo MIT · Qwen3-ASR Apache-2.0
Речь в речь голосовые агенты, перевод	OpenAI gpt-realtime-2.1 · Gemini Live API · ElevenLabs Agents
Музыка и шумы текст → музыка, шумы	Suno v6 · Lyria 3.5 · ElevenLabs Music / Sound Effects · MusicGen CC BY-NC

Точность распознавания (английский): лучшие коммерческие ≈ 4–5% ошибок в словах, лучшие открытые ≈ 5–6%, Whisper large-v3 ≈ 7,8%. Open ASR Leaderboard, 09.10.2026.

Срок жизни моделей короткий: OpenAI отключает tts-1 и gpt-4o-mini-tts 06.01.2027, whisper-1 и gpt-4o-transcribe 26.02.2027. Имя модели держим в настройках.

Зелёная рамка: открытая модель и её лицензия. **MIT, Apache-2.0:** можно в коммерции, сохраняя текст лицензии. **CC BY:** можно в коммерции с указанием автора. **CC BY-NC:** только некоммерческое. У голосов и датасетов бывают свои лицензии.

ПЕРЕРЫВ

5 минут на кофе и отдых для ушей

05:00

Дальше: код, стоимость, приёмка, риски и домашнее задание.

ДЛЯ СПРАВКИ • GOOGLE-GENAI + WHISPER

Код: синтез речи через Gemini и проверка распознаванием через Whisper

```python
from google import genai
from google.genai import types

client = genai.Client()  # ключ из GEMINI_API_KEY
r = client.models.generate_content(
    model="gemini-3.8-flash-tts",
    contents=types.Content(role="user", parts=[types.Part(
        text="Six forty-two. Order four one seven.",
        speech_metadata=types.SpeechMetadata(
            style="calm, friendly dispatcher"))]),
    config=types.GenerateContentConfig(
        response_modalities=["AUDIO"],
        speech_config=types.SpeechConfig(
            voice_config=types.VoiceConfig(
                prebuilt_voice_config=types.PrebuiltVoiceConfig(
                    voice_name="Kore")))))
audio = r.candidates[0].content.parts[0].inline_data  # уже WAV
open("line1.wav", "wb").write(audio.data)
```

> **Синтез:** та же идея, что в L03, но ответ — звук: готовый WAV, 16 бит, 24 кГц, моно. Стиль голоса — в отдельном поле `style`: Gemini 3.8 читает текст дословно.

ПРОВЕРКА, ЛОКАЛЬНО И БЕСПЛАТНО

```python
from faster_whisper import WhisperModel
m = WhisperModel("small")
segs, _ = m.transcribe("mix.wav")
print(" ".join(s.text for s in segs))
```

Программный интерфейс Gemini (API), октябрь 2026. Полный пайплайн урока: `deck_v2/make_audio.py`.

Стоимость аудио: секунда, минута, час

Пересчёт: **1 минута речи ≈ 1000 символов** (так считает ElevenLabs). Списочные цены на 12.10.2026.

МОДЕЛЬ · КАК СЧИТАЮТ	1 С	1 МИН	1 ЧАС
Gemini 3.8 Flash TTS Синтез · $9 / 1 млн аудиотокенов	$0.00022	$0.0135	**$0.81**
ElevenLabs v3 / v4 Синтез · $0.08 / 1000 символов	$0.00133	$0.08	**$4.80**
OpenAI gpt-transcribe Распознавание · $0.0045 / мин	$0.00007	$0.0045	**$0.27**
ElevenLabs Scribe v2 Распознавание · $0.22 / час	$0.00006	$0.00367	**$0.22**
OpenAI gpt-live-1 Речь в речь · $0.05 / мин + модель	$0.00083	$0.05	**$3.00**
ElevenLabs Music Музыка · $0.15 / мин	$0.0025	$0.15	**$9.00**

≈ 1 цент

озвучка нашего ролика: 149 символов на ElevenLabs v3; у нас $0 на открытых моделях

$4.80 = 12 с

час голоса ElevenLabs стоит как 12 секунд видео Veo 3.1 (L05: $0.40/с)

ПРИЁМКА

Чек-лист приёмки озвучки

Это же критерии оценки домашнего задания. Справа реальный результат нашей версии.

1	**Слова** совпадают со сценарием: распознавание + список критичных слов	✗
2	**Произношение** имён, чисел, терминов: проверено на слух	✗
3	**Тайминг:** реплика влезает в шот, не режется склейкой	✓
4	**Сведение:** голос разборчив, фон приглушён, нет чужой речи	✗
5	**Громкость** -14 ± 1 LUFS; истинный пик ≤ -1 дБ (dBTP)	✓
6	**Права:** лицензия голоса и музыки, согласие, пометка «создано ИИ»	!

-14,0 LUFS

пик -1,1 dBTP. Без кода: Youlean Loudness Meter или измеритель громкости в DaVinci Resolve, смотрим Integrated и True Peak

> **Не принято:** голос искажает «Анна» и «шесть сорок две»; в начале слышна английская реплика Veo, которую распознавание на русском пропустило. Исправление: другой голос, звук шота 1 заглушить на 0–3 с.

Доказательства в ДЗ: 1 → transcript.txt и таблица критичных слов · 2, 4 → заметки на слух с таймкодами · 3 → script.md · 5 → скриншот измерителя · 6 → таблица лицензий и пометка «создано ИИ»

РИСКИ

Риски и согласие на голос: клонирование, маркировка, закон

- **Готовый или придуманный голос**
  можно, по лицензии сервиса, с пометкой «создано ИИ»
- **Свой голос, клон коллеги**
  письменное согласие: для чего, где, как долго, как отозвать
- **Голос клиента, руководителя, публичного лица**
  нельзя без письменного согласия и юристов; голосом обманывают

КАК СЕРВИСЫ ПРОВЕРЯЮТ СОГЛАСИЕ НА КЛОН

- **OpenAI, Google:** владелец голоса записывает фиксированную фразу согласия.
- **ElevenLabs Professional:** владелец читает проверочный текст; Instant: только галочка.
- **Azure:** доступ к клонам только по заявке, запись согласия сверяют с голосом.
- **Открытые модели** (Qwen3-TTS, Chatterbox): клон по 3–10 с, **без проверок**.

EU AI Act, ст. 50: с 2 августа 2026 синтетический звук и дипфейки нужно помечать; штраф до €15 млн или 3% оборота. **OpenAI** требует сообщать слушателю, что голос сгенерирован. **Google** ставит невидимую метку SynthID во весь звук своих моделей.

ПРАКТИКА

Домашнее задание 6: озвучить свой ролик из L05



Ваш ролик из L05

Трек А (товар) или Б (курьер, кейс Glovo). Нет ролика: возьмите курьерский ролик урока. В ролике нет звука: фон из шумов или музыки.

```
genai-homeworks/L06/
├── script.md       # текст, текст для голоса, время
├── audio/          # реплики, подложка, сведение
├── final_voiced.mp4
├── transcript.txt # распознанный текст
├── audio_spec.md
└── audio_qa.md
```

1. **Сценарий**: 3 реплики, бюджет слов, критичные слова → `script.md`
2. **Текст для голоса**: числа и имена словами, инструкция стиля
3. **Голос** в двух сервисах без кода (например, ElevenLabs и Google AI Studio), выбрать лучший
4. **Фон**: звук видеомодели, шумы или музыка, с лицензией
5. **Сведение** в `final_voiced.mp4` : -14 ± 1 LUFS, скриншот измерителя
6. **Проверка**: `transcript.txt` , чек-лист слайда 18 → `audio_qa.md` , стоимость → `audio_spec.md`

Ревьюер: **ihar_rubanovich@epam.com**. Только свой голос или голоса из библиотек; чужие голоса не клонируем.

ИТОГИ

Итоги урока

1. **Сценарий с бюджетом слов**
   2–2,5 слова в секунду, по секунде тишины у склеек
2. **Текст для голоса отдельно**
   числа, время, имена словами; стиль отдельной инструкцией
3. **Голос с лицензией и согласием**
   клон только с письменного согласия владельца
4. **Фон с известной лицензией**
   звук видео, шумы или музыка; MusicGen и бесплатный Suno некоммерческие
5. **Сведение к −14 LUFS**
   голос сверху, фон приглушён, истинный пик ≤ -1 дБ (dBTP)
6. **Проверка распознаванием и на слух**
   частота ошибок + критичные слова



Урок 07: GitHub, Microsoft 365 и Copilot. Из генерации контента переходим к ИИ в рабочих инструментах.