GENAI BASICS • УРОК 06 • МОДУЛЬ 2: МУЛЬТИМОДАЛЬНОСТЬ

Речь и аудио

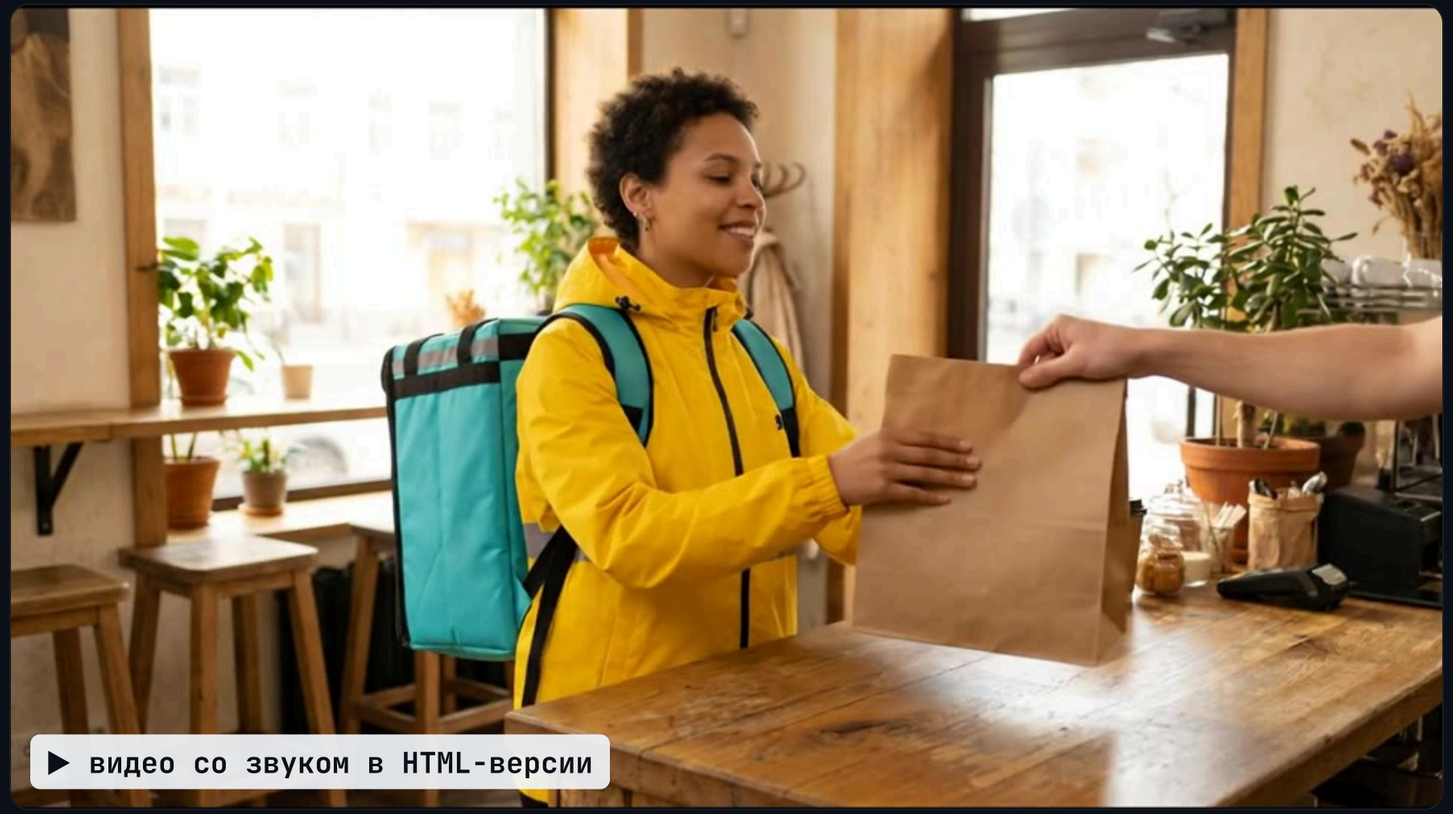
Озвучка, звук и музыка для ролика и проверка результата

Синтез речи, распознавание речи, голосовые агенты, музыка. ElevenLabs, OpenAI, Google, Suno, открытые модели. Данные на октябрь 2026.



ПРИМЕР

Ролик курьера из L05 с озвучкой, звуком и музыкой



3 реплики

8,6 с речи; голос из **открытой модели** синтеза речи (скачивается и работает локально) на обычном ноутбуке

3 дорожки

голос + звук, который Veo сгенерировал вместе с видео + музыка

−14,2 LUFS

громкость как на Spotify и YouTube (их норма −14). Подробно на шаге 5

ПАЙПЛАЙН УРОКА

1 Сценарий · 2 Текст для голоса · 3 Голос · 4 Шумы и музыка · 5 Сведение · 6 Проверка

Не слышите звук ролика? Напишите в чат.

ГДЕ ГЕНЕРИРОВАТЬ

Начинаем в веб-студии, автоматизируем через API

ВЕБ-СТУДИЯ · GOOGLE AI STUDIO → GENERATE SPEECH · БЕСПЛАТНО



1. **Текст** реплики
2. **Стиль** отдельно: «спокойный диспетчер»
3. **Модель** Gemini 3.8 Flash TTS
4. **Готовый звук**: 5 с, скачать WAV

API · КНОПКА GET CODE → ГОТОВЫЙ PYTHON, ГЛАВНАЯ СТРОКА:

```
client.models.generate_content(model="gemini-3.8-flash-tts", contents=...)
```

Ещё два пути: **чат** (ChatGPT, Gemini app: попробовать, голос почти не настроить) и **открытые модели на своём компьютере** (Kokoro, Piper, Whisper, MusicGen: $0, но железо и лицензии на вас; так сделан наш пример).

КАРТА ЗАДАЧ

Четыре задачи аудио-ИИ: что на входе и что на выходе

текст → голос

Синтез речи (text-to-speech, TTS)

озвучка роликов, уведомления, аудиокниги. **Сегодня: голос курьера.**

В нашем примере: **Kokoro (EN) и Piper (RU)**

голос → текст

Распознавание речи (speech-to-text, STT)

субтитры, протоколы встреч, поиск по звонкам. Второе название: automatic speech recognition (ASR). **Сегодня: проверка озвучки.**

В нашем примере: **Whisper small, проверка озвучки**

голос → голос

Речь в речь (speech-to-speech)

голосовые агенты, синхронный перевод (в реальном времени), дубляж

В нашем примере: **— (агентов строим в модуле 5 (L11–L13))**

текст → музыка, шумы

Музыка и звуковые эффекты

подложка, джинглы, шумы. Плюс звук, который **видеомодель** делает сама (L05).

В нашем примере: **MusicGen, музыкальная подложка**

ПРИНЦИП РАБОТЫ

Модель угадывает, как звучит текст, поэтому путает числа и имена

Текст
«Шесть сорок две.»

→

Модель
угадывает кусочки звука

→

Кусочки звука
аудиотокены, 12–50 шагов в секунду

→

Декодер
собирает волну

→

Звук
24 000–48 000 чисел в секунду

РЕПЛИКА 1 НАШЕГО СЦЕНАРИЯ, РЕАЛЬНАЯ ФОРМА ВОЛНЫ · 3,8 С



Сжатие: секунда звука — это десятки тысяч чисел. Модель работает с короткой «выжимкой» из нескольких десятков кусочков, декодер разворачивает её обратно в волну.

Чего нет внутри: словаря правил чтения. Модель выучила, как текст обычно звучит. Поэтому ошибается на **числах, именах, сокращениях**.

МОСТ ИЗ L05

Veo сам придумывает реплики: точные слова делаем отдельным голосом

Шот 1, кафе промпт без реплик



▶ звук в HTML-версии

РАСПОЗНАНО В ЗВУКЕ VEO

“Here's your order. Thank you. Have a good day.”

Неудачный клип из L05 в промпте тоже нет реплик



▶ звук в HTML-версии

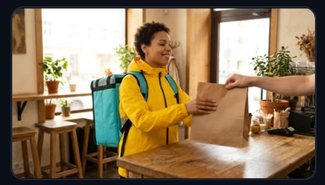
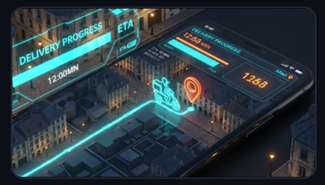
РАСПОЗНАНО В ЗВУКЕ VEO

“Continue straight for 200 meters, then your destination is on the left.”

Даёт: шум улицы, дождь, шаги, синхронно с картинкой. Но платим за него: Veo 3.1 в Vertex AI со звуком $0.40/с, без звука $0.20/с.

Не даёт: точный текст, один голос на все шоты, отдельные дорожки. Реплики модель **придумывает сама**.

Сценарий озвучки: текст, время и бюджет слов на каждый шот

ШОТ	ВРЕМЯ	ЗАКАДРОВЫЙ ТЕКСТ	СЛОВ / ДЛИНА	ШУМЫ
	0–8 с	«6:42. Заказ 417 забран, ещё горячий.»	9 / 3,8 с	кафе: шум зала, чашки
	7,5–15,5 с	«На проспекте дождь. Маршрут в обход моста.»	7 / 2,5 с	дождь, шины по лужам
	15–23 с	«До двери 12 минут. Анна уже в пути.»	8 / 2,3 с	тихий интерфейсный звук

Музыка: одна подложка на все шоты, лоу-фай, без вокала

≈ 2,8 слова/с

наш голос: быстрее плана; влезает только потому, что реплики короткие. План: **≈ 2 слова/с**

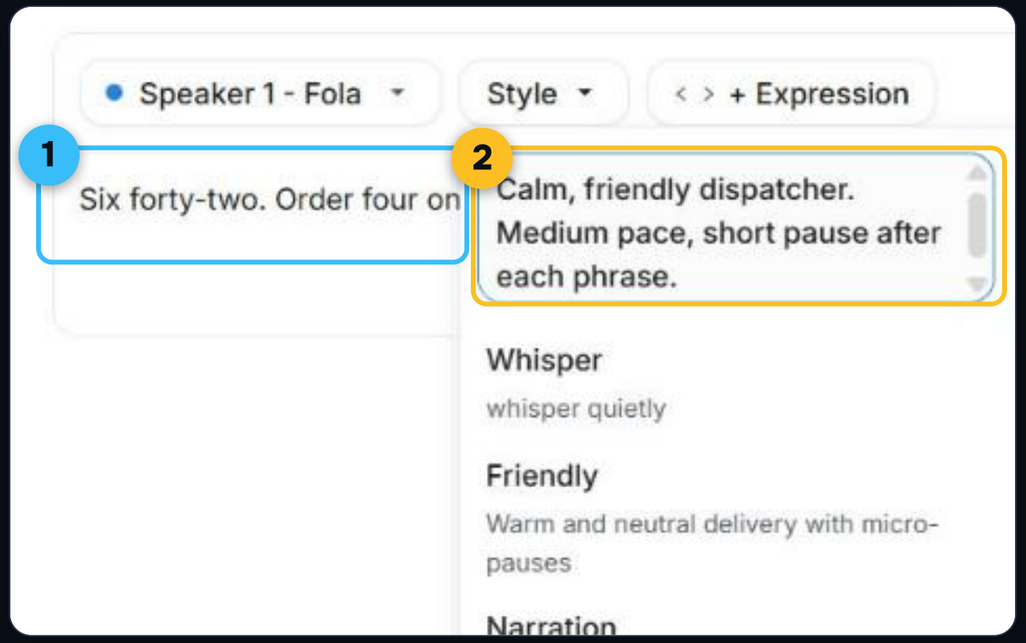
Шот 8 с ≈ 6 с речи (секунда тишины у склеек) **× 2 слова/с ≈ 12 слов.** Слова считаем в тексте для голоса: «шесть сорок две» = 3 слова. Не влезает: сокращаем текст, голос не ускоряем.

Текст для голоса: числа словами, стиль отдельной инструкцией

ЧТО ВИДИТ ЗРИТЕЛЬ → ЧТО ЧИТАЕТ МОДЕЛЬ

СЦЕНАРИЙ	ТЕКСТ ДЛЯ ГОЛОСА	ПОЧЕМУ
6:42	Шесть сорок две	время, счёт матча или пропорция?
417	четыреста семнадцать	для номера заказа по-русски обычно читают числом; решаем заранее, а не модель
12 мин	двенадцать минут	сокращения модель может прочитать по буквам

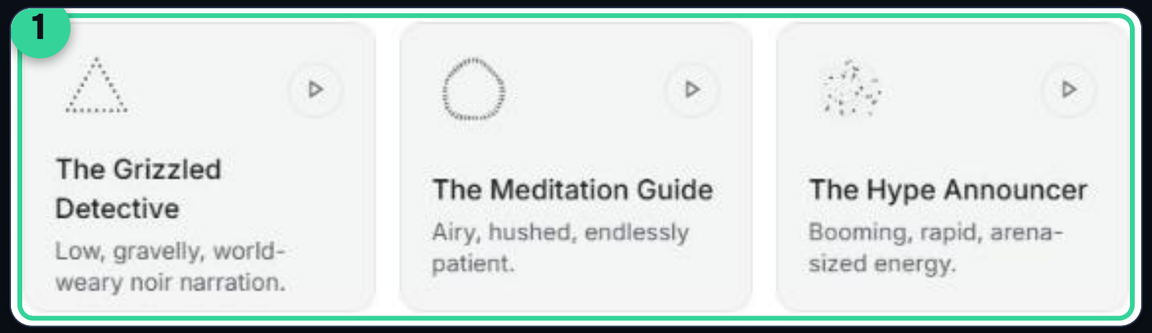
СТИЛЬ ЗАДАЁТСЯ ОТДЕЛЬНОЙ ИНСТРУКЦИЕЙ



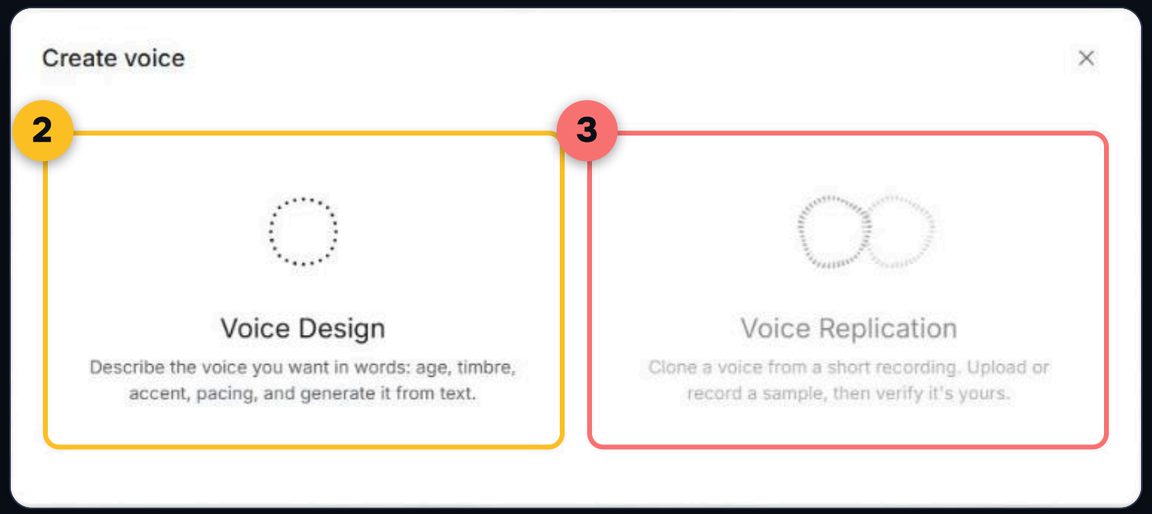
1. **Текст**: только то, что надо произнести
2. **Стиль** отдельным полем (Google AI Studio). В ElevenLabs v3 — теги в тексте: `[whispers]`

Три источника голоса: библиотека, описание, клон

GOOGLE AI STUDIO · БИБЛИОТЕКА ГОЛОСОВ



CREATE NEW VOICE · ДВА НОВЫХ ПУТИ



1. **Готовый голос** из библиотеки: лицензия сервиса
2. **Голос по описанию**: «молодой, с хрипотцой»; проверить, что не похож на знаменитость
3. **Клон** по записи: сервис просит доказать, что голос ваш

> **Перед выбором:** прогоните через голос самые сложные слова сценария (имена, числа). Голос, который их искажает, отклоняем.

Шумы и музыка: главное — лицензия трека

Наша музыкальная подложка MusicGen-small · 23 с



▶ звук в HTML-версии

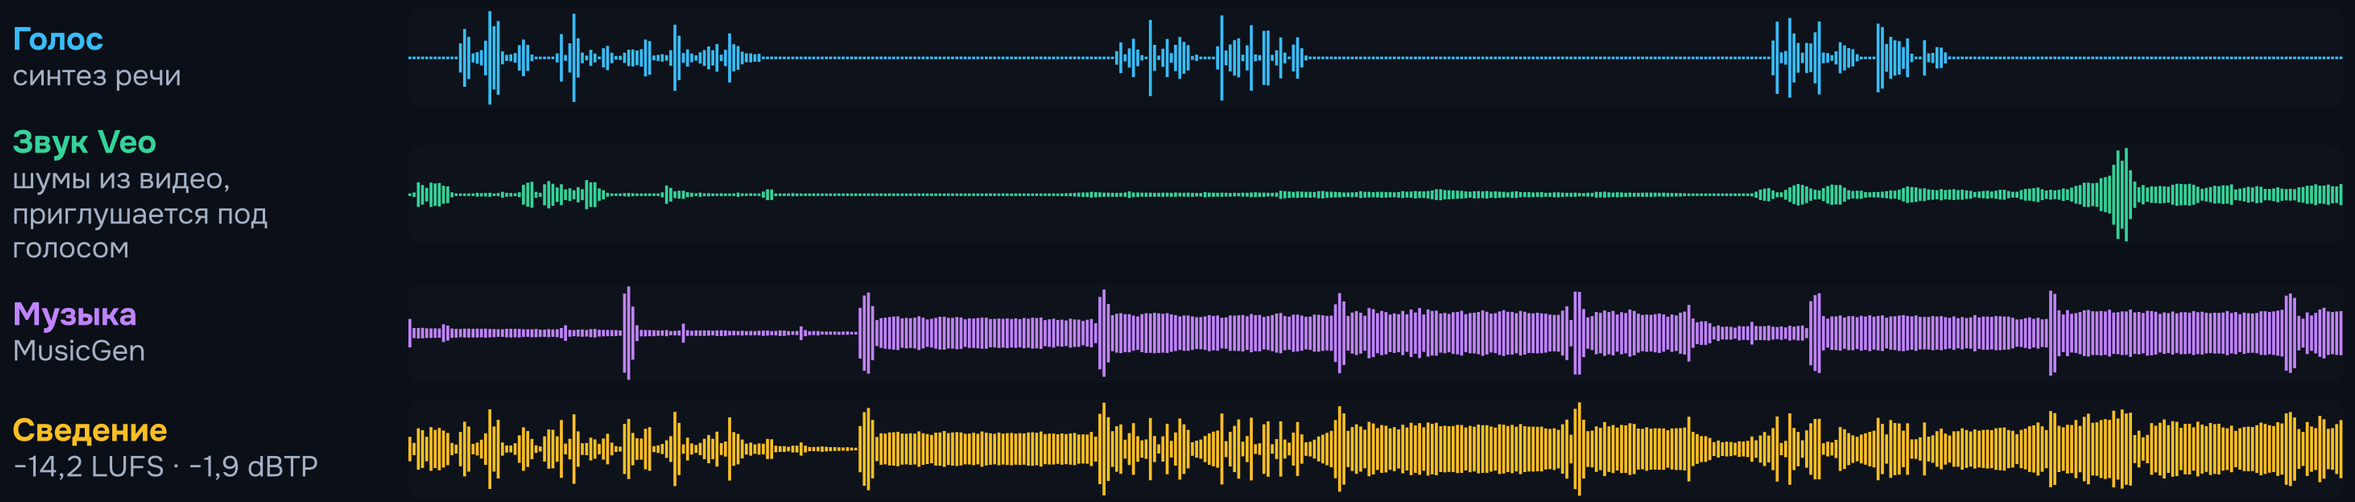
ПРОМПТ

```
calm lo-fi hip hop beat, soft electric piano, light rain
mood, 85 bpm, no vocals
```

> Файлы модели MusicGen: лицензия **Creative Commons «с указанием авторства, некоммерческая» (CC BY-NC 4.0)**. Для урока можно, для клиента нет.

СЕРВИС	ДЛИНА	КОММЕРЧЕСКОЕ ИСПОЛЬЗОВАНИЕ
Suno v6 песни	песня	только платные тарифы
Lyria 3.5 Gemini app, Gemini API	пара минут	по условиям Google; метка SynthID; API $0.08 за песню
ElevenLabs Music музыка	3 с – 5 мин	«почти любое», по тарифу
ElevenLabs Sound Effects шумы	≤ 30 с	по тарифу

Сведение: голос сверху, фон приглушён, громкость выровнена



- **Приглушение (ducking):** фон автоматически тише, пока звучит голос.
- **Громкость −14 LUFS** (единица громкости «как слышит ухо»): норма Spotify и YouTube; для ТВ −23.
- **Пик в готовом файле не выше −1 dBTP**, иначе после сжатия звук хрипит. Лимитер ставим на −2: запас, см. справа.

Без кода, Audacity (бесплатно): импорт трёх дорожек → фон: *Effect* › *Auto Duck* → *Loudness Normalization* −14 LUFS → *Limiter* −2 dB (запас: видео в AAC поднимает пик на ~0,5 дБ) → WAV в CapCut или Clipchamp.

Распознавание нашло ошибки, которые мы не услышали

СЦЕНАРИЙ

6:42. Заказ 417 забран, ещё горячий. На проспекте дождь. Маршрут в обход моста. До двери 12 минут. Анна уже в пути.

ЧТО УСЛЫШАЛ WHISPER (SMALL, НА НОУТБУКЕ)

~~Часть 42.~~ Заказ **417** забран. Ещё горячий. На проспекте дождь. Маршрут в обход моста. До двери **12 минут.** ~~Оно~~ уже в пути.

- **«Часть 42» вместо «Шесть сорок две»**: причина в голосе: проглатывает «ш»
- **«Оно» вместо «Анна»**: причина в голосе: неверно читает имя
- **Не услышано**: английская фраза Veo в начале: распознавание на русском её пропускает, начало слушаем ушами

14,3%

частота ошибок в словах (word error rate, WER) = (замены + пропуски + вставки) / слов в сценарии

2 из 4

критичных слов верно (время, номер, минуты, имя)

Без кода: ElevenLabs Speech to Text, Google AI Studio (промпт «Transcribe verbatim. Do not correct mistakes.»), Buzz (Whisper для компьютера).

ЛОКАЛЬНЫЕ МОДЕЛИ

Открытые модели бесплатны за минуту, но платите железом и временем

Hugging Face
карточка модели и файлы весов
→
Ваш диск
~/.cache/huggingface
→
Python-пакет
qwen-tts, kokoro-onnx
→
Процессор или видеокарта
считает звук
→
WAV-файл
ничего не уходит в интернет

МОДЕЛЬ	ФАЙЛЫ	ГДЕ ЗАПУСКАТЬ	У НАС
Kokoro-82M · Piper синтез речи	0,36 · 0,06 ГБ	процессор ноутбука	наш голос EN · RU
Whisper small распознавание	0,5 ГБ	процессор ноутбука	наша проверка
Qwen3-TTS 0.6B синтез + клон	2,5 ГБ	процессор: ≈8–9× медленнее реального времени	слайд 16
Qwen3-TTS 1.7B синтез + клон	4,5 ГБ	видеокарта от 8 ГБ памяти	лучше качество

$0 за минуту

нет оплаты за символы и минуты, но вы платите **железом, электричеством и временем на установку**

> Зачем: **данные не уходят** из компьютера, нет лимитов, работает без интернета. Цена: качество ниже лучших сервисов, обновления и лицензии на вас.

РЫНОК • ОКТЯБРЬ 2026

Аудиомодели по задачам: коммерческие и открытые

Синтез речи (TTS)
текст → голос

- ElevenLabs v4 / v3
- Gemini 3.8 Flash TTS
- OpenAI gpt-4o-mini-tts (до 06.01.2027)
- Kokoro-82M Apache-2.0
- Qwen3-TTS Apache-2.0

Распознавание речи (STT, ASR)
голос → текст

- OpenAI gpt-transcribe
- ElevenLabs Scribe v2
- AssemblyAI Universal-3.5 Pro
- Whisper large-v3-turbo MIT
- Qwen3-ASR Apache-2.0

Речь в речь
голосовые агенты, перевод

- OpenAI gpt-realtime-2.1 / gpt-live-1
- Gemini Live API
- ElevenLabs Agents

Музыка и шумы
текст → музыка, шумы

- Suno v6
- Lyria 3.5
- ElevenLabs Music / Sound Effects
- MusicGen CC BY-NC

Точность распознавания (английский): лучшие системы ≈ 4–5% ошибок в словах, Whisper large-v3 ≈ 7–8%. Рейтинг Open ASR Leaderboard (Hugging Face); цифры меняются, перепроверяйте.

Зелёная рамка: открытая модель и её лицензия. **MIT, Apache-2.0:** можно в коммерции, сохраняя текст лицензии. **CC BY-NC:** только некоммерческое. У голосов и датасетов бывают свои лицензии.

ПЕРЕРЫВ

5 минут на кофе и отдых для ушей

05:00

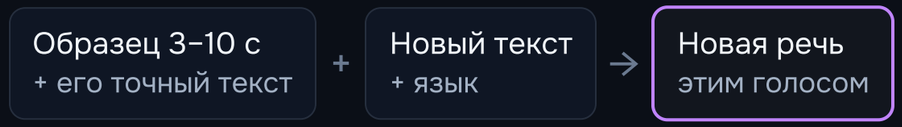
Дальше: агент клонирует голос, стоимость, приёмка, риски и домашнее задание.

ПРАКТИКА С АГЕНТОМ

Агент ставит Qwen3-TTS локально и клонирует голос

ПРОМПТ ДЛЯ АГЕНТА РАЗРАБОТКИ: CODEX В CHATGPT ИЛИ ANTIGRAVITY — БЕСПЛАТНО С ЛИМИТОМ, CLAUDE CODE — ПЛАТНО

```
Установи открытую модель синтеза речи Qwen3-TTS (Qwen/Qwen3-TTS-12Hz-0.6B-Base, Apache-2.0) в папку C:\ai\qwen-tts-demo и склонируй МОЙ голос.
0. Мой образец: my_voice.m4a из «Звукозаписи» Windows, 10 с, и my_voice.txt с точным текстом. Переведи образец в WAV 24 кГц моно через ffmpeg.
1. Проверь видеокарту и её память, оперативную память, свободный диск (~5 ГБ). Скажи, что подойдёт: 0.6B или 1.7B, видеокарта или процессор.
2. Создай там отдельное окружение Python, установи qwen-tts и soundfile.
3. Скачай модель с Hugging Face и покажи, где лежат файлы.
4. Напиши clone.py и озвучь моим голосом по-русски: «Шесть сорок две. Заказ четыреста семнадцать забран, ещё горячий.» → line1.wav.
5. Запусти, замерь время, ничего не загружай в интернет.
```



Образец синтетический голос Kokoro, 5,8 с

▶ звук в HTML-версии

Клон реплика 1: 5,1 с речи за 38 с на процессоре

▶ звук в HTML-версии

Только свой голос. Модель ничего не проверяет: согласие — ваша ответственность (слайд 19).

СТОИМОСТЬ

Час звука стоит центы и доллары, час видео — больше тысячи долларов

Цена **одного часа**, шкала логарифмическая (каждая метка ×10).
1 минута речи ≈ 1000 символов. Списочные цены на 16.10.2026.



≈ 1 цент

озвучка нашего ролика: 149 символов на ElevenLabs v3; у нас $0 на открытых моделях

$4.80 = 12 с

час голоса ElevenLabs стоит как 12 секунд видео Veo 3.1 (L05: $0.40/с)

ПРИЁМКА

Обе наши версии не прошли приёмку: вот чек-лист

Это же критерии оценки домашнего задания. Справа реальный результат нашей версии.

1	**Слова** совпадают со сценарием: распознавание + список критичных слов	✗
2	**Произношение** имён, чисел, терминов: проверено на слух	✗
3	**Тайминг:** реплика влезает в шот, не режется склейкой	✓
4	**Сведение:** голос разборчив, фон приглушён, нет чужой речи	✗
5	**Громкость** -14 ± 1 LUFS; истинный пик ≤ -1 дБ (dBTP)	✓
6	**Права:** лицензия голоса и музыки, согласие, пометка «создано ИИ»	!

−14,2 LUFS

пик -1,9 dBTP. Без кода: Youlean Loudness Meter или измеритель громкости в DaVinci Resolve, смотрим Integrated и True Peak

> **Не принято:** голос искажает «Анна» и «шесть сорок две»; в начале слышна английская реплика Veo, которую распознавание на русском пропустило. Исправление: другой голос, звук шота 1 заглушить на 0–3 с.

Доказательства в ДЗ: 1 → transcript.txt и таблица критичных слов · 2, 4 → заметки на слух с таймкодами · 3 → script.md · 5 → скриншот измерителя · 6 → таблица лицензий и пометка «создано ИИ»

РИСКИ

Риски и согласие на голос: клонирование, маркировка, закон

Готовый или придуманный голос
можно, по лицензии сервиса, с пометкой «создано ИИ»

Свой голос, клон коллеги
письменное согласие: для чего, где, как долго, как отозвать

Голос клиента, руководителя, публичного лица
нельзя без письменного согласия и юристов; голосом обманывают

КАК СЕРВИСЫ ПРОВЕРЯЮТ СОГЛАСИЕ НА КЛОН

- **OpenAI, Google:** владелец голоса записывает фразу согласия. **Azure:** доступ по заявке.
- **ElevenLabs Professional:** владелец читает проверочный текст; Instant: только галочка.
- **Открытые модели** (Qwen3-TTS, Chatterbox): клон по 3–10 с, **без проверок**.

EU AI Act, ст. 50: с 2 августа 2026 синтетический звук и дипфейки нужно помечать; штраф до €15 млн или 3% оборота. **OpenAI** требует сообщать слушателю, что голос сгенерирован. **Google** ставит невидимую метку SynthID во весь звук своих моделей.

ПРАКТИКА

Домашнее задание 6: озвучить свой ролик из L05



Ваш ролик из L05

Трек А (товар) или Б (курьер, кейс Glovo). Нет ролика: возьмите курьерский ролик урока. В ролике нет звука: фон из шумов или музыки.

```
genai-homeworks/L06/
├── script.md       # текст, текст для голоса, время
├── audio/          # реплики, подложка, сведение
├── final_voiced.mp4
├── transcript.txt # распознанный текст
├── audio_spec.md
└── audio_qa.md
```

1. **Сценарий**: 3 реплики, бюджет слов, критичные слова → `script.md`
2. **Текст для голоса**: числа и имена словами, инструкция стиля
3. **Голос** в двух сервисах без кода (например, ElevenLabs и Google AI Studio), выбрать лучший
4. **Фон**: звук видеомодели, шумы или музыка, с лицензией
5. **Сведение** в `final_voiced.mp4`: −14 ± 1 LUFS, скриншот измерителя
6. **Проверка**: `transcript.txt`, чек-лист слайда 18 → `audio_qa.md`, стоимость → `audio_spec.md`

Ревьюер: **ihar_rubanovich@epam.com**. Только свой голос или голоса из библиотек; чужие голоса не клонируем.

Итоги урока

1. **Сценарий с бюджетом слов**
   около 2 слов в секунду, по секунде тишины у склеек
2. **Текст для голоса отдельно**
   числа, время, имена словами; стиль отдельной инструкцией
3. **Голос с лицензией и согласием**
   клон только с письменного согласия владельца
4. **Фон с известной лицензией**
   звук видео, шумы или музыка; MusicGen и бесплатный Suno некоммерческие
5. **Сведение к −14 LUFS**
   голос сверху, фон приглушён, истинный пик ≤ −1 дБ (dBTP)
6. **Проверка распознаванием и на слух**
   частота ошибок + критичные слова



Урок 07: экосистема Microsoft Copilot. Из генерации контента переходим к ИИ в рабочих инструментах.