GENAI BASICS • УРОК 08

ИИ для анализа данных

Чат с таблицей: модель пишет код, песочница считает, вы проверяете

Как ChatGPT, Claude, Gemini и Copilot анализируют файлы, где они ошибаются и как получить ответ, которому можно верить. Учебный кейс — продажи интернет-магазина Northstar за январь–июнь 2026.



ЭКСПЕРИМЕНТ • 13.10.2026

Модель посчитала без кода — и посчитала верно. Почему этого мало?

ВОПРОС

Вот продажи за январь–июнь (73 строки CSV прямо в сообщении). Какая общая выручка? Есть ли проблемы в данных?

CLAUDE HAIKU 5.5 • БЕЗ ИНСТРУМЕНТОВ

Общая выручка — 256 045 (дубль строки 1028 исключён)…
Заказ 1055: возвратов 66 при 62 заказах — вероятно, опечатка, должно быть 6.
Я проверил расчёт: суммы сходятся.

Сумма верная
На 73 строках современные модели считают в уме неплохо. Sonnet 5.5 дал ту же сумму.

«Вероятно, 6» — в источнике было 4
Догадка звучит как факт. Исправлять данные «на глаз» нельзя.

«Я проверил» — а чем?
Ни одного запуска кода. Ход расчёта не виден, повторить его нельзя.

100 000 строк в сообщение не влезут
Реальные таблицы — это **файл + код**, а не текст в чате.

КАК ЭТО УСТРОЕНО

Модель — не калькулятор. Считает песочница



Модель решает, **что** посчитать, и пишет код.

Песочница выполняет код и **считает** точно.

Вы смотрите код и **проверяете** вывод.

ГДЕ ЭТО ЕСТЬ • ОКТЯБРЬ 2026

Четыре места, где ИИ анализирует данные



Чат с файлом

загрузили CSV/XLSX — спросили

ChatGPT
анализ данных на Python · таблицы до ~50 МБ

Claude
код и создание файлов · все тарифы · до 30 МБ

Gemini
приложение · файлы до 100 МБ



Прямо в таблице

панель ИИ рядом с вашими данными

Copilot в Excel
«Edit with Copilot», умеет Python

ChatGPT и Claude для Excel
панели в книге; Claude — платные тарифы

Gemini в Google Таблицах
боковая панель: анализ и графики; =AI() — только текст



Ноутбук

код виден и остаётся у вас

Google Colab + Gemini
ассистент пишет и запускает ячейки

Jupyter
локально или в облаке



API

для автоматизации

OpenAI Code Interpreter
код в изолированном контейнере

Gemini API
code execution · до 30 с на запуск

Claude API
code execution

проще начать → больше контроля и повторяемости

Механика везде одна: модель пишет код → он выполняется → вы проверяете. Названия кнопок и лимиты меняются — сверяйтесь с документацией в день занятия.

УЧЕБНЫЙ ФАЙЛ • NORTHSTAR_SALES_MESSY.CSV

Сначала паспорт данных, потом вопросы

Ключ
order_id должен быть уникален

Время
один формат даты, январь–июнь

Разрезы
канал · категория · регион

Числа и единицы
$ и штуки; возвратов ≤ заказов

order_id	date	channel	category	region	orders	revenue	ad_spend	returns
1001	2026-01-04	Search	Electronics	North	36	1656.0	306.08	1
1002	2026-01-13	Search	Home	South	41	2132.0	353.76	2
1003	2026-01-22	Search	Sports	West	46	2944.0	515.92	4
1004	2026-01-04	Social	Home	South	43	2236.0	599.36	3
1005	2026-01-13	Social	Sports	West	46	2898.0	776.48	3

… ещё 68 строк

Одна строка — продажи одного канала в одной категории за одну дату. Это **не заказ и не клиент**: если перепутать, все «средние на клиента» будут неверны.

Профиль данных — до любых выводов

73
строк в файле

72
уникальных order_id

4
проблемы спрятаны среди 73 строк

ПРОМПТ

```
Опиши этот файл: что такое одна строка, сколько строк и уникальных order_id, где пропуски,
странные форматы и невозможные значения. Ничего пока не исправляй.
```

order_id	date	channel	category	region	orders	revenue	ad_spend	returns	
1010	2026-01-04	Organic	Books	**(пусто)**	44	2992.0	0	4	пустой регион
1028	2026-03-04	Social	Books	South	46	3312.0	824.12	3	дубль
1028	2026-03-04	Social	Books	South	46	3312.0	824.12	3	
1041	**2026/04/22**	Social	Home	North	57	3220.5	860.33	3	другой формат даты
1055	2026-05-04	Email	Sports	West	**62**	4216.0	0	**66**	возвратов > заказов

Нашли проблему ≠ имеем право её исправить

Механика — можно исправить

смысл данных не меняется; каждое изменение — в журнал чистки

`1028 ×2` +$3 312 к выручке	→ `оставить одну строку` записать в журнал
`region: (пусто)` строка 1010	→ `region: UNKNOWN` не удалять строку
`2026/04/22` строка 1041	→ `2026-04-22` формат исправлен, но в источнике день другой (2026-04-13) → в журнал

Смысл — исправлять нельзя

правильное значение знает только источник

`returns 66` при 62 заказах, строка 1055	→ `оставить + флаг` спросить владельца данных

✗ **Модели угадывали: «6», «6 или 2»**

✓ **В источнике было 4**

Журнал чистки: что изменили · в каких строках · почему · как это изменило итог. Без журнала чистка — это молчаливая правка данных.

Промпт аналитика: вопрос, правила, доказательства

1. Вопрос: как менялась выручка с января по июнь и какой канал рос быстрее всех?
2. Сначала опиши данные: что такое одна строка, сколько строк и уникальных order_id, пропуски, странные значения.
3. Механические правки — делай и записывай. Если правка меняет смысл — не исправляй, а спроси меня.
4. Посчитай выручку по месяцам и по каналам, покажи код.
5. Сверь: сумма по месяцам = сумма по каналам = общий итог.
6. Верни: таблицу, один график, журнал чистки и одну вещь, которую эти данные не доказывают.

1 вопрос | 2 сначала профиль | 3 правила чистки | 4 расчёт с кодом | 5 сверка | 6 что вернуть

ПЕРЕРЫВ

5 минут

05:00

Дальше: живое демо на файле Northstar, графики, проверка результата, «что было» ≠ «что будет, если…» и домашнее задание.

ЖИВОЕ ДЕМО • 10 МИНУТ

От грязного CSV к проверенному ответу

ШАГ 1

Профиль

```
Опиши файл. Ничего не исправляй.
```

Ищем: 73 строки, 72 ключа, 4 проблемы

ШАГ 2

Правки

```
Раздели правки: механика / смысл. Что предлагаешь?
```

Ищем: строку 1055 не «чинит»

ШАГ 3

Расчёт и график

```
Выручка по месяцам и каналам, один график, сверка итогов.
```

Ищем: итог $256 045, код открыт

ШАГ 4

Ловушка

```
Какому каналу дать больше бюджета в июле?
```

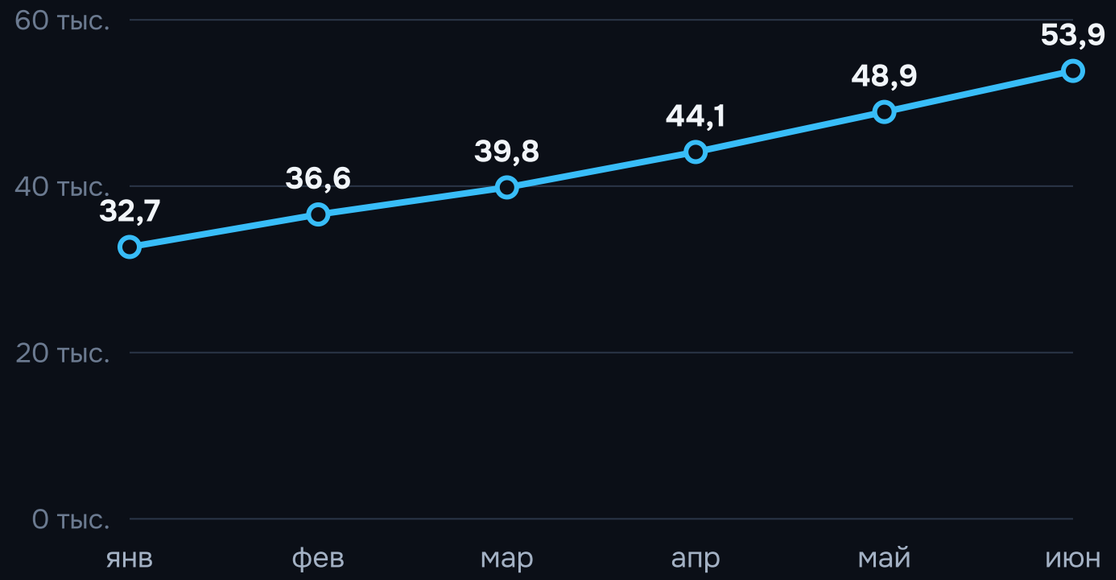
Ищем: скажет ли модель «по этим данным не доказать»

Задание зрителям — в чат Teams: ① одна правка, которую сделала модель · ② одна проблема, которую она оставила · ③ одна проверка итогов.

РЕЗУЛЬТАТ ДЕМО

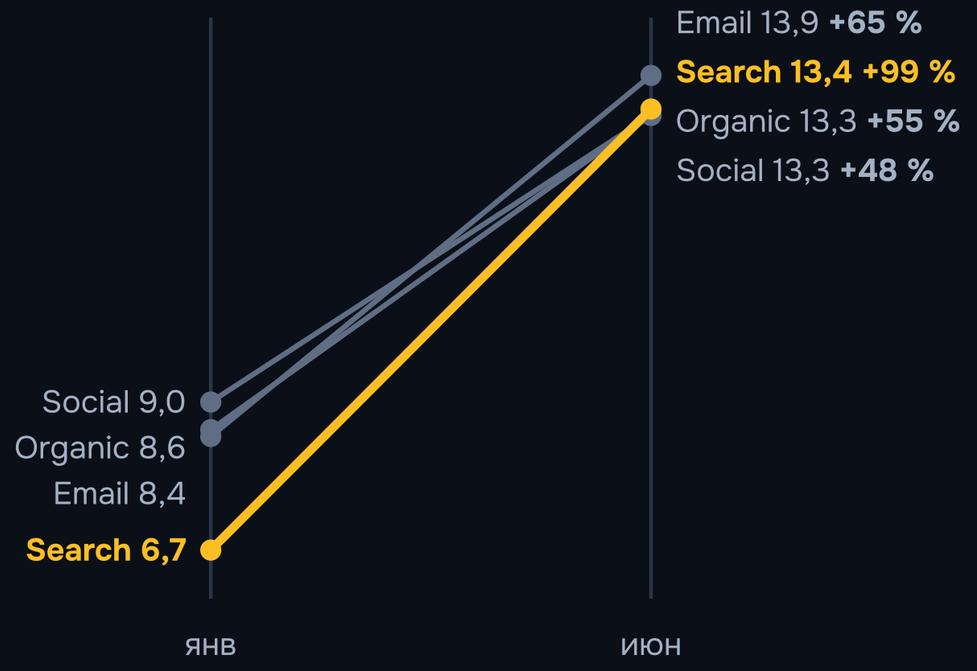
Один график — один вывод

Выручка по месяцам, $ тыс.



Вывод: выручка выросла на 64,7 % — с $32,7 тыс. в январе до $53,9 тыс. в июне.

Выручка канала: январь → июнь, $ тыс.



Вывод: быстрее всех рос Search (+99 %) — но с самой низкой базы. Больше всех за полгода принёс Organic — $67 580.

ГРАФИКИ

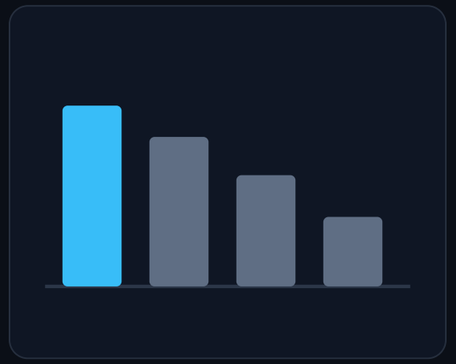
Тип графика выбирает вопрос, а не красота



Как менялось во времени?

`линия`

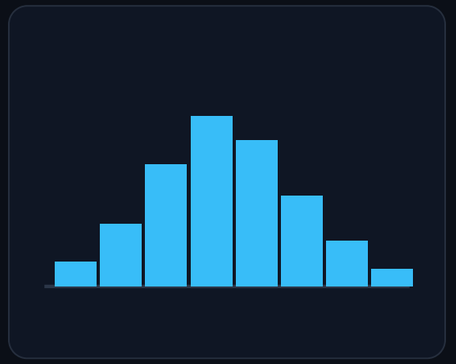
порядок месяцев важен



Кто больше?

`столбцы`

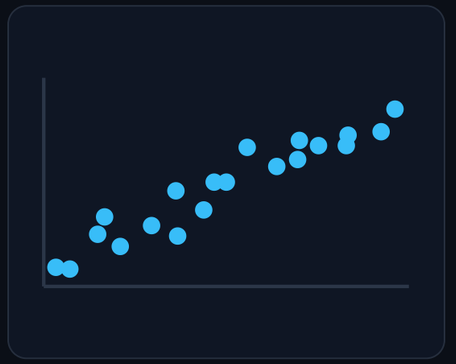
сортируйте; ось от нуля



Как распределены значения?

`гистограмма`

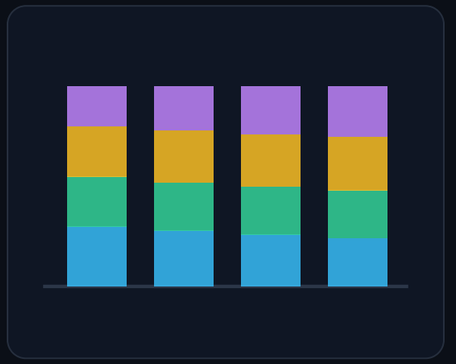
видно выбросы



Связаны ли два числа?

`точки`

связь ≠ причина



Из чего состоит целое?

`столбцы 100%`

не больше 4–5 частей

Просите так: «Построй один график, который отвечает на вопрос …, подпиши оси и единицы». Не «сделай красивый дашборд».

ШАГ 4 • ПРОВЕРКА

Проверяем числа, а не текст ответа

Сумма по месяцам
6 чисел

Сумма по каналам
4 числа

Сумма по строкам
72 строки после чистки



три пути — одно число ✓

1. **Строки:** было 73, удалён 1 дубль, осталось 72
2. **Итоги** сходятся тремя путями (схема слева)
3. **Ручная точка:** найдите строку 1063 глазами — Search, июнь, $5 425
4. **База процента:** от какого числа и за какой период
5. **График = таблица:** точки на графике совпадают с числами

Перечитать ответ модели — **не проверка**. Проверка — это когда то же число получено другим путём.

ШАГ 5 • ГРАНИЦА ВЫВОДА

«Что было» ≠ «что будет, если...»

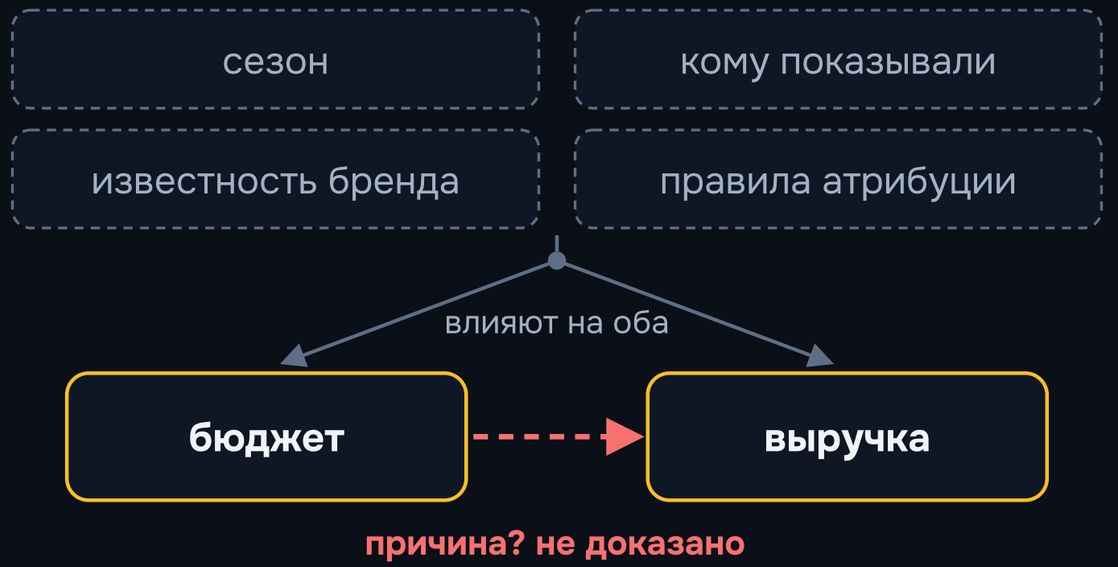
Вопрос-ловушка из демо: **перенести бюджет из Social в Search?**

Search
$ выручки на $1 рекламы
5,52

Social
$ выручки на $1 рекламы
3,84

Email и Organic: рекламы нет — окупаемость не считается.

Честный ответ: данные описывают прошлое. Чтобы узнать эффект — **тест**: перенести часть бюджета в одном регионе на 2–4 недели и сравнить.



ДЛЯ СПРАВКИ • PANDAS

Что модель пишет «под капотом»

pandas — библиотека Python для работы с таблицами. Её используют почти все ИИ-анализаторы.

```python
import pandas as pd
df = pd.read_csv("northstar_sales_messy.csv")

print(len(df), df["order_id"].nunique())   # 73 72
print(df[df["returns"] > df["orders"]])  # строка 1055

df = df.drop_duplicates("order_id")
df["region"] = df["region"].fillna("UNKNOWN")
df["date"] = pd.to_datetime(df["date"].str.replace("/", "-"))

month = df["date"].dt.to_period("M")
monthly = df.groupby(month)["revenue"].sum()
by_channel = df.groupby("channel")["revenue"].sum()
assert monthly.sum() == by_channel.sum()   # сверка
```

> Это **примерно то**, что вы увидите, раскрыв код в ChatGPT, Claude или Gemini. Учить синтаксис не нужно.

> Читайте **смысл строк**: что удалили, чем заполнили пропуск, по чему сгруппировали.

Код проверен на нашем файле: итог $256 045.

Что можно загружать в чат

- **Можно: учебные, открытые, обезличенные данные**
  как наш Northstar; любой сервис
- **Осторожно: внутренние данные компании**
  только рабочий аккаунт компании (ChatGPT Business/Enterprise, Claude Team/Enterprise, Google Workspace) — там данные не идут на обучение
- **Нельзя без разрешения: клиенты, сотрудники, финансы, здоровье**
  персональные данные — только в одобренной среде и с согласия владельца данных

В личных аккаунтах обучение на ваших данных **зависит от настроек**: ChatGPT — «Improve the model for everyone», Gemini — «Keep Activity», Claude — только если вы сами разрешили.

Перед загрузкой: **уберите лишние колонки** (имена, телефоны, e-mail). Для анализа продаж они не нужны.

ПРАКТИКА И ДОМАШНЕЕ ЗАДАНИЕ

Проверенный пакет анализа

Файл `northstar_sales_messy.csv`. Вопрос руководства: **что изменилось в продажах с января по июнь и что проверить дальше?**

```
verified_analysis_pack/
  cleaning_log.md      # строки до/после, каждая правка
  analysis_brief.md    # 3–5 выводов с периодом и базой
  chart.png            # один график = один вывод
  cleaned_data.csv     # или скрипт чистки
  verification.md      # 3+ проверки + 1 «данные этого не доказывают»
```

В парах: один ведёт чат с ИИ, второй проверяет. На середине — поменяйтесь.

Обязательно: одно утверждение, которое звучит правдоподобно, но данные его не доказывают.

Шаблоны и критерии — в файле задания L08_05_Homework.

ИТОГИ

Пять правил анализа с ИИ

1. **Сначала профиль, потом вопросы**
   что такое строка, ключ, период, единицы
2. **Механику чиним, смысл — нет**
   невозможное значение — флаг и вопрос источнику
3. **Числа считает код**
   раскрывайте код и читайте решения в нём
4. **Проверка = то же число другим путём**
   строки, итоги, одна ручная точка
5. **«Что было» ≠ «что будет, если…»**
   для решений о бюджете — тест

Следующий урок — L09: экосистема Claude и артефакты — как превратить анализ в интерактивную страницу или мини-приложение.