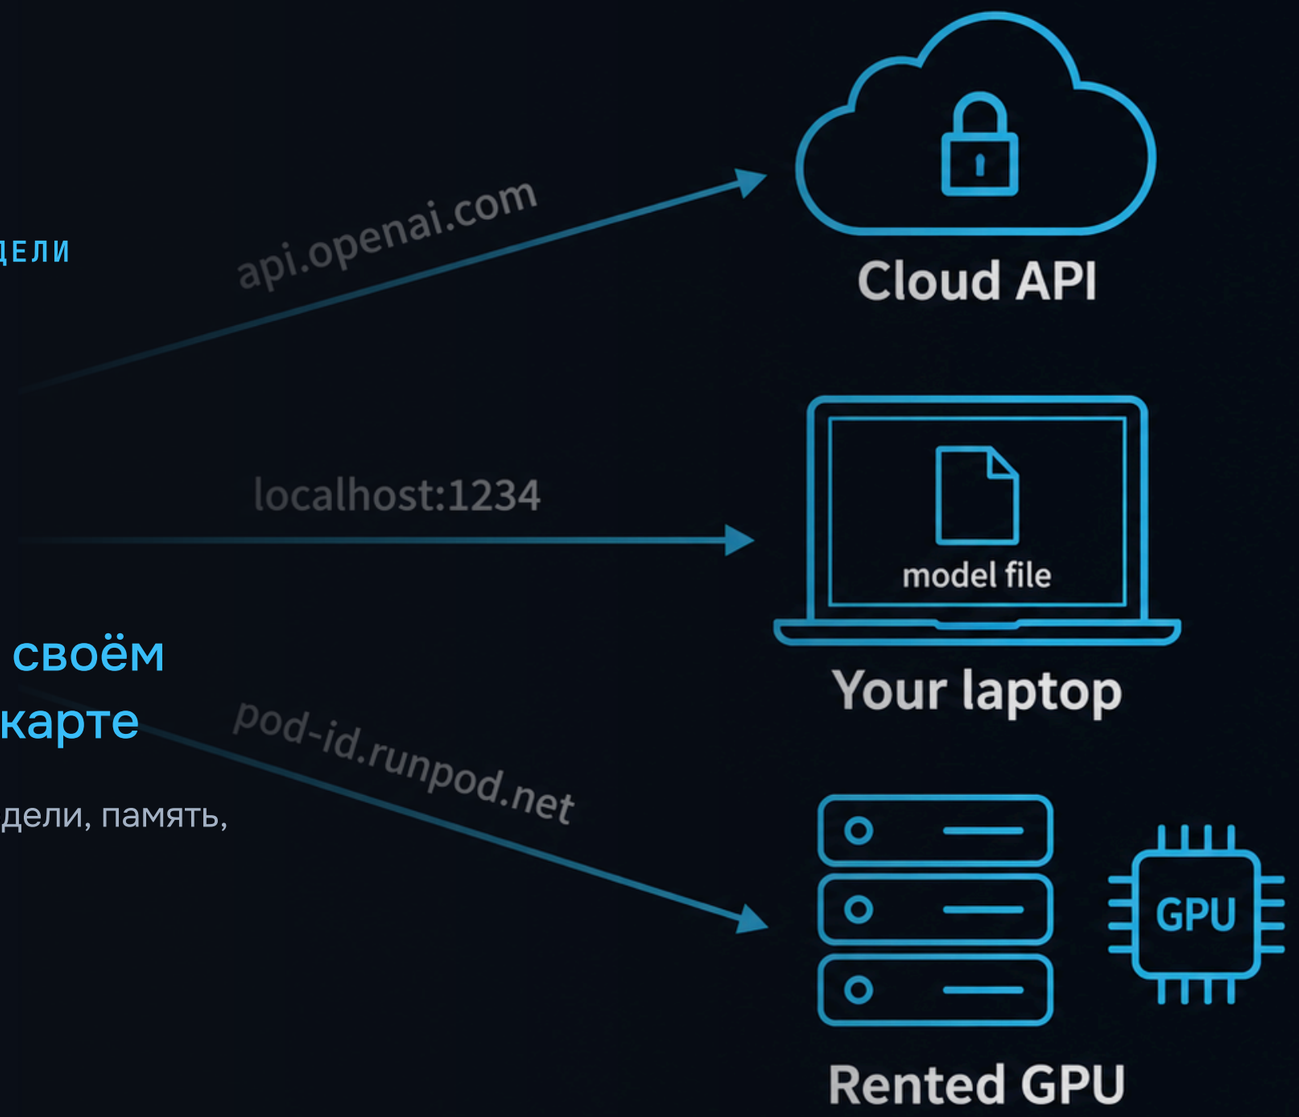
GENAI BASICS • УРОК 10 • МОДУЛЬ 3: СВОИ МОДЕЛИ

Открытые модели

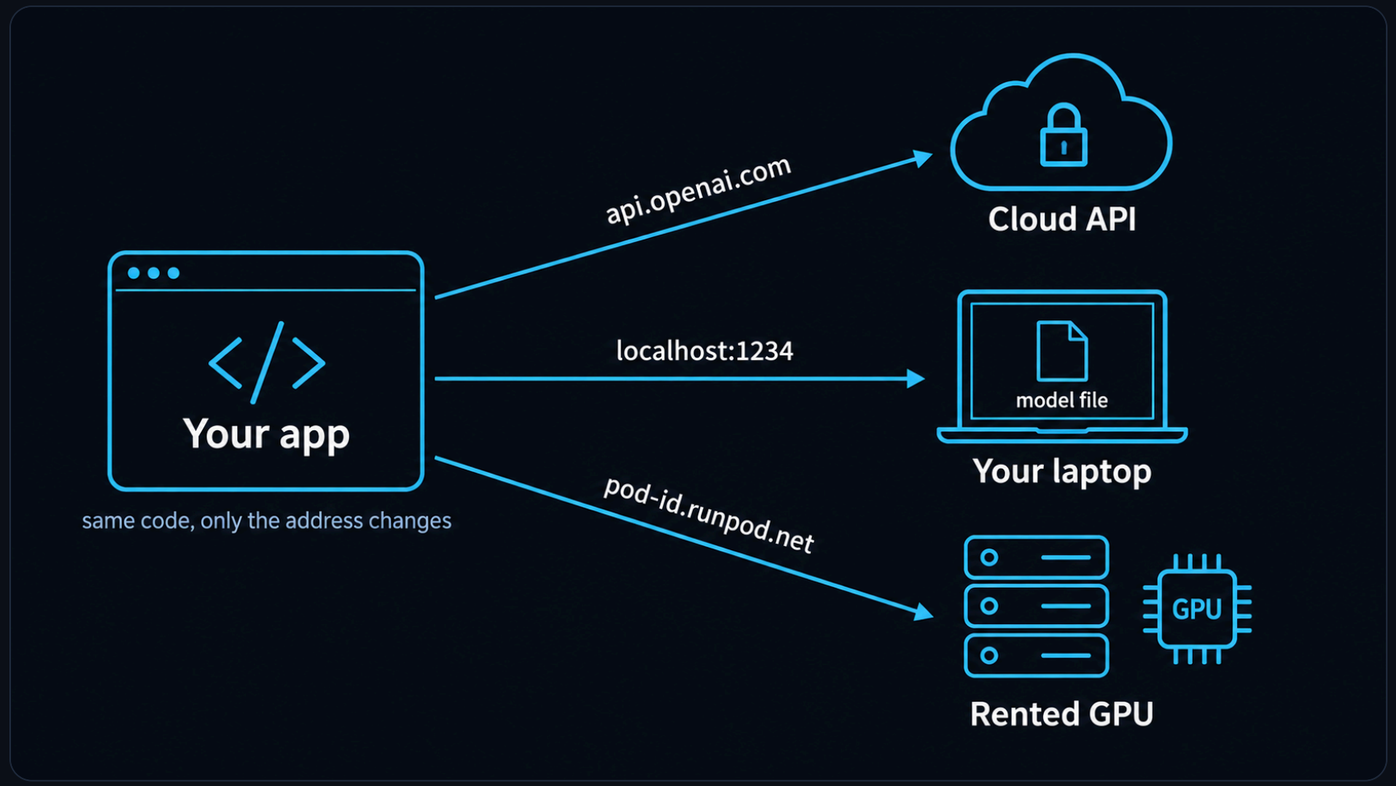
Как запустить языковую модель на своём ноутбуке и на арендованной видеокарте

Hugging Face, LM Studio, Ollama, RunPod. Размер модели, память, скорость, цена. Данные на октябрь 2026.



ИДЕЯ УРОКА

Одно приложение, три места, где работает модель



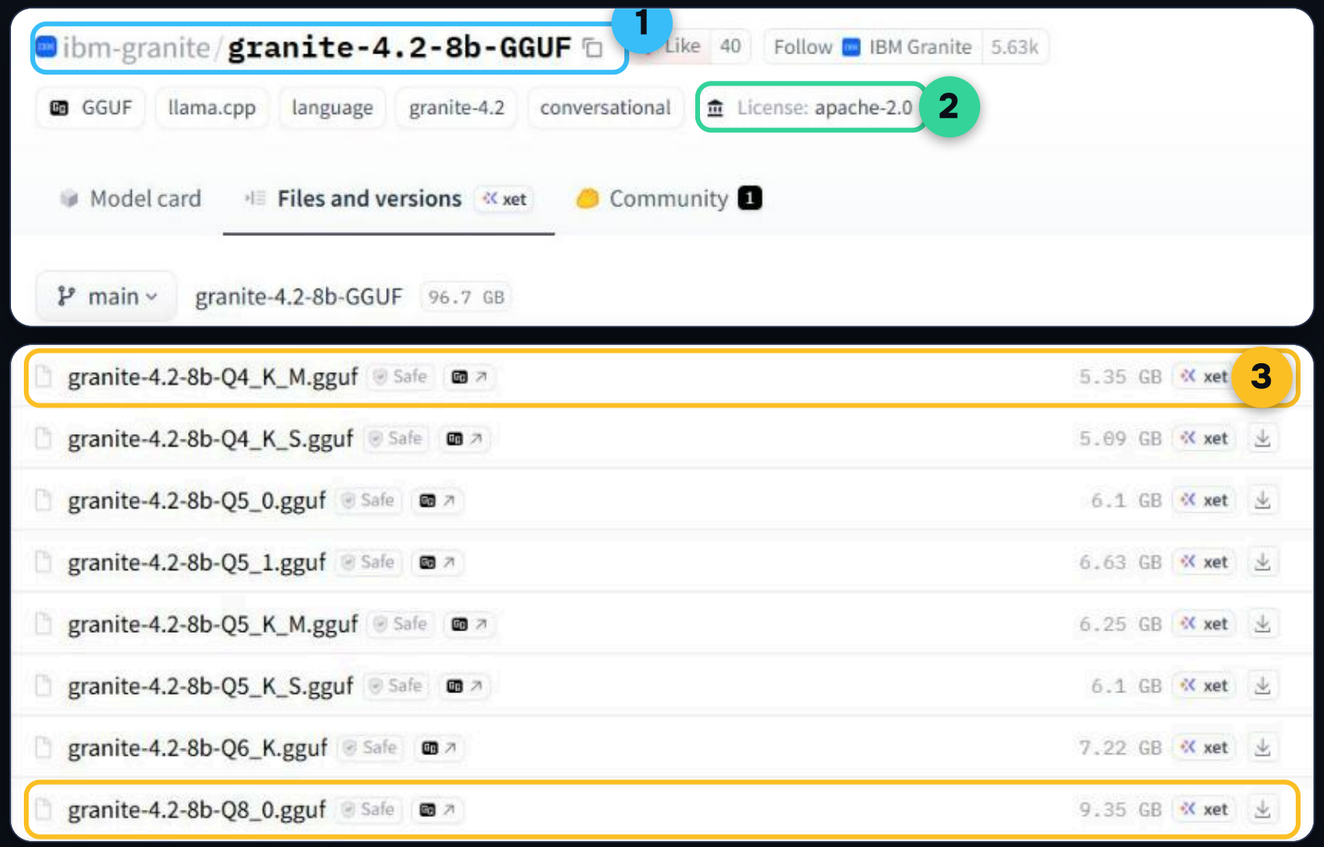
1. **Облачный API**: модель у поставщика, платим за токены, данные уходят к нему
2. **Ваш ноутбук** (localhost = «этот компьютер»): файл модели у вас, интернет не нужен, платите железом
3. **Арендованная видеокарта**: ваша модель на чужом мощном компьютере, оплата по часам

Главное: код приложения почти не меняется, меняется только адрес, куда он отправляет запрос.

ОТКРЫТАЯ МОДЕЛЬ

Открытая модель — это файл, который можно скачать, и лицензия к нему

HUGGING FACE · IBM-GRANITE/GRANITE-4.2-8B-GGUF · СНЯТО 16.10.2026



1. **Кто сделал**: IBM, Granite 4.2 8B. **8B** = 8 млрд параметров, то есть чисел внутри модели
2. **Лицензия** Apache-2.0: можно в работе и в коммерции
3. **Файлы .gguf** (формат для LM Studio и Ollama): одна модель в разных размерах, здесь от 5,35 до 9,35 ГБ

> **Hugging Face** — главный «склад» открытых моделей. У каждой есть карточка: что умеет, ограничения, лицензия.

> «Открытая» ≠ «можно всё». У Llama 4 своя лицензия с ограничениями, у MusicGen (L06) только некоммерческая.

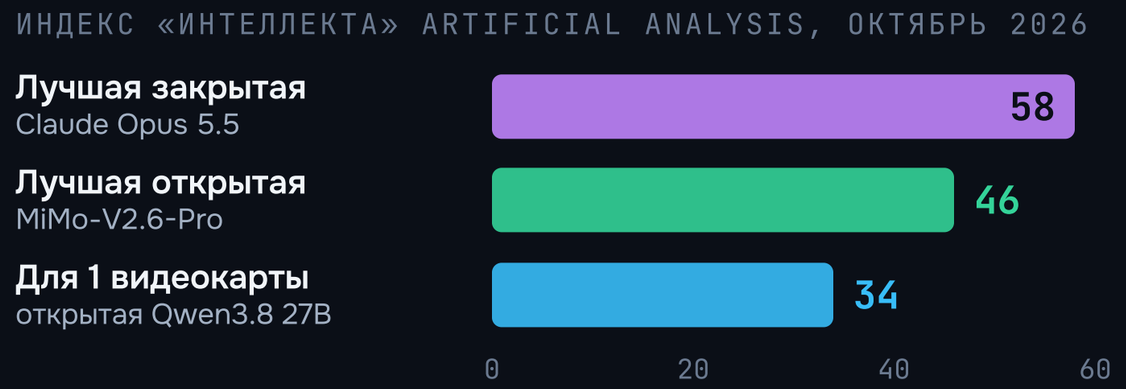
ЗАЧЕМ

Своя модель: данные не уходят, но качество ниже лидеров

Плюсы: данные не покидают компьютер · работает без интернета · нет счёта за токены · модель не поменяют без вас

Минусы: слабее лучших облачных · нужна память и видеокарта · установка и обновления на вас

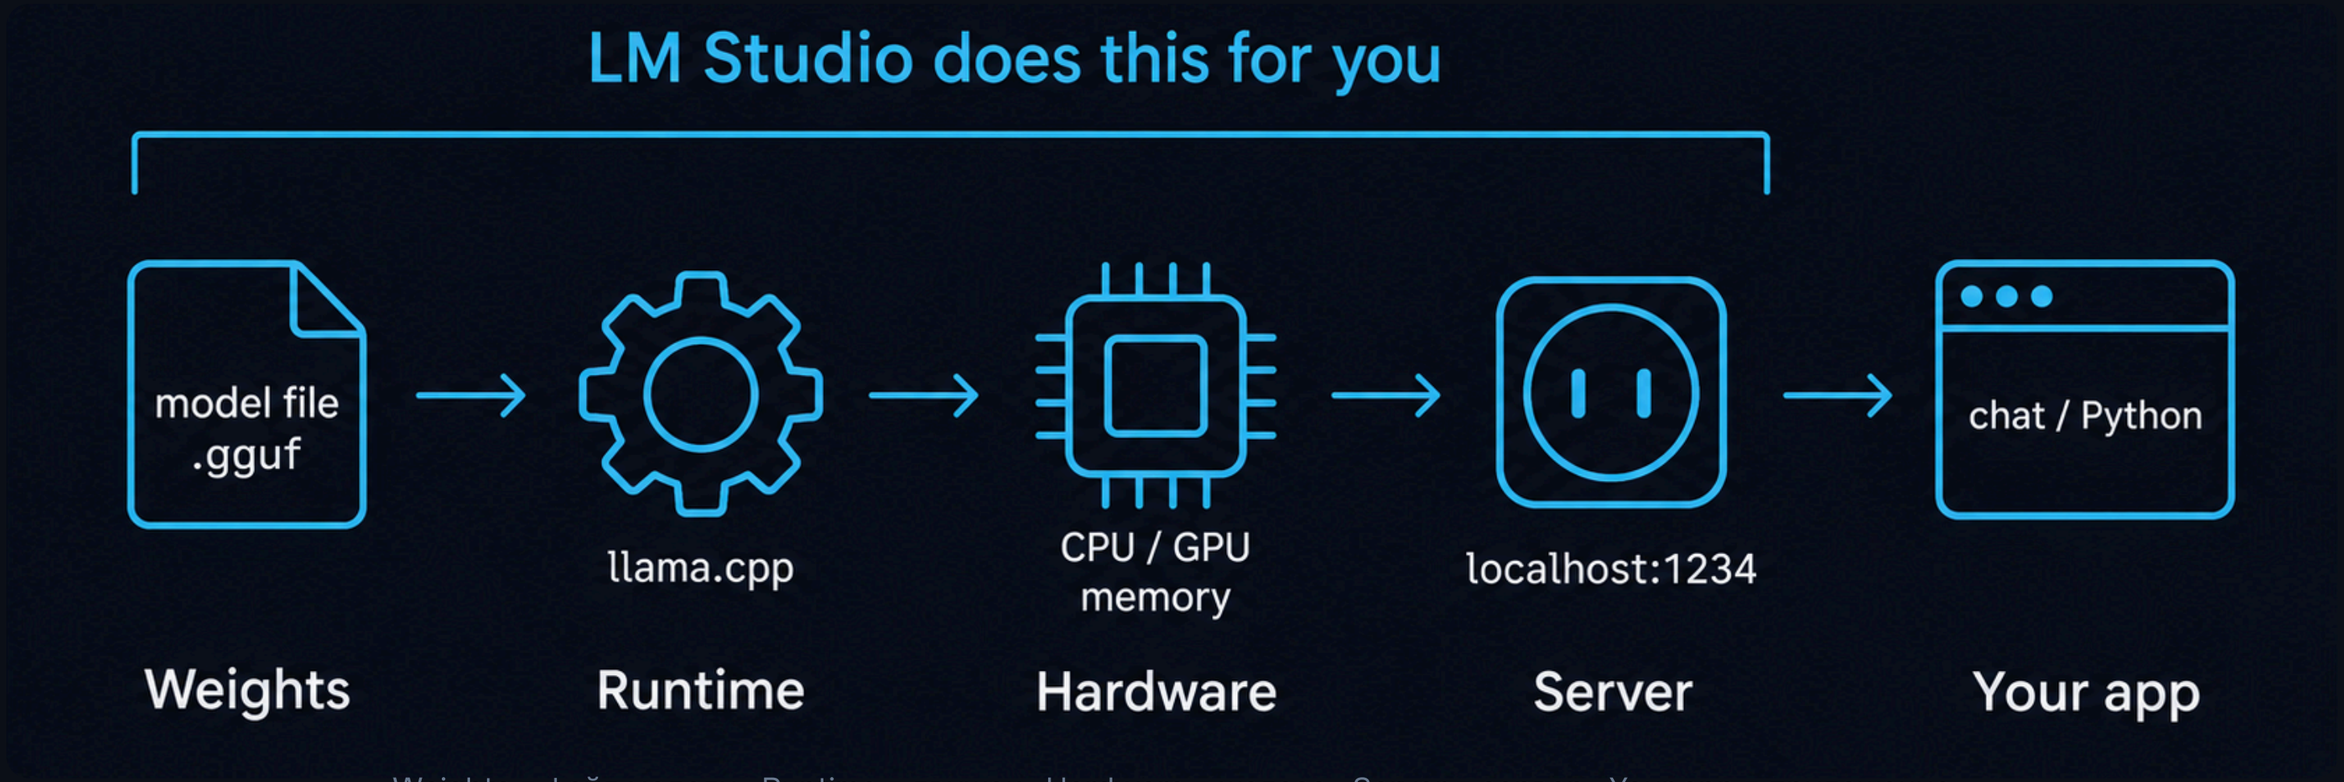
Хорошо подходит: разбор писем и тикетов, черновики, поиск по своим документам. **Плохо:** сложные рассуждения, большой код.



Чем выше, тем лучше. Разрыв между лучшей закрытой и лучшей открытой ≈ 12 пунктов.

КАК ЭТО УСТРОЕНО

Пять частей: файл, движок, железо, сервер, приложение



Weights = файл модели · Runtime = движок · Hardware = железо · Server = сервер · Your app = приложение

Движок (llama.cpp) умеет «прочитать» файл модели и посчитать ответ. **Сервер** даёт к нему адрес, как у облачного API.

Если тормозит, ищем, какая часть виновата: файл слишком большой? нет видеокарты? Не «модель плохая».

РАЗМЕР ФАЙЛА

Сжатие (квантизация): та же модель в 2–5 раз меньше, чуть хуже качество

GRANITE 4.2 8B: РАЗМЕРЫ ФАЙЛОВ НА HUGGING FACE



Q4

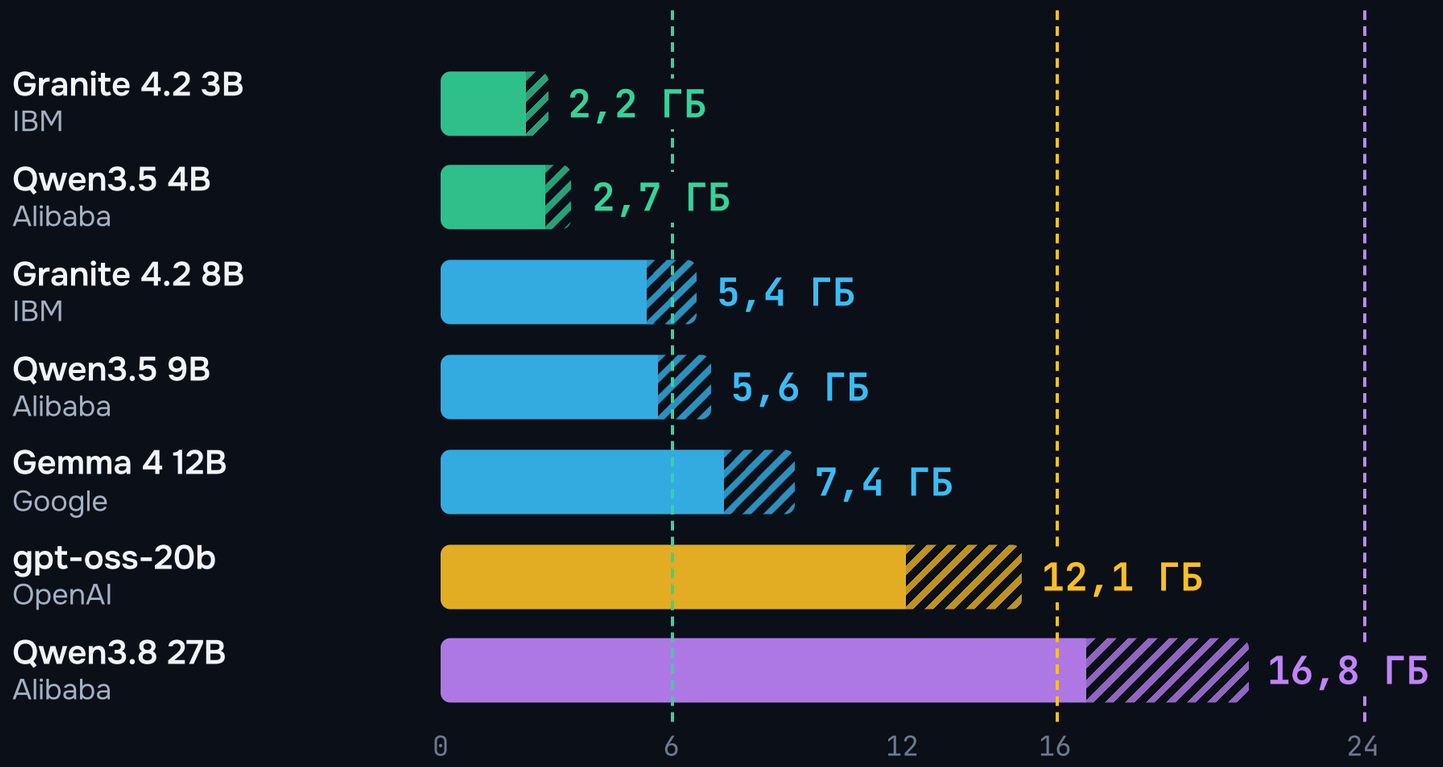
начинаем с 4 бит: так советует и документация LM Studio

> **Как это работает:** каждое число модели хранят грубее, меньшим числом бит. Как JPEG для фото: файл меньше, детали чуть теряются.

ВЛЕЗЕТ ЛИ

Файл модели плюс запас на разговор должен влезть в память видеокарты

ФАЙЛ Q4_K_M + ЗАПАС 25% (ШТРИХОВКА)



+25%

к файлу: память на контекст, то есть историю разговора (обычно 20–30%)

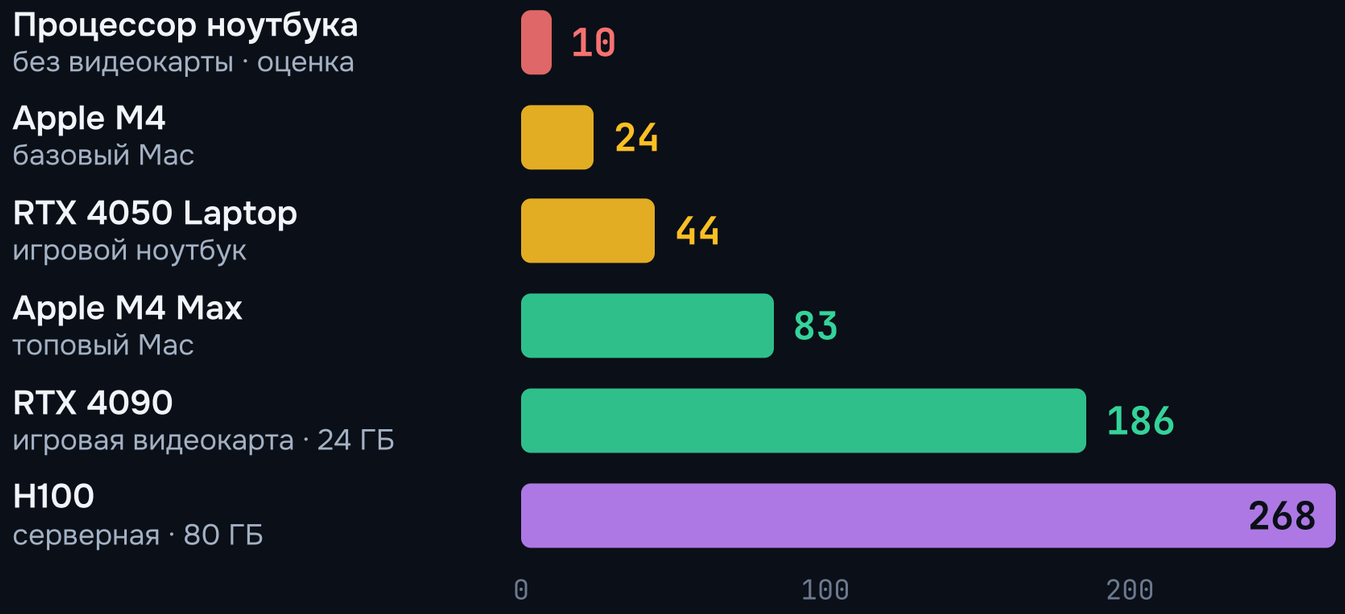
Память видеокарты (VRAM): **6 ГБ** → до 4B · **16 ГБ** → до 12B · **24 ГБ** → до 27B.

Без видеокарты модель живёт в обычной памяти: влезет, но будет медленно. Берите 3–4B.

СКОРОСТЬ

Видеокарта отвечает в 2–25 раз быстрее процессора

Токенов в секунду (токен ≈ часть слова), модель 7B в 4 битах, llama.cpp. Человек читает ≈ 4–7 токенов в секунду.



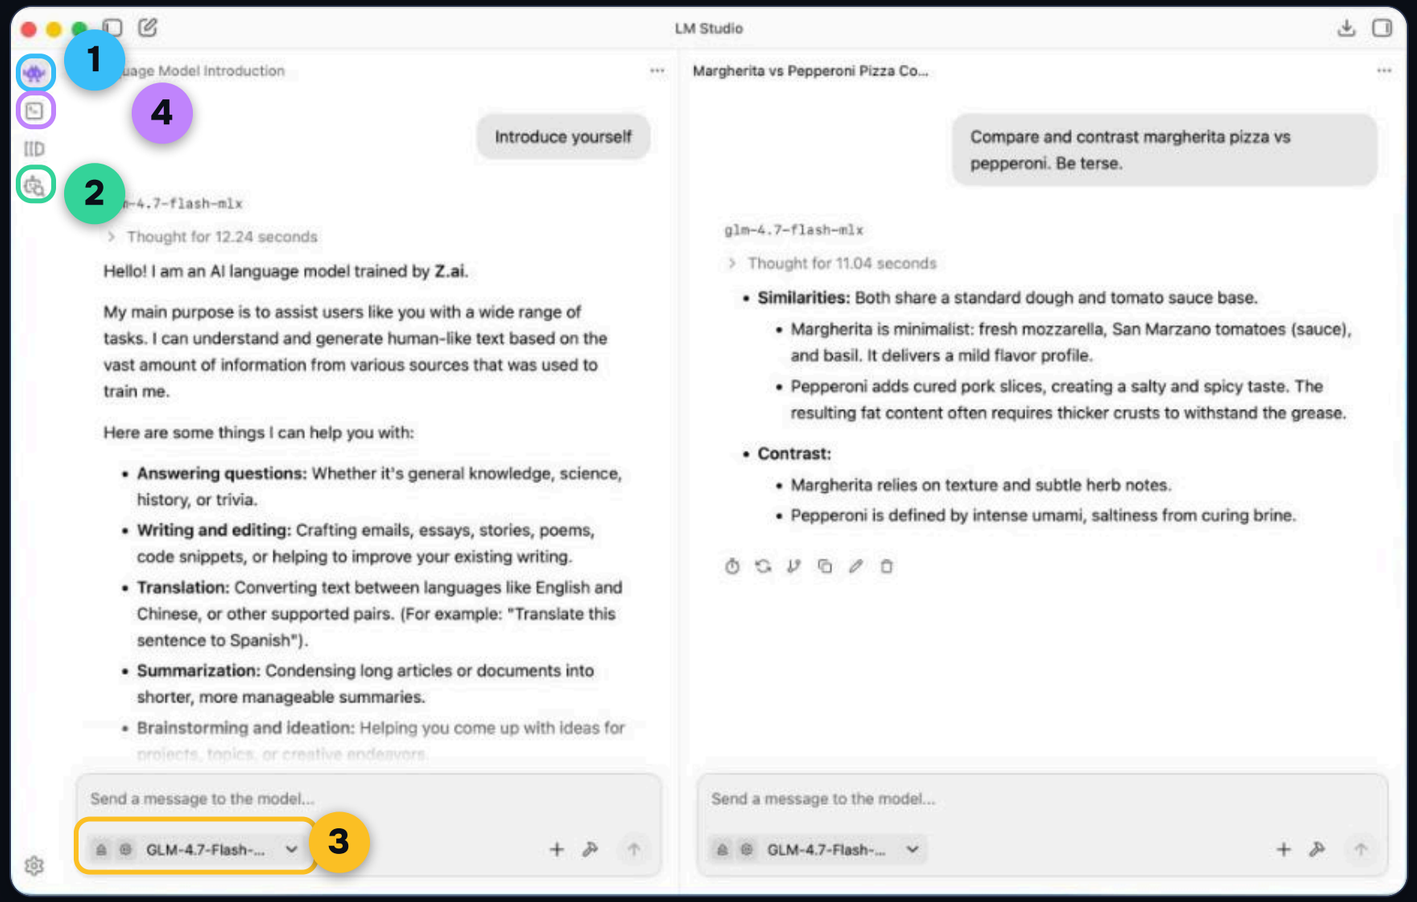
≥ 20 т/с

комфортно: длинный ответ без ожидания; 10 т/с терпимо только для коротких

> Числа ориентировочные: зависят от модели, длины разговора и настроек. Свою скорость LM Studio показывает под каждым ответом.

LM STUDIO

LM Studio: чат как ChatGPT, но модель работает у вас



Изображение: LM Studio / Element Labs, блог версии 0.4.0

1. **Chat** — разговор с моделью
2. **Discover** — поиск и скачивание моделей с Hugging Face
3. **Выбор модели**: какую загрузить в память
4. **Developer** — локальный сервер (слайд 11)

> Бесплатно, в том числе для работы. Windows, Mac (Apple Silicon), Linux. Версия 0.4.26.

ДЕМО 1

Демо: скачать маленькую модель и задать ей рабочий вопрос

1 Найти
Discover → «granite-4.2-3b»

→

2 Скачать
Q4_K_M · 2,2 ГБ

→

3 Загрузить
выбрать модель в чате

→

4 Спросить
промпт ниже

→

5 Посмотреть
токенов/с под ответом

ПРОМПТ

```
Тикет: «Клиент не может сбросить пароль после смены
телефона».
Верни JSON: проблема, срочность (низкая/средняя/высокая),
следующий шаг.
```

Что замечаем: ответ приходит без интернета; под ответом скорость в токенах в секунду; в диспетчере задач растёт память.

Запасной план: если Wi-Fi медленный, модель скачана заранее; показываем на ней.

ЛОКАЛЬНЫЙ СЕРВЕР

Включили сервер — и модель отвечает вашему коду, как облачный API

PYTHON, ТОТ ЖЕ КОД, ЧТО В L03

```python
from openai import OpenAI

client = OpenAI(
    base_url="http://localhost:1234/v1",
    api_key="lm-studio")                # для облака: ваш ключ

r = client.chat.completions.create(
    model="granite-4.2-3b",
    messages=[{"role": "user", "content": ticket}])
print(r.choices[0].message.content)
```

МЕНЯЮТСЯ АДРЕС И ИМЯ МОДЕЛИ (И КЛЮЧ)

Облако (OpenAI)
`https://api.openai.com/v1`
`gpt-5.4-mini`

Ноутбук (LM Studio)
`http://localhost:1234/v1`
`granite-4.2-3b`

Ноутбук (Ollama)
`http://localhost:11434/v1`
`granite4.2:3b`

> В LM Studio: вкладка **Developer → Start server**. Адрес `localhost` значит «этот компьютер».

ПРАКТИКА С АГЕНТОМ

Агент разработки ставит модель за вас и сам меряет скорость

ПРОМПТ ДЛЯ CLAUDE CODE, CODEX ИЛИ ANTIGRAVITY

```
Установи на этот компьютер Ollama (официальный установщик с
ollama.com) и запусти открытую модель granite4.2:3b.
1. Проверь видеокарту и её память, оперативную память и свободное
место на диске. Скажи, какая модель подойдёт.
2. Скачай модель и задай ей вопрос: «Кратко: что такое квантизация?»
3. Замерь скорость (токенов в секунду) и сколько памяти заняла
модель.
4. Покажи, по какому адресу работает локальный сервер, и пришли
пример запроса на Python.
5. Ничего не открывай в сеть, сервер только на localhost.
```

Ollama — похожая программа, которой удобно управлять командами: `ollama run granite4.2:3b`.

Агент проверит железо, поставит программу, скачает модель и принесёт отчёт: скорость, память, адрес сервера.

Агент ставит программы на ваш компьютер: читайте, что он предлагает выполнить, и подтверждайте шаги.

БЕЗОПАСНОСТЬ

«Локально» ещё не значит «приватно»: смотрим весь путь данных

- **Модель считает на вашем компьютере**
  сам текст запроса никуда не уходит
- **Скачивание моделей и обновления**
  идут в интернет; качайте из официальных источников
- **Плагины и веб-поиск**
  могут отправлять данные наружу
- **Сервер открыт в сеть (не localhost)**
  к модели могут обратиться другие; включайте Require Authentication

Правило урока: сервер только на `localhost`, модели только из Hugging Face от известных авторов, документы клиентов — только с разрешения.

> Лицензия модели тоже часть безопасности: нельзя «случайно» встроить некоммерческую модель в продукт.

РЫНОК • ОКТЯБРЬ 2026

Открытые модели по размеру: что запускать на чём

Видеокарта до 8 ГБ		Видеокарта 16–24 ГБ		Сервер, много видеокарт	
Granite 4.2 3B · 8B	Apache-2.0	**Gemma 4 12B**	Apache-2.0	**DeepSeek V4.1**	MIT
Qwen3.5 4B · 9B	Apache-2.0	**gpt-oss-20b**	Apache-2.0	**gpt-oss-120b**	Apache-2.0
Gemma 4 E4B	Apache-2.0	**Qwen3.8 27B**	Apache-2.0	**Llama 4**	своя лицензия

> Почти всё под Apache-2.0. Для старта: **Granite 4.2 3B**; умнее, но нужна видеокарта: **Qwen3.5 9B** или **Gemma 4 12B**.

ПЕРЕРЫВ

5 минут: пока модель скачивается, можно выпить кофе

05:00

Дальше: аренда видеокарты в RunPod, цена, как выбрать, домашнее задание.

ПРЕДЕЛ НОУТБУКА

Когда ноутбука мало: четыре признака

Не влезает
модель больше памяти ноутбука

Слишком медленно
10 000 писем за ночь на процессоре не успеть

Много пользователей
один ноутбук отвечает одному человеку

Нужно 24/7
ноутбук закрывают и уносят домой

Решение: оставляем ту же модель и тот же код, но переносим расчёт на мощную видеокарту в облаке. Меняется только адрес.

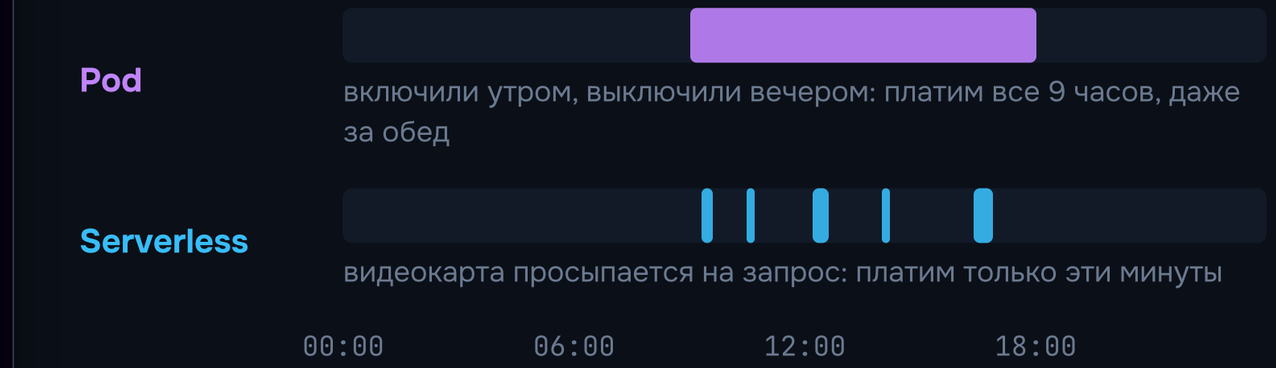
RunPod: видеокарта в аренду с посекундной оплатой, два режима

RUNPOD.IO/PRICING · COMMUNITY CLOUD · СНЯТО 16.10.2026



Зелёным: RTX 4090, 24 ГБ — $0.34 в час

ОДИН РАБОЧИЙ ДЕНЬ БОТА ПОДДЕРЖКИ

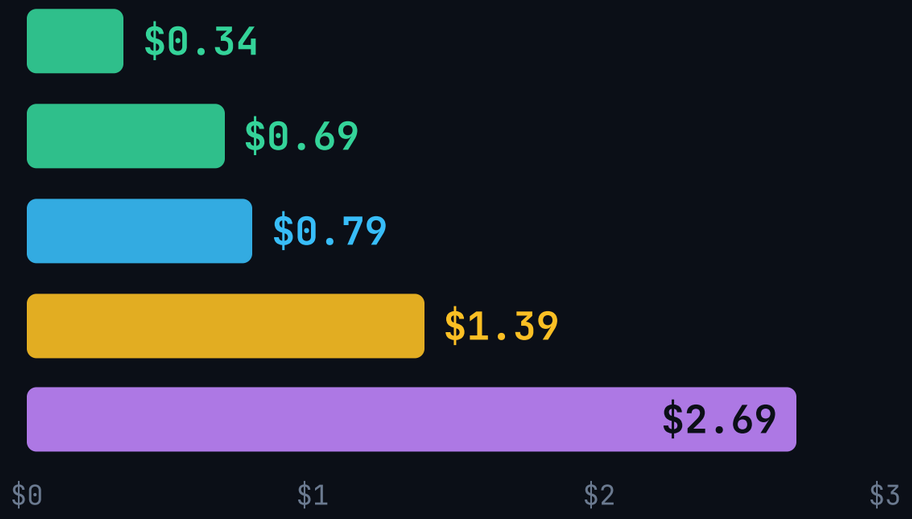


> **Ловушка:** остановленный Pod (Stop) продолжает брать плату за диск. Закончили — удалите (Terminate).

ЦЕНА

Аренда видеокарты выгодна, только если она всё время занята

RunPod Pods, цена за час, 16.10.2026



$0.73 → $7.30

за 1 млн токенов на RTX 4090 (модель 8B, ≈130 токенов/с): занята **100%** времени → занята **10%**

$0.40–4.50

за 1 млн токенов ответа у дешёвых облачных моделей (Gemini Flash-Lite, GPT mini)

> Простаивающая видеокарта стоит столько же, сколько работающая. Причина брать свою модель — чаще приватность и контроль, а не экономия.

КАК ВЫБРАТЬ

Выбор по двум вопросам: можно ли отдать данные и сколько работы

	Мало запросов	Много запросов
Данные можно отдать поставщику модели	**Облачный API** ChatGPT, Gemini, Claude: лучшее качество, платим за запросы	**Облачный API** пакетная обработка у поставщика обычно дешевле аренды
Данные должны остаться у вас	**Свой ноутбук** LM Studio, Ollama	**RunPod** Pod — ровный поток; Serverless — запросы волнами

> RunPod — тоже чужой компьютер, но модель и данные под вашим контролем, а не у поставщика модели. Код держим так, чтобы адрес менялся одной строкой.

ДОМАШНЕЕ ЗАДАНИЕ

ДЗ: запустить модель у себя и честно сравнить с облаком

1. Поставьте LM Studio или Ollama, скачайте модель 3–9B в Q4
2. Дайте ей 3 рабочие задачи и те же задачи ChatGPT или Gemini
3. Запишите скорость (токенов/с) и сколько памяти заняла модель
4. Сравните ответы по шкале 1–5 и сделайте вывод
5. Заполните карточку: API / ноутбук / Pod / Serverless и почему

```
L10_homework/
├─ README.md          # выбор и вывод
├─ results.md         # 3 задачи: локально vs облако
├─ speed.png          # скриншот с токенами/с
└─ decision.md        # карточка выбора
```

> Нет подходящего компьютера? Возьмите самую маленькую модель (Granite 4.2 3B, 2,2 ГБ) — она работает и без видеокарты.

Только синтетические или свои данные. RunPod — по желанию, платно.

ИТОГИ

Итоги урока

Открытая модель = файл + лицензия
ищем на Hugging Face, читаем карточку

Q4 + 25% должно влезть в видеокарту
иначе медленно; без видеокарты берём 3–4B

LM Studio или Ollama → localhost
в коде меняется одна строка; сервер не открываем в сеть

RunPod: платим и за простой
закончили — Terminate, не Stop

Дальше, L11: вызов функций и первый агент: модель не только отвечает, но и действует.