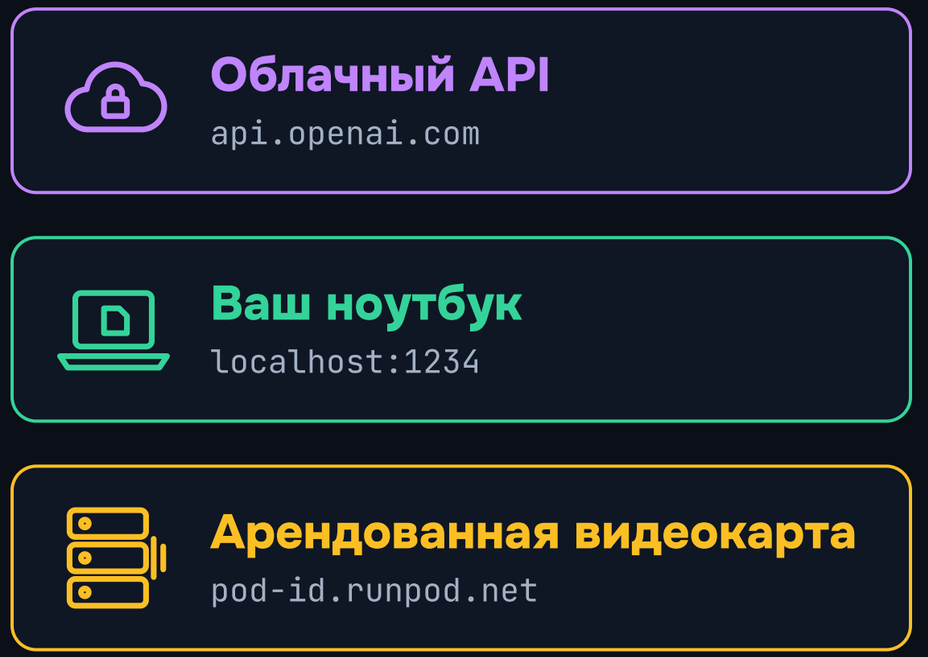
GENAI BASICS • УРОК 10 • МОДУЛЬ 4: ОТКРЫТЫЕ МОДЕЛИ

Открытые модели

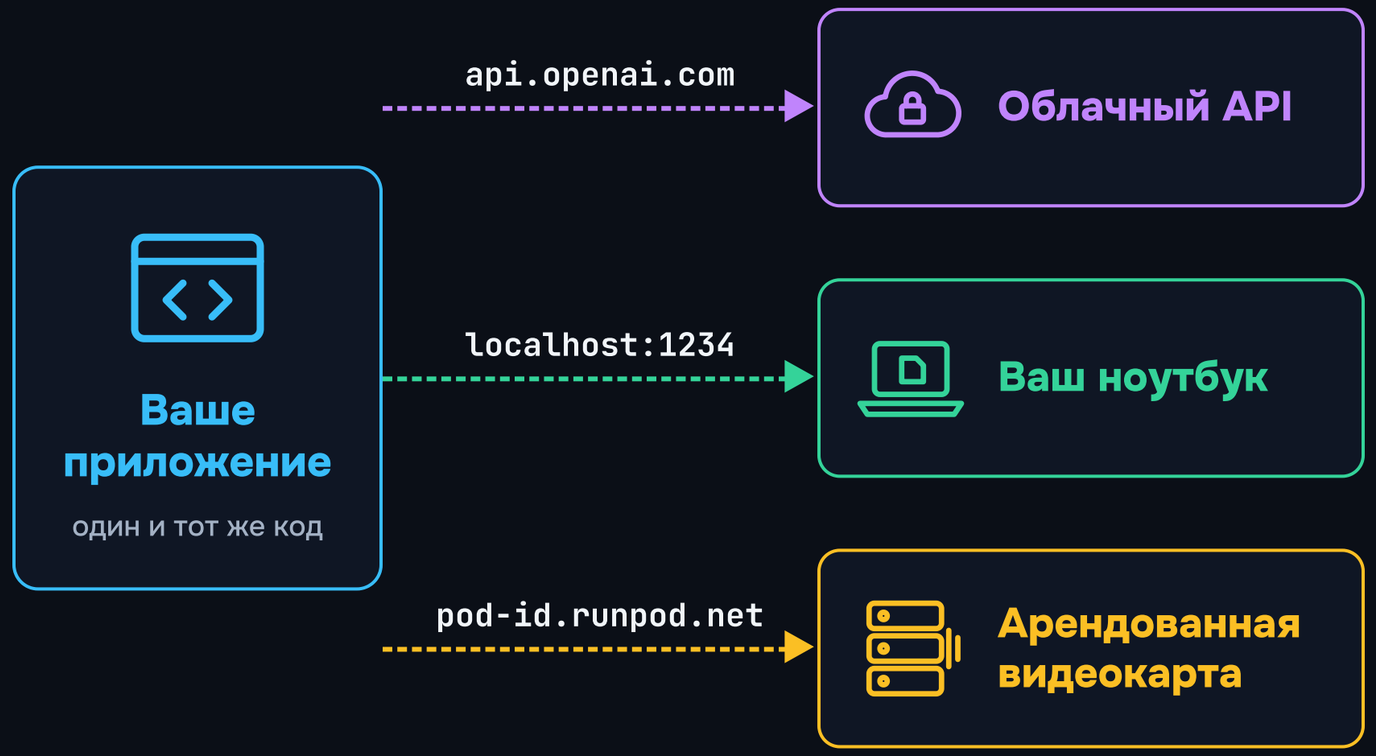
Как запустить языковую модель на своём ноутбуке и на арендованной видеокарте

Hugging Face, LM Studio, Ollama, Runpod. Размер модели, память, скорость, цена. Данные на октябрь 2026.



ИДЕЯ УРОКА

Одно приложение, три места, где работает модель



1. **Облачный API**: модель у поставщика, платим за токены, данные уходят к нему
2. **Ваш ноутбук** (localhost = «этот компьютер»): файл модели у вас, интернет не нужен, платите железом
3. **Арендованная видеокарта**: ваша модель на чужом мощном компьютере, оплата по часам

> **Главное:** код приложения почти не меняется: меняются только адрес и имя модели.

ОТКРЫТАЯ МОДЕЛЬ

Открытая модель — это файл, который можно скачать, и лицензия к нему

HUGGING FACE · IBM-GRANITE/GRANITE-4.2-8B-GGUF · СНЯТО 16.10.2026



1. **Кто сделал**: IBM, Granite 4.2 8B. **8B** = 8 млрд параметров, то есть чисел внутри модели
2. **Лицензия** Apache-2.0: можно в работе и в коммерции
3. **Файлы .gguf** (формат для LM Studio и Ollama): одна модель в разных размерах, здесь около 5–9 ГБ; полный список — слайд 6

Hugging Face — главный «склад» открытых моделей. У каждой есть карточка: что умеет, ограничения, лицензия.

«Открытая» ≠ «можно всё». У Llama 4 своя лицензия с ограничениями, у MusicGen (L06) только некоммерческая.

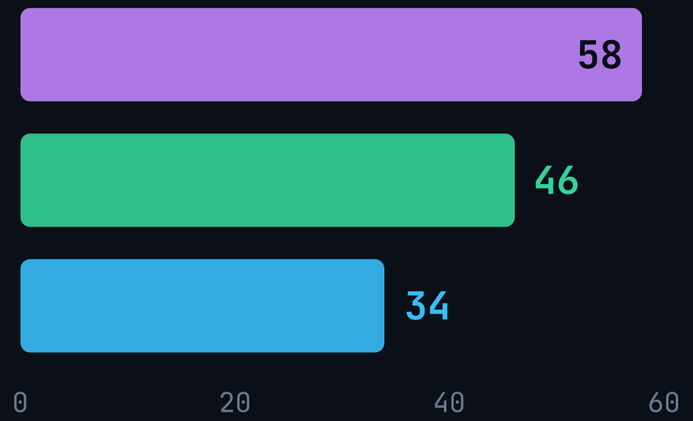
ЗАЧЕМ

Своя модель: данные не уходят, но качество ниже лидеров

Плюсы: данные не покидают компьютер · работает без интернета · нет счёта за токены · модель не поменяют без вас

Минусы: слабее лучших облачных · нужна память и видеокарта · установка и обновления на вас

ИНДЕКС «ИНТЕЛЛЕКТА» ARTIFICIAL ANALYSIS, ОКТЯБРЬ 2026



Чем выше, тем лучше. Разрыв между лучшей закрытой и лучшей открытой ≈ 12 пунктов.

ЛОКАЛЬНАЯ МОДЕЛЬ НА РАБОЧИХ ЗАДАЧАХ

✓ разбор писем и тикетов

✓ черновики

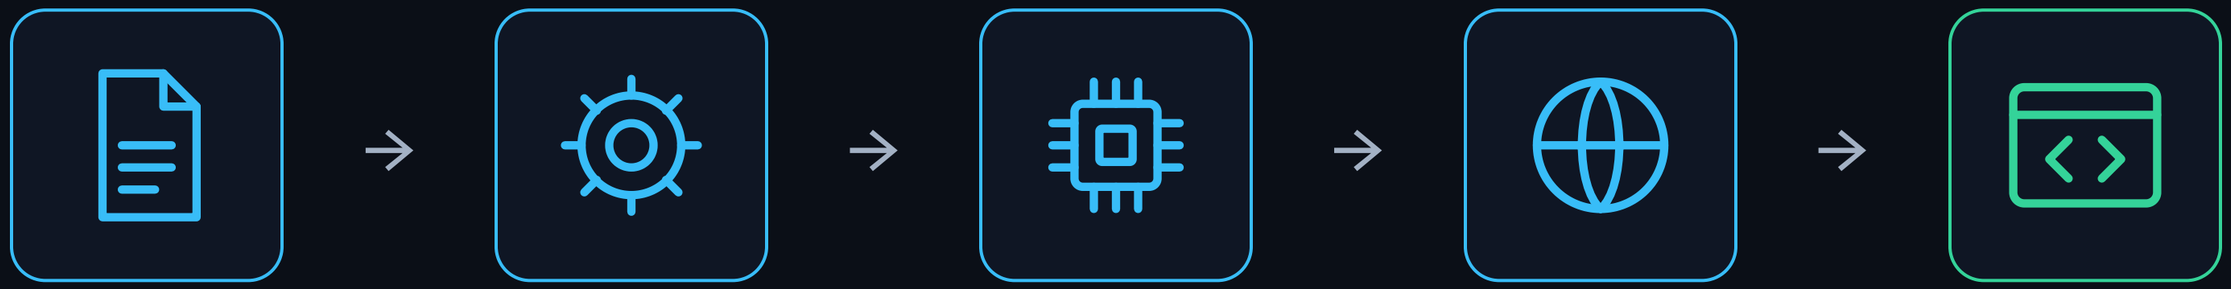
✓ поиск по своим документам

✗ сложные рассуждения, большой код

КАК ЭТО УСТРОЕНО

Пять частей: файл, движок, железо, сервер, приложение

LM Studio или Ollama делают это за вас



Файл модели
веса, .gguf

Движок
llama.cpp

Железо
процессор, видеокарта, память

Сервер
localhost:1234

Приложение
чат или Python

Движок (llama.cpp) умеет «прочитать» файл модели и посчитать ответ. **Сервер** даёт к нему адрес, как у облачного API.

Если тормозит, ищем, какая часть виновата: файл слишком большой? нет видеокарты? Не «модель плохая».

РАЗМЕР ФАЙЛА

Сжатие (квантизация): та же модель в 2–5 раз меньше, чуть хуже качество

GRANITE 4.2 8B: РАЗМЕРЫ ФАЙЛОВ НА HUGGING FACE



Q4

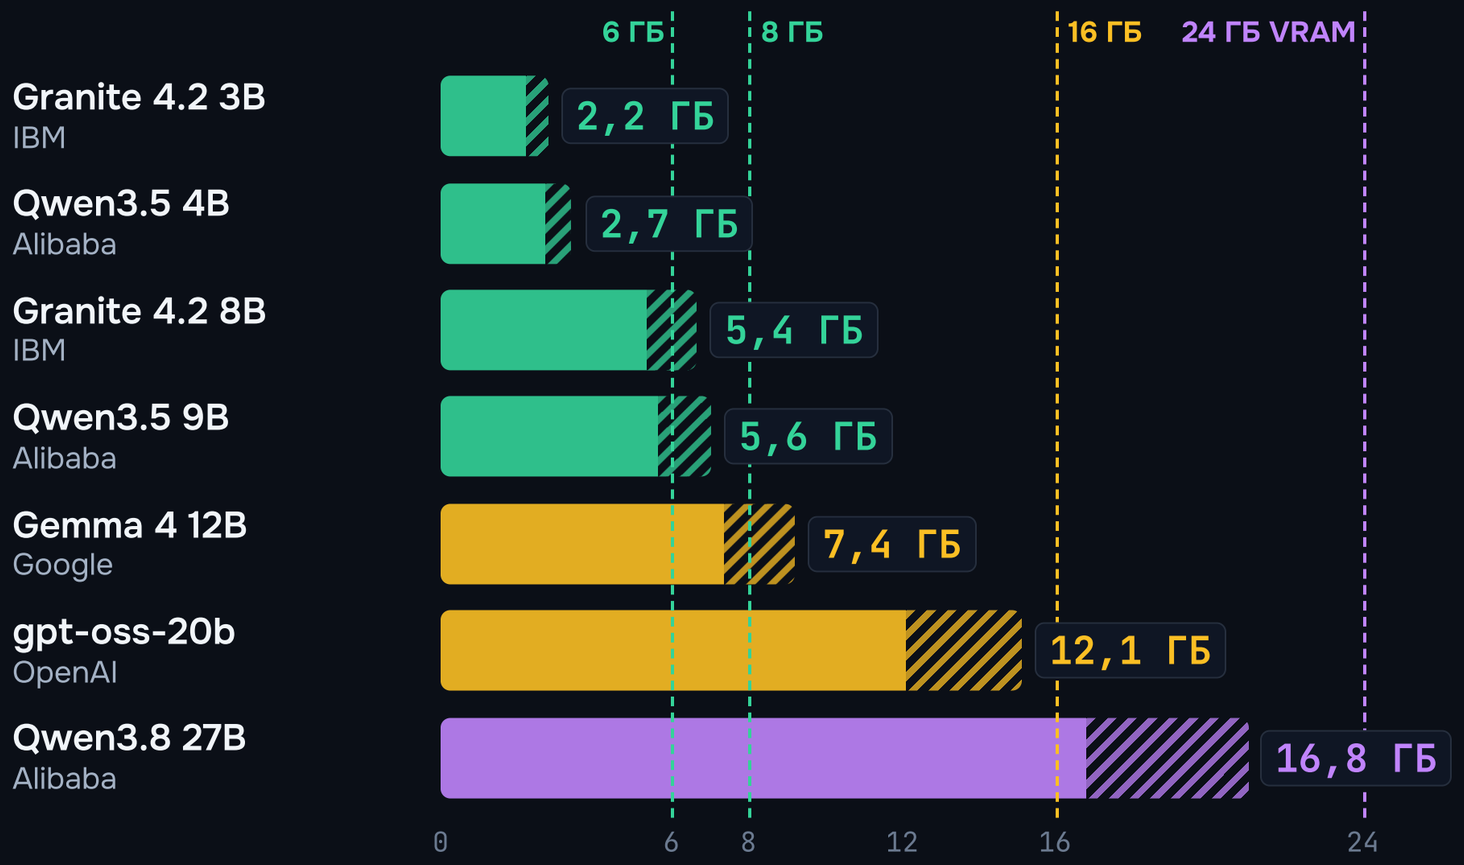
начинаем с 4 бит: так советует и документация LM Studio

> **Как это работает:** каждое число модели хранят грубее, меньшим числом бит. Как JPEG для фото: файл меньше, детали чуть теряются.

ВЛЕЗЕТ ЛИ

Файл модели плюс запас на разговор должен влезть в память видеокарты

ФАЙЛ Q4_K_M + ЗАПАС 25% (ШТРИХОВКА) · ЦВЕТ = НАИМЕНЬШАЯ ВИДЕОКАРТА, КУДА МОДЕЛЬ ВЛЕЗАЕТ



+25%

к файлу: память на контекст, то есть историю разговора (обычно 20–30%)

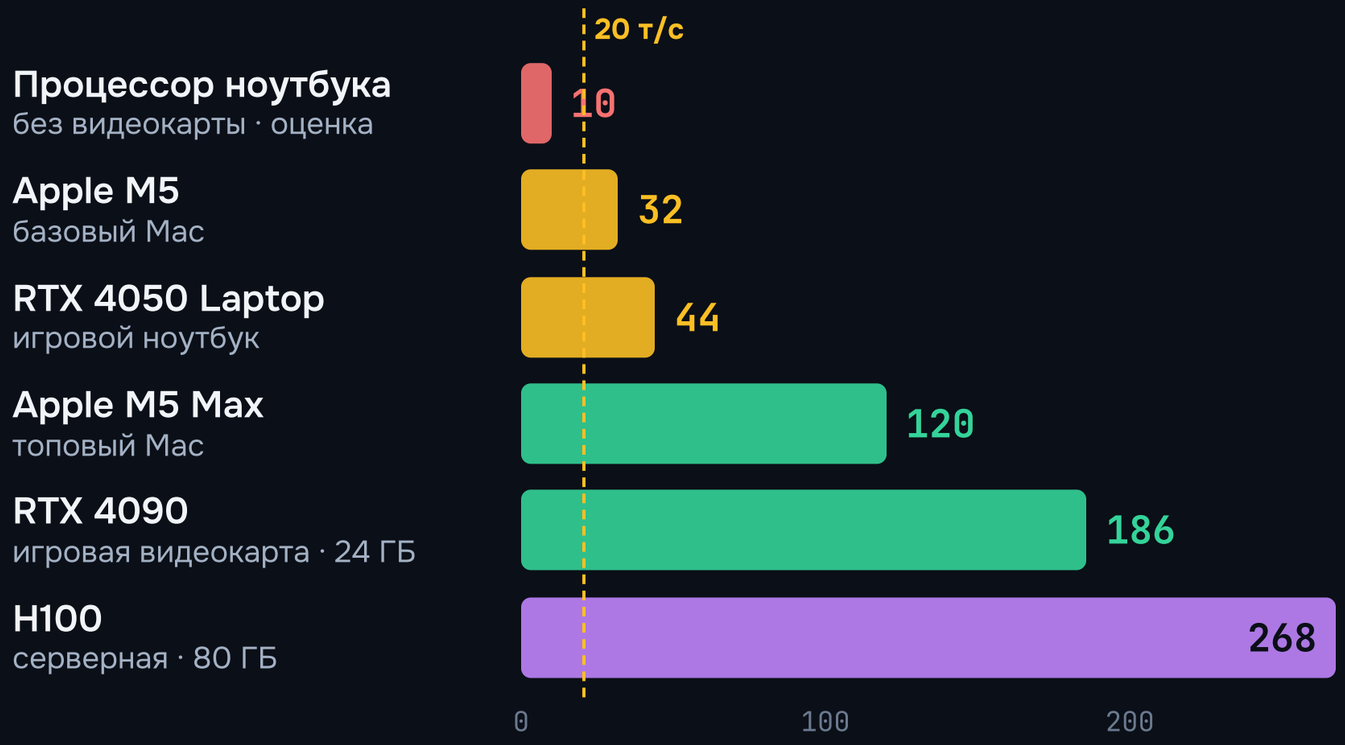
Память видеокарты (VRAM): **6 ГБ** → до 4B · **8 ГБ** → до 9B · **16 ГБ** → до 12B (20B впритык) · **24 ГБ** → до 27B.

Без видеокарты модель живёт в обычной памяти: влезет, но будет медленно. Берите 3–4B.

СКОРОСТЬ

Видеокарта отвечает в 2–25 раз быстрее процессора

Токенов в секунду (токен ≈ часть слова), модель 7B в 4 битах, llama.cpp. Человек читает ≈ 4–7 токенов в секунду.



≥ 20 т/с

комфортно: длинный ответ без ожидания; 10 т/с терпимо только для коротких

> Числа ориентировочные: зависят от модели, длины разговора и настроек. Свою скорость LM Studio показывает под каждым ответом.

СКОЛЬКО ЖДАТЬ ОТВЕТ НА ПОЛСТРАНИЦЫ (≈ 300 ТОКЕНОВ)

30 с
Процессор

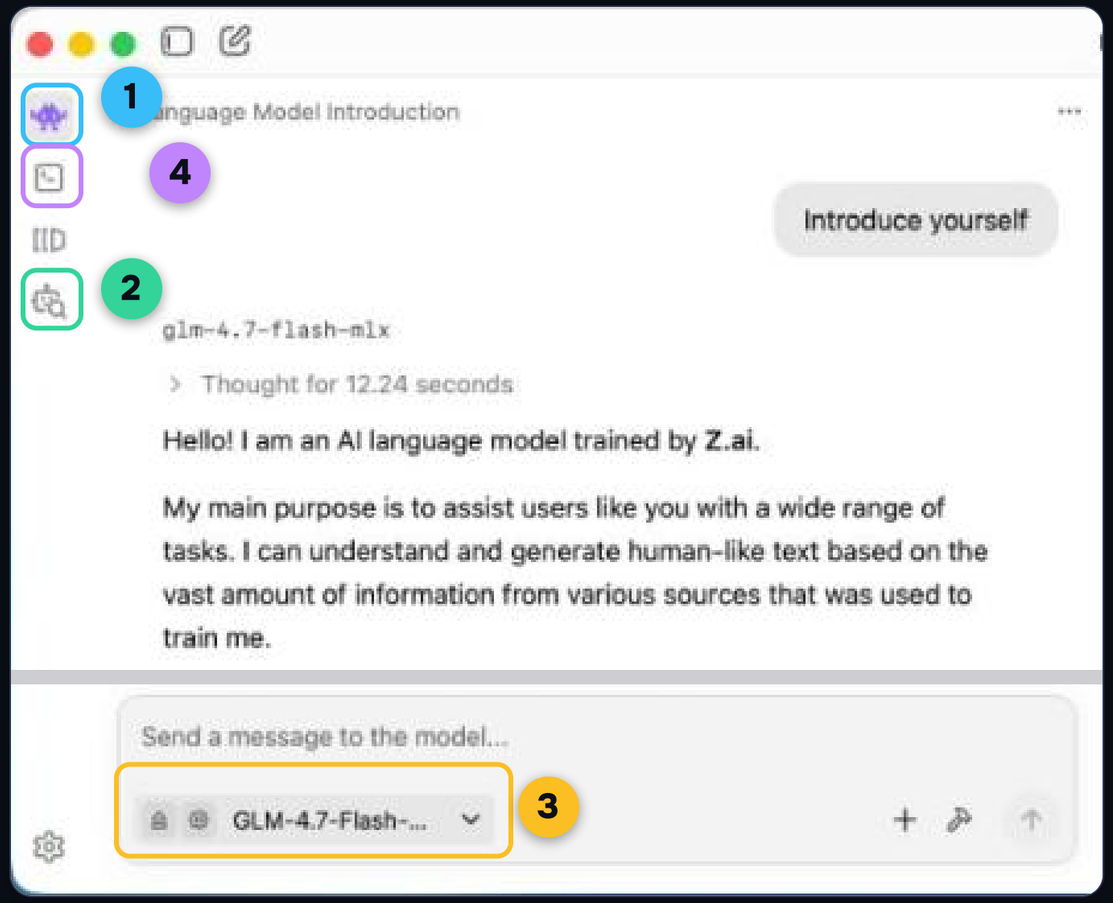
9 с
Apple M5

7 с
RTX 4050 Laptop

1,6 с
RTX 4090

LM STUDIO

LM Studio: чат как ChatGPT, но модель работает у вас



Изображение: LM Studio / Element Labs, блог версии 0.4.0 (фрагмент: левый чат)

1. **Chat** — разговор с моделью
2. **Discover** — поиск и скачивание моделей с Hugging Face
3. **Выбор модели**: какую загрузить в память
4. **Developer** — локальный сервер (слайд 11)

> Бесплатно, в том числе для работы. Windows, Mac (Apple Silicon), Linux. Версия 0.4.26.

ДЕМО 1

Демо: скачать маленькую модель и задать ей рабочий вопрос

1. **Найти** — Discover → «granite-4.2-3b»
2. **Скачать** — Q4_K_M · 2,2 ГБ
3. **Загрузить** — выбрать модель в чате
4. **Спросить** — промпт ниже
5. **Посмотреть** — токенов/с под ответом

ПРОМПТ

```
Тикет: «Клиент не может сбросить пароль после смены
телефона».
Верни JSON: проблема, срочность (низкая/средняя/
высокая), следующий шаг.
```

ОБРАЗЕЦ ХОРОШЕГО ОТВЕТА (JSON)

```
{
  "проблема": "сброс пароля после смены телефона",
  "срочность": "средняя",
  "следующий_шаг": "проверить личность и сбросить
вход вручную"
}
```

> **Что замечаем:** ответ приходит без интернета; под ответом скорость в токенах в секунду; в диспетчере задач растёт память.

ЛОКАЛЬНЫЙ СЕРВЕР

Включили сервер — и модель отвечает вашему коду, как облачный API

PYTHON, ТОТ ЖЕ КОД, ЧТО В L03

```python
from openai import OpenAI

ticket = "Клиент не может сбросить пароль"
client = OpenAI(
    base_url="http://localhost:1234/v1",
    api_key="lm-studio")                # для облака: ваш ключ

r = client.chat.completions.create(
    model="granite-4.2-3b",
    messages=[{"role": "user", "content": ticket}])
print(r.choices[0].message.content)
```

МЕНЯЮТСЯ АДРЕС И ИМЯ МОДЕЛИ (И КЛЮЧ)

Облако (OpenAI)
`https://api.openai.com/v1`
`gpt-5.4-mini`

Ноутбук (LM Studio)
`http://localhost:1234/v1`
`granite-4.2-3b`

Ноутбук (Ollama)
`http://localhost:11434/v1`
`granite4.2:3b`

> В LM Studio: вкладка **Developer → Start server**. Адрес `localhost` значит «этот компьютер».

ПРАКТИКА С АГЕНТОМ

Агент разработки ставит модель за вас и сам меряет скорость

ПРОМПТ ДЛЯ АГЕНТА РАЗРАБОТКИ: CODEX В CHATGPT ИЛИ ANTIGRAVITY — БЕСПЛАТНО С ЛИМИТОМ, CLAUDE CODE — ПЛАТНО

```
Установи на этот компьютер Ollama (официальный установщик с
ollama.com) и запусти открытую модель granite4.2:3b.
1. Проверь видеокарту и её память, оперативную память и
свободное место на диске. Скажи, какая модель подойдёт.
2. Скачай модель и задай ей вопрос: «Кратко: что такое
квантизация?»
3. Замерь скорость (токенов в секунду) и сколько памяти заняла
модель.
4. Покажи, по какому адресу работает локальный сервер, и
пришли пример запроса на Python.
5. Ничего не открывай в сеть, сервер только на localhost.
```

Ollama — похожая программа, которой удобно управлять командами: `ollama run granite4.2:3b`.

Агент проверит железо, поставит программу, скачает модель и принесёт отчёт: скорость, память, адрес сервера.

Агент ставит программы на ваш компьютер: читайте, что он предлагает выполнить, и подтверждайте шаги.

БЕЗОПАСНОСТЬ

«Локально» ещё не значит «приватно»: смотрим весь путь данных

- **Модель считает на вашем компьютере**
  сам текст запроса никуда не уходит
- **Скачивание моделей и обновления**
  идут в интернет; качайте из официальных источников
- **Плагины и веб-поиск**
  могут отправлять данные наружу
- **Сервер открыт в сеть (не localhost)**
  к модели могут обратиться другие; включайте Require Authentication (вход по токену)

Правило урока: сервер только на `localhost`, модели только из официальных источников (Hugging Face, ollama.com) от известных авторов, документы клиентов — только с разрешения.

> Лицензия модели тоже часть безопасности: нельзя «случайно» встроить некоммерческую модель в продукт.

РЫНОК • ОКТЯБРЬ 2026

Открытые модели по размеру: что запускать на чём

Видеокарта до 8 ГБ

- **Granite 4.2 3B · 8B**
  Apache-2.0
- **Qwen3.5 4B · 9B**
  Apache-2.0
- **Gemma 4 E4B** (≈4B, для телефонов и ноутбуков)
  Apache-2.0

Видеокарта 16–24 ГБ

- **Gemma 4 12B**
  Apache-2.0
- **gpt-oss-20b**
  Apache-2.0
- **Qwen3.8 27B**
  Apache-2.0

Сервер, много видеокарт

- **DeepSeek V4.1**
  MIT
- **gpt-oss-120b**
  Apache-2.0
- **Llama 4**
  своя лицензия

> Почти всё под Apache-2.0. Для старта: **Granite 4.2 3B**; умнее, но нужна видеокарта: **Qwen3.5 9B** или **Gemma 4 12B**.

ПЕРЕРЫВ

5 минут: пока модель скачивается, можно выпить кофе

05:00

Дальше: аренда видеокарты в Runpod, цена, как выбрать, домашнее задание.

ПРЕДЕЛ НОУТБУКА

Когда ноутбука мало: четыре признака

Не влезает

модель больше памяти ноутбука

Слишком медленно

10 000 писем за ночь на процессоре не успеть

Много пользователей

один ноутбук отвечает одному человеку

Нужно 24/7

ноутбук закрывают и уносят домой

Решение: оставляем ту же модель и тот же код, но переносим расчёт на мощную видеокарту в облаке. Меняются только адрес и имя модели.

RUNPOD

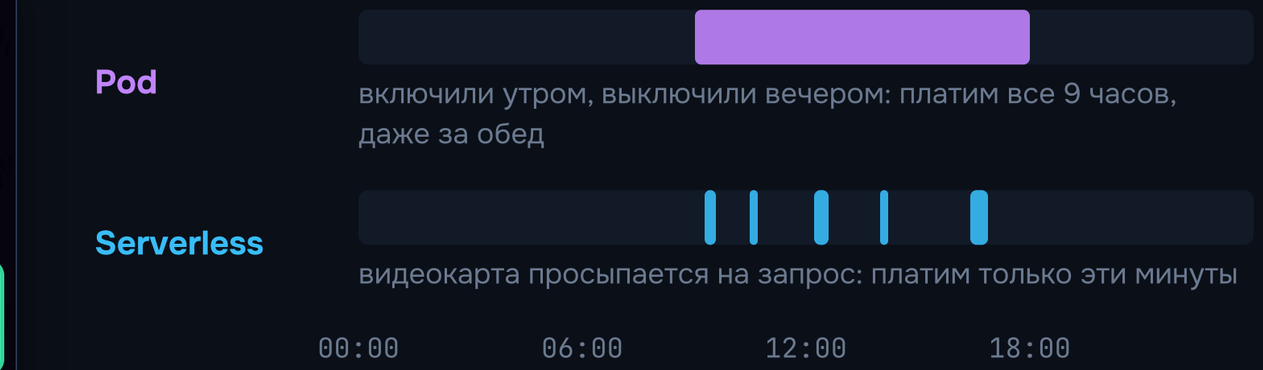
Runpod: видеокарта в аренду с посекундной оплатой, два режима

RUNPOD.IO/PRICING · COMMUNITY CLOUD · 24 ГБ · СНЯТО 16.10.2026

L4	24 GB VRAM	$0.44/hr
RTX 3090	24 GB VRAM	$0.22/hr
RTX 4090	24 GB VRAM	$0.34/hr
RTX A5000	24 GB VRAM	$0.16/hr

Зелёным: RTX 4090, 24 ГБ — $0.34 в час

ОДИН РАБОЧИЙ ДЕНЬ БОТА ПОДДЕРЖКИ



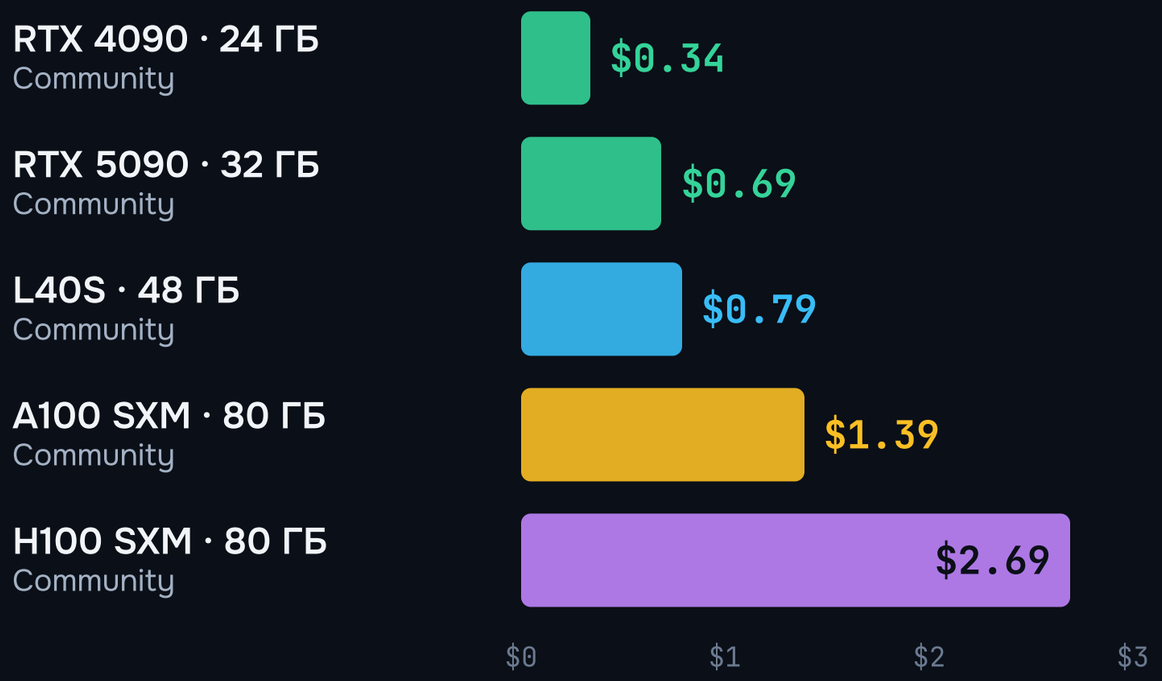
Ловушка: остановленный Pod (Stop) продолжает брать плату за диск. Закончили — удалите (Terminate).

ЦЕНА

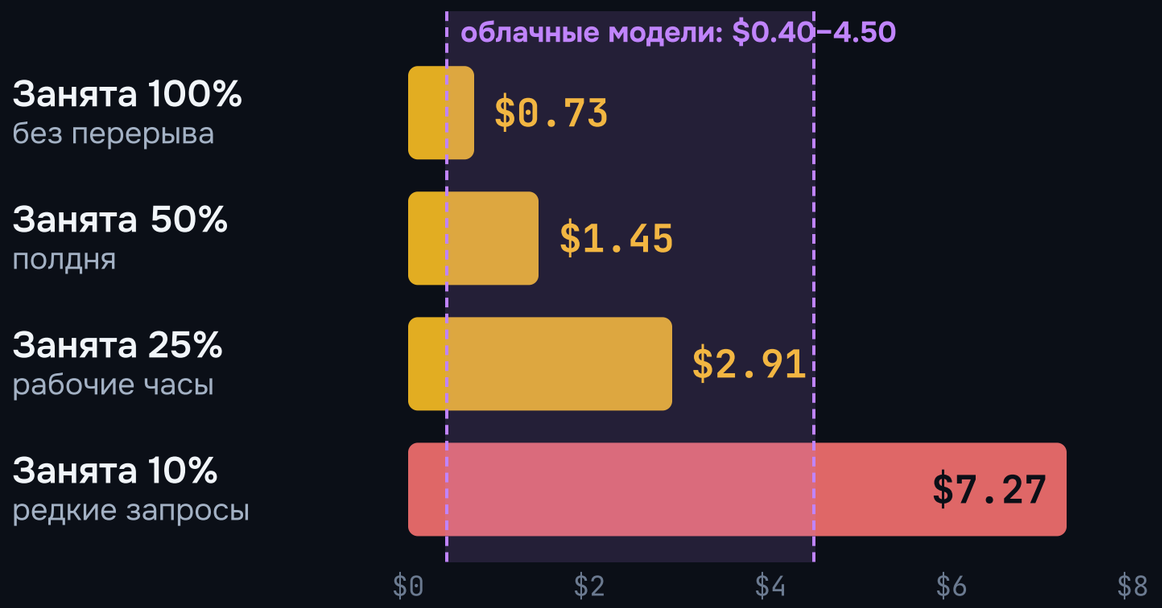
Аренда выгодна только при постоянной загрузке

Runpod Pods, цена за час, 16.10.2026

ЦЕНА ЗА ЧАС



RTX 4090, МОДЕЛЬ 8B: ЦЕНА 1 МЛН ТОКЕНОВ



Полоса: дешёвые облачные модели (Gemini Flash-Lite от $0.40, GPT mini до $4.50) за 1 млн токенов ответа, без платы за простой. Даже полностью занятая карта дороже самых дешёвых.

> Простаивающая видеокарта стоит столько же, сколько работающая. Причина брать свою модель — чаще приватность и контроль, а не экономия.

КАК ВЫБРАТЬ

Выбор по двум вопросам: можно ли отдать данные и сколько работы

	Мало запросов	Много запросов
Данные можно отдать поставщику модели	**Облачный API** ChatGPT, Gemini, Claude: лучшее качество, платим за запросы	**Облачный API** пакетная обработка у поставщика обычно дешевле аренды
Данные должны остаться у вас	**Свой ноутбук** LM Studio, Ollama	**Runpod** Pod — ровный поток; Serverless — запросы волнами

> Runpod — тоже чужой компьютер, но модель и данные под вашим контролем, а не у поставщика модели. При переезде меняются только адрес и имя модели. Для чувствительных данных — Secure Cloud (дороже, напр. RTX 4090 $0.89/ч).

ДОМАШНЕЕ ЗАДАНИЕ

ДЗ: запустить модель у себя и честно сравнить с облаком

1. Поставьте LM Studio или Ollama, скачайте модель 3–9B в Q4 (видеокарта 16 ГБ+: до 20B)
2. Дайте ей 3 рабочие задачи и те же задачи ChatGPT или Gemini
3. Запишите скорость (токенов/с) и сколько памяти заняла модель
4. Сравните ответы по шкале 1–5 и сделайте вывод
5. Заполните карточку: API / ноутбук / Pod / Serverless и почему

```
genai-homeworks/L10/
├─ README.md   # выбор и вывод
├─ results.md  # 3 задачи: у себя и в облаке
├─ speed.png   # скриншот с токенами/с
└─ decision.md # карточка выбора
```

> Нет подходящего компьютера? Возьмите самую маленькую модель (Granite 4.2 3B, 2,2 ГБ) — она работает и без видеокарты.

Только синтетические или свои данные. Runpod — по желанию, платно.

ИТОГИ

Своя модель — это файл и память, а в коде меняются только адрес и имя модели

Открытая модель = файл + лицензия

ищем на Hugging Face, читаем карточку

Q4 + 25% должно влезть в видеокарту

иначе медленно; без видеокарты берём 3–4B

LM Studio или Ollama → localhost

в коде меняются только адрес и имя модели; сервер не открываем в сеть

Runpod: платим и за простой

закончили — Terminate, не Stop

Дальше, L11: вызов функций и первый агент: модель не только отвечает, но и действует.