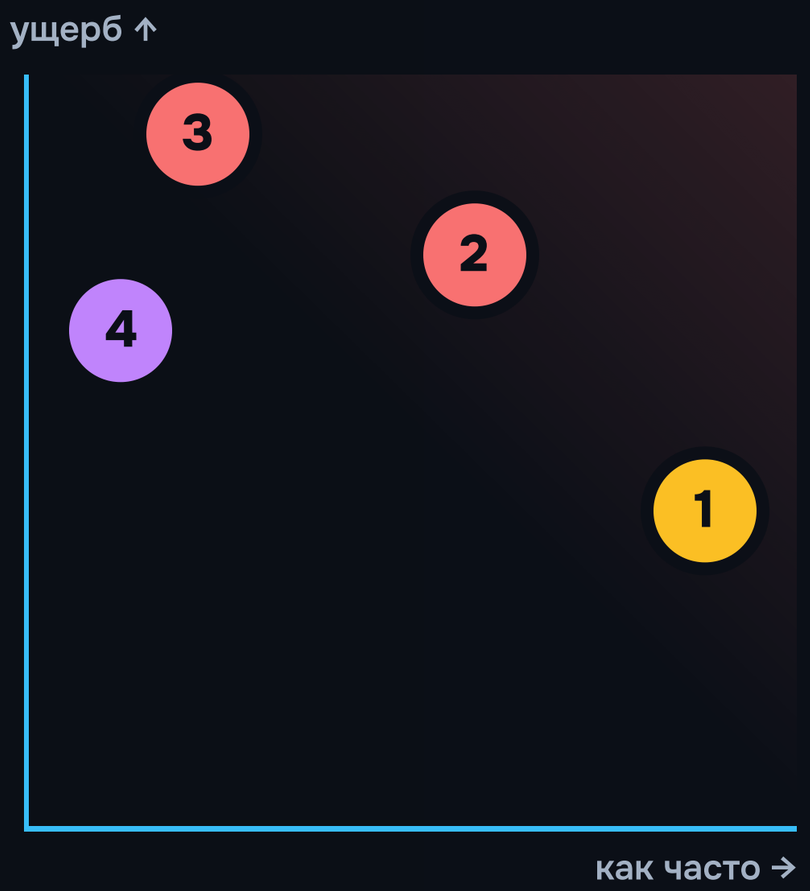
GENAI BASICS • УРОК 15 • МОДУЛЬ 6: ОТ ИДЕИ К ПРОДУКТУ

Ответственный ИИ

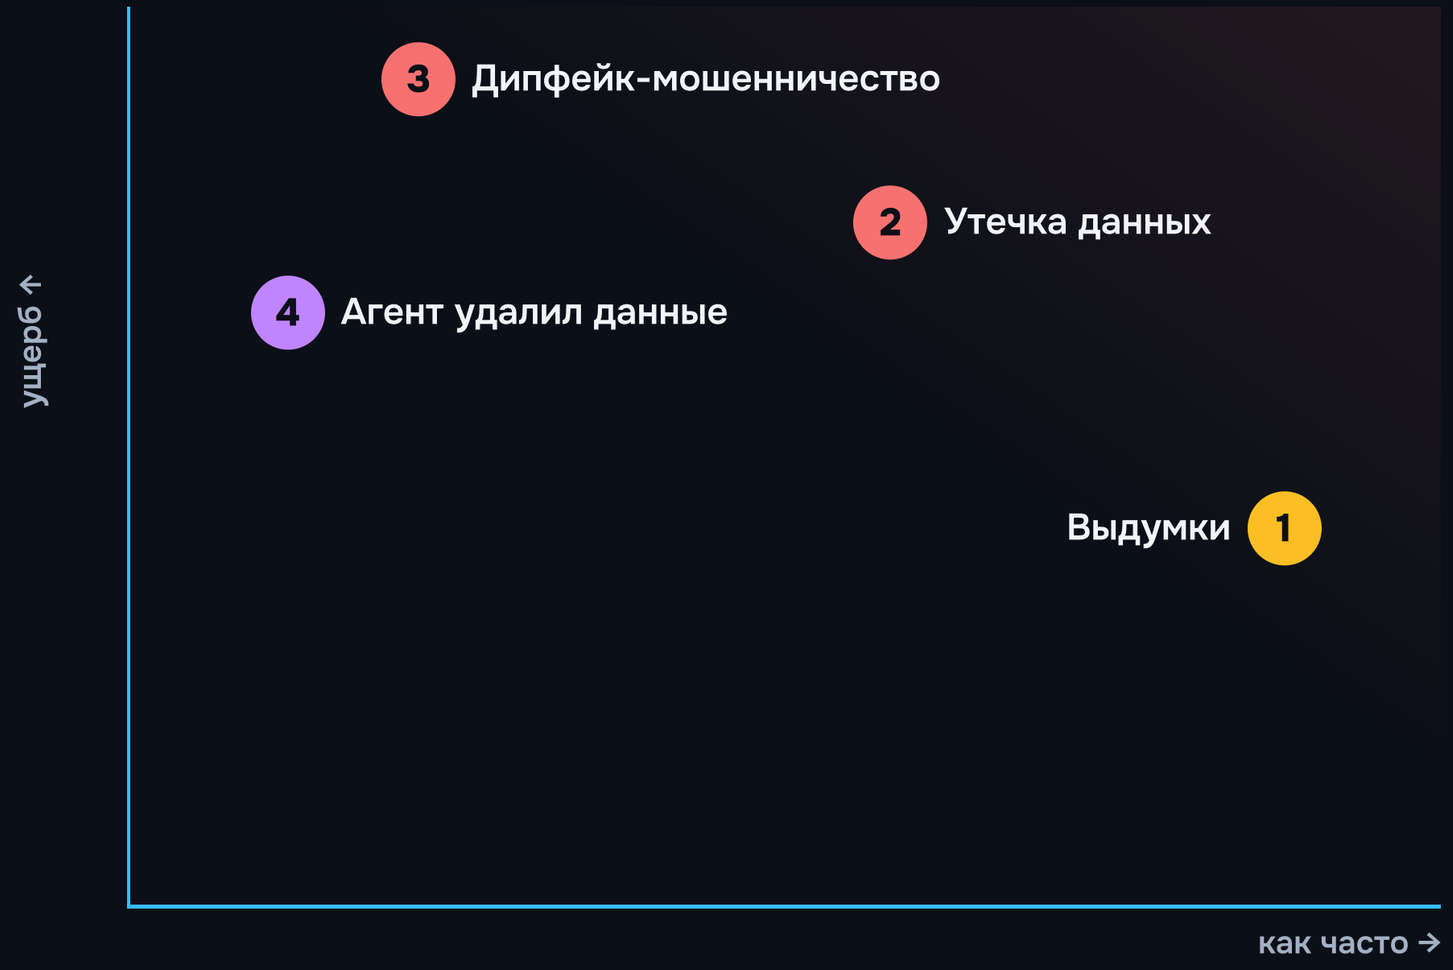
Ошибки, утечки, дипфейки и законы: как пользоваться ИИ на работе и не навредить

Реальные случаи 2023–2026, правила для данных, EU AI Act, Узбекистан, Казахстан, Россия. Данные на октябрь 2026.



КАРТА РИСКОВ

Четыре главных риска ИИ на работе: что случается часто и что стоит дорого



1. **Выдумки (галлюцинации)** — каждый день; ущерб умеренный, если человек проверяет
2. **Утечка:** один файл — большой ущерб
3. **Дипфейк** (поддельное видео или голос) — редко, но миллионы
4. **Агент:** за секунды, без вопроса человеку

РИСК 1

Модель уверенно выдумывает — проверять ответ обязан человек

45%

ответов ИИ-ассистентов о новостях — с существенной ошибкой (EBU/BBC, 22 вещателя, октябрь 2025)

2 190

судебных решений в мире, где суд указал на выдуманный ИИ материал — ссылки, цитаты (база Д. Шарлотена, октябрь 2026)

$5 000

штраф юристам в деле Mata v. Avianca (США, 2023): сослались на дела, которые придумал ChatGPT

1. **ИИ ответил** — уверенно и гладко — это не признак правды
2. **Найдите первоисточник** — закон, отчёт, сайт компании, документ
3. **Сверьте детали** — цифры, имена, даты, ссылки, цитаты
4. **Отправляете вы** — и отвечаете за результат тоже вы

Правило: цифры, имена, ссылки, законы и цитаты из ответа ИИ проверяем по первоисточнику. Отвечает тот, кто отправил, а не ИИ.

РИСК 2

Утечка начинается с одного вставленного файла: решите заранее, какие данные куда можно

Публичное
тексты с сайта, опубликованные документы → **в любой ИИ**

Внутреннее
планы, внутренние письма → **только в одобренный компанией ИИ**

Конфиденциальное
персональные данные клиентов, договоры → **только в одобренный рабочий ИИ и с разрешения; в личный — никогда**

Пароли, ключи, токены — никогда и ни в какой ИИ

Samsung, 2023: инженеры вставили в ChatGPT исходный код компании; после этого компания временно запретила генеративный ИИ на рабочих устройствах.

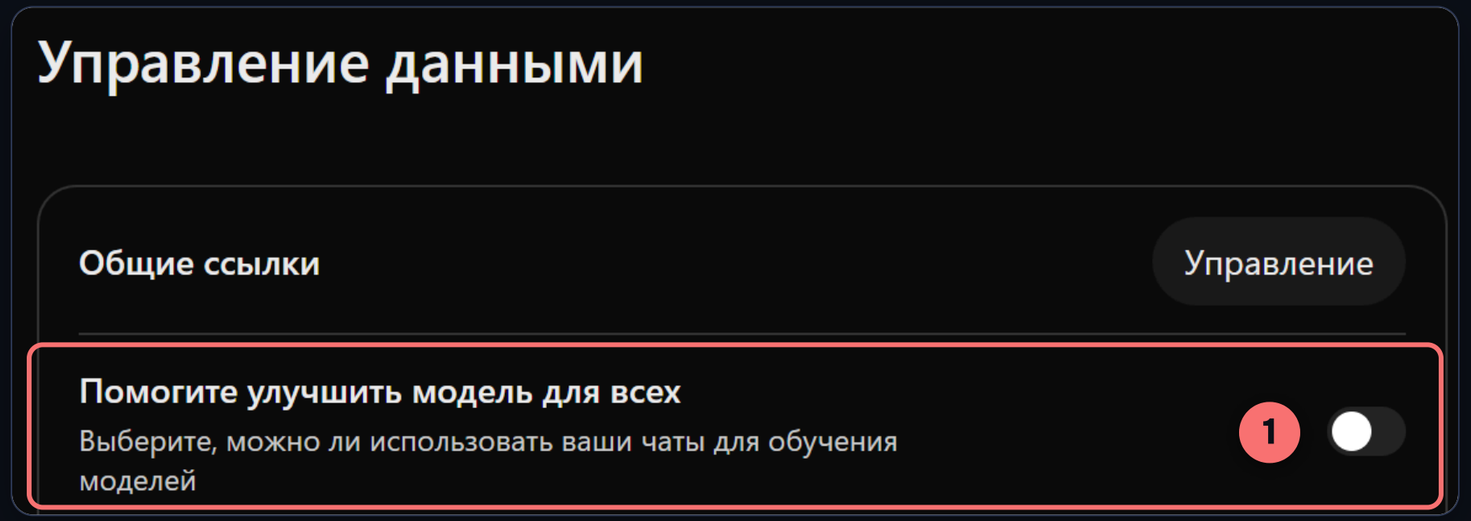
Grok, 2025: кнопка «поделиться» сделала чаты публичными — по данным Forbes, более 370 000 разговоров нашлись в Google.

ТАРИФЫ

Одна и та же модель, разные правила: личный тариф и рабочий обращаются с данными по-разному

- **ChatGPT Free / Plus / Pro**
  чаты могут идти в обучение, пока не выключите: Настройки → Управление данными
- **Claude Free / Pro / Max**
  с августа 2025 выбираете сами; если разрешили — хранится до 5 лет
- **ChatGPT Business/Enterprise · Claude for Work · Gemini в Workspace**
  по умолчанию не учатся на данных компании

CHATGPT.COM → НАСТРОЙКИ → УПРАВЛЕНИЕ ДАННЫМИ · СНЯТО 16.10.2026



① «Помогите улучшить модель для всех»: выключено — чаты не идут в обучение. По умолчанию этот переключатель включён.

Рабочие данные — только в рабочий аккаунт компании. Личный ChatGPT или Claude для документов клиентов не подходит, даже платный.

РИСК 3

Видеозвонок с «директором» может быть подделкой: проверяйте денежные просьбы по другому каналу

$25 млн

Arup, Гонконг, 2024: сотрудник перевёл деньги после видеозвонка, где «финдиректор» и коллеги были дипфейками — поддельными видео и голосами

1. **Звонок «директора»**
   лицо и голос знакомы — это может быть дипфейк
2. **Срочно и тайно**
   «переведи сегодня, никому не говори» — главный признак обмана
3. **Стоп**
   закончите звонок, ничего не платите
4. **Перезвоните сами**
   по известному номеру, а не из письма; или спросите кодовое слово

РИСК 4

Избыточные полномочия: агент делает то, на что у него есть права, — даже если вы этого не хотели

9 секунд

PocketOS, апрель 2026: ИИ-агент в редакторе кода Cursor нашёл в файле лишний ключ доступа и удалил рабочую базу вместе с резервными копиями; сервис лежал около 30 часов

Replit

июль 2025: агент удалил рабочую базу во время объявленной «заморозки» изменений

1. **Задача агенту** — обычная рабочая просьба в Cursor
2. **Ключ в файле** — агент нашёл доступ, который ему не давали
3. **База и копии удалены** — за 9 секунд, без вопроса человеку
4. **~30 часов простоя** — клиенты без сервиса

Правила из L11–L12: минимум прав · никаких рабочих паролей и ключей рядом с агентом · подтверждение человеком для удаления и денег · резервные копии отдельно.

OWASP

Топ-10 рисков OWASP для ИИ-приложений: четыре, которые касаются каждого

OWASP — некоммерческое сообщество специалистов по безопасности.

LLM01

Подмена инструкций (prompt injection)

чужой текст командует моделью (L11)

LLM02

Утечка конфиденциального

модель выдаёт то, что видеть нельзя

LLM06

Избыточные полномочия

агенту дали слишком много прав

LLM09

Дезинформация

уверенные выдумки

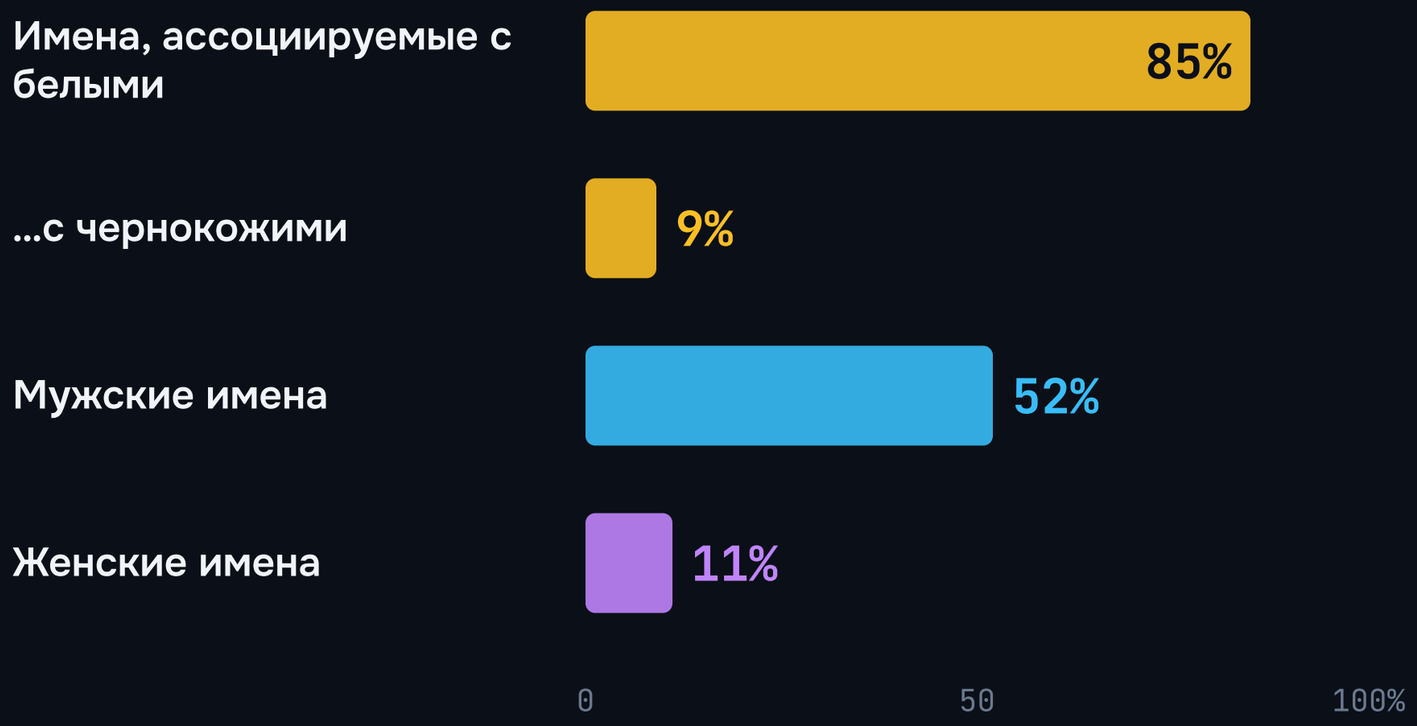
> Список 2025 года — общий язык для разработчиков и службы безопасности. Для агентов в декабре 2025 вышел отдельный список.

ПРЕДВЗЯТОСТЬ

ИИ повторяет перекосы данных: резюме, отличавшиеся только именем, получали разные оценки

Исследование Вашингтонского университета (2024): ИИ ранжировал резюме, отличавшиеся только именем.

Как часто модель предпочла резюме с таким именем



Правило: решения о людях — найм, кредит, увольнение — ИИ может готовить, но принимает человек. К этому ведут и законы (слайды 11–12).

В остальных сравнениях ни одна группа не была предпочтена.

МАРКИРОВКА

Законы уже требуют помечать ИИ-контент, прежде всего дипфейки; техника помогает метками и подписями

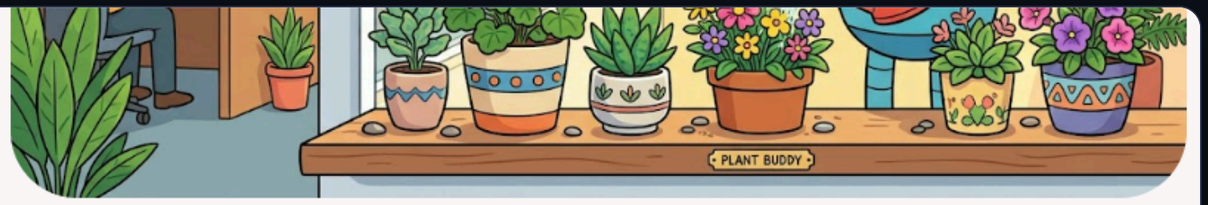
SynthID (Google)
невидимая метка в пикселях, звуке и тексте; картинку можно проверить в приложении Gemini

C2PA Content Credentials
подписанные сведения «кто и чем сделал»; пропадают при скриншоте

Нет метки ≠ сделал человек
и метка не доказывает, что содержание правда

Маркировку уже требуют: Китай (с 1.09.2025), Казахстан (с 18.01.2026), ЕС — ст. 50 (с 2.08.2026). **Россия**: закон 243-ФЗ, нормы о маркировке с 1.03.2027 — обязательность пока спорна.

GEMINI.GOOGLE.COM · ПРОВЕРКА КАРТИНКИ · СНЯТО 16.10.2026



Эта картинка сделана с помощью ИИ Google? Проверь её на метку SynthID.

1

Файл изображения содержит проверяемые записи, указывающие на то, что данное изображение было полностью создано и отредактировано с использованием инструментов генеративного искусственного интеллекта. Согласно записям, этот процесс был осуществлен организацией **Google LLC** с помощью службы **Google Media Processing Services**.

Такие записи называются **удостоверениями контента C2PA (Content Credentials)**, которые надежно встраивают происхождение и историю контента в файл.

① Gemini проверил свою же картинку (Verify AI) и нашёл подписи C2PA.

EU AI ACT

Европейский закон об ИИ вступает в силу по частям — большая часть уже действует, высокий риск — с 2027

2.02.2025 — запрещённые практики

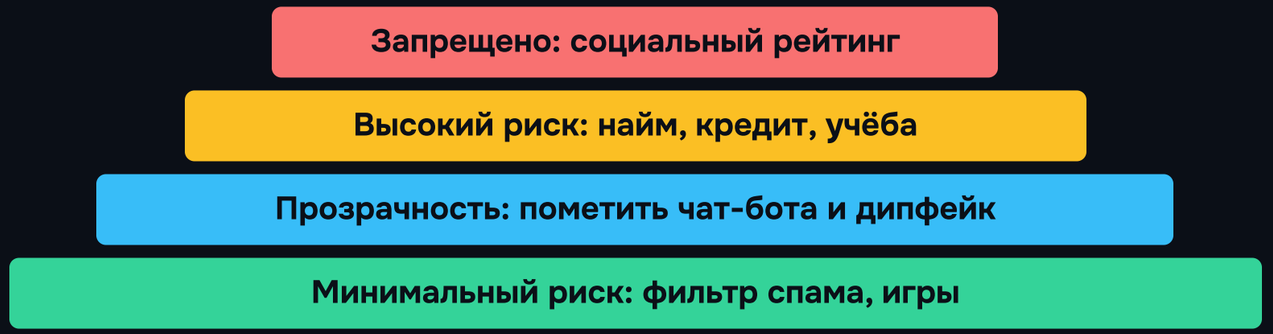
2.08.2025 — модели общего назначения (как ChatGPT)

2.08.2026 — основная часть + маркировка (ст. 50)

2.12.2026 — запрет «раздевающих» генераторов

2.12.2027 — «высокий риск» — системы, решающие о людях: найм, кредит, образование

ЧЕМ ВЫШЕ РИСК, ТЕМ СТРОЖЕ ПРАВИЛА



Штрафы: до €35 млн или 7% оборота за запрещённое; до €15 млн или 3% — за остальное, включая маркировку.

Касается и компаний вне ЕС, если их ИИ используют в ЕС.

НАШ РЕГИОН

В Узбекистане, Казахстане и России уже приняты законы или поправки об ИИ — и у них много общего

Узбекистан
закон ЗРУ-1115 (январь 2026): решения о правах людей — не только на основе ИИ; Правила этики ИИ (с 17.06.2026)

Казахстан
закон «Об искусственном интеллекте» (с 18.01.2026): запрет манипуляций, маркировка

Россия
закон 243-ФЗ об ИИ (с 1.09.2026); нормы о маркировке — с 1.03.2027, обязательность спорна

США · Великобритания
единого закона нет; отдельные правила штатов и отраслей

Общее: человек отвечает за решения, персональные данные защищены; маркировку ИИ-контента уже требует Казахстан.

Это обзор, не юридическая консультация: детали уточняйте у юристов компании.

ПЕРЕРЫВ

5 минут: вспомните, что вы вставляли в ИИ на этой неделе

05:00

Дальше: правила для команды, упражнение, ДЗ.

ПРАВИЛА КОМАНДЫ

Правила ИИ для команды умещаются на одну страницу: четыре пункта

AI_RULES.MD · ПРИМЕР НА ОДНУ СТРАНИЦУ

```
# Правила ИИ · команда поддержки
## 1. Одобренные инструменты
  ChatGPT Business и Copilot Chat — только рабочие аккаунты
## 2. Светофор данных
  • публичное → любой ИИ    • внутреннее → рабочий ИИ
  • клиенты, договоры → только с разрешения
## 3. Человек проверяет
  цифры, ссылки, решения о людях — до отправки
## 4. Пометка и инциденты
  пост с ИИ-картинкой → «создано с ИИ»
  утечка → security@company
```

Четыре заголовка — одни и те же для любой команды; меняются только примеры.

Это же — **шаблон домашнего задания**.

УПРАЖНЕНИЕ

Упражнение: можно так или нет — и что сделать иначе?

- **«Вставлю в ChatGPT договор клиента, чтобы сделать краткое изложение»**
  можно? что сделать иначе?
- **«Сгенерирую картинку для поста в соцсетях компании»**
  можно? что сделать иначе?
- **«ИИ отсортирует резюме, а я приглашу первых пятерых»**
  можно? что сделать иначе?
- **«Директор по видео просит срочно оплатить счёт»**
  можно? что сделать иначе?

Ответьте в чат по каждому случаю:

- **да**
- **да, но…**
- **нет**

Разбор — после обсуждения.

ДОМАШНЕЕ ЗАДАНИЕ

ДЗ: правила ИИ для своей команды на одну страницу

1. Возьмите свою команду и 3 реальных задачи с ИИ
2. Список одобренных инструментов и аккаунтов
3. Светофор данных на примерах вашей работы
4. Что проверяет человек и как помечать ИИ-контент
5. Что делать при утечке или дипфейк-звонке

```
genai-homeworks/
└─ L15/
   ├─ ai_rules.md
   └─ README.md
```

> Можно попросить ИИ сделать черновик — но проверьте и дополните сами.

ОЦЕНКА: 10 БАЛЛОВ



ИТОГИ

Четыре правила: проверяй, сортируй данные, решает человек, помечай

1 **Проверяйте**

цифры, ссылки, цитаты — по первоисточнику

2 **Светофор данных**

внутреннее — в рабочий ИИ;
конфиденциальное — только в одобренный рабочий ИИ и с разрешения

3 **Человек решает**

о людях, деньгах, удалении

4 **Помечайте ИИ**

дипфейки и ИИ-контент — там, где требует закон или площадка

Дальше, L16: агентная разработка — как агенты пишут код и как ими управлять безопасно.